

Identificar Sentimientos en Cuarentena por la Covid-19 mediante Clasificador Léxico y Aprendizaje Supervisado

Yonatan Mamani-Coaquira¹, Manuel J. Ibarra¹, Ecler Mamani Vilca¹,
Erech Ordoñez Ramos¹, Mario Aquino Cruz¹

ymamanic@gmail.com; manuelibarra@gmail.com; eclervirtual@gmail.com;
ingerech@gmail.com; mario.ac23@gmail.com

¹Escuela Profesional de Ingeniería Informática y Sistemas, Universidad Nacional Micaela Bastidas de Apurímac, Abancay, 03001, Apurímac, Perú.

Pages: 618-631

Resumen: La Covid-19 comenzó afectar a Perú el 6 de marzo de 2020, se iniciaron medidas preventivas para evitar la propagación. El 15 de marzo comenzó el aislamiento social obligatorio en todo el Perú, las personas utilizan Twitter para intercambiar diversas informaciones sobre el aislamiento social, esto es importante para autoridades y el público porque ayuda a considerar estrategias para evitar contagios. El presente trabajo tiene como objetivo clasificar los sentimientos positivos y negativos que fueron expresando en Twitter a través de la propuesta del Clasificador Léxico de Palabras y el uso de algoritmos clasificadores. El resultado obtenido fue que las palabras más frecuentes son: Cuarentena, Covid y Casa. Las palabras positivas fueron Bueno y Ganar, la palabra negativa fue Extraño. El modelo de clasificación de sentimiento alcanzó el 91.5% de precisión mediante el algoritmo Support Vector Machine y el Clasificador Léxico de Palabras.

Palabras-clave: covid-19, análisis de sentimiento, cuarentena, aprendizaje supervisado, clasificador léxico.

Identify Sentiments in Quarantine by Covid-19 through Lexical Classifier and Supervised Learning

Abstract: The Covid-19 began to affect Peru on March 6 of 2020, preventive measures were started to prevent the spread. On March 15 compulsory social isolation began throughout Peru, the people use Twitter to exchange various information about social isolation, this is important for authorities and the public because it helps to consider strategies to avoid contagion. The present work has the objective to classify the positive and negative sentiment that were expressed on Twitter through the proposal of the Lexical Word Classifier and the use of classifying algorithms. The result obtained was that the most frequent words are: Quarantine, Covid and Home. The positive words were Good and Win, the negative word was Strange. The sentiment classification model reached 91.5% accuracy using the Support Vector Machine algorithm and the Lexicon Word Classifier.

Keywords: covid-19, sentiment analysis, quarantine, supervised learning, lexical classifier.

1. Introdução

La enfermedad del coronavirus inició en Wuhan, China, fue reportado y confirmado el 31 de diciembre del 2019 (Organization, 2020a), según la Organización Mundial de la Salud (OMS) la enfermedad es conocida como COVID-19 (coronavirus disease 2019). Esta enfermedad ha causado una crisis de salud pública nacional y mundial (Wu, Leung, & Leung, 2020), según sus características epidemiológicas es una enfermedad infecciosa emergente que se propaga rápidamente entre humanos, los síntomas comunes son: fiebre (37.3°C o más), cansancio y tos seca, la OMS menciona que la forma de propagarse es a través de gotículas que procede de la nariz o boca y recomienda mantenerse más de un metro de distancia de la persona enferma (Organization, 2020b). Hasta el 23 de Abril (18:00 GMT-5) del 2020 en todo el mundo se han confirmado 2 699 338 casos, 737 735 recuperados, 188 437 muertos, y en Perú en esa misma fecha se tenía 20 914 casos confirmados, 1139 recuperados y 572 muertos (Dong, Du, & Gardner, 2020)(Dong, 2020). La forma de evitar la propagación de esta enfermedad es el distanciamiento entre personas. Varios países implementaron amplia gama de medidas drásticas para mitigar la propagación de este virus. En Perú el primer caso fue confirmado el 6 de marzo de 2020 y el 10 de marzo confirman 11 casos, luego inició el incremento de casos diariamente, por estas razones el 15 de marzo de 2020 el presidente de Perú Martin Vizcarra Cornejo declaró el aislamiento social por 15 días de manera obligatoria, desde entonces inició restricciones de viajes a nivel nacional y fuera del país.

Con lo descrito anteriormente la población se ha mantenido en casa todo el día, si salía de casa solo podía realizar actividades de primera necesidad, por esta razón; el internet se convirtió en una herramienta imprescindible para la comunicación entre personas, también permite hacer actividades virtuales como: ver películas, realizar clases virtuales, conferencias virtuales, navegar en las redes sociales, entre otras actividades relacionadas con el uso de internet. Durante la crisis de la pandemia Covid-19, existen personas que utilizan las redes sociales para intercambiar opiniones en diferentes aspectos como: manifestar las actividades que están realizando en casa, compartir información que ayuden a las autoridades, personas interesados en comprender la situación, recomendación de clases virtuales, entre otras, esta información en relación a Covid-19.

El crecimiento exponencial del intercambio de mensajes en la red social Twitter ha cambiado paradigmas de comunicación en la sociedad. Existen Investigaciones que realizaron análisis de sentimientos en otro tipo de enfermedades como: Ebola (Xu, Wang, Jia, & Wang, 2016), Mers, Gripe Porcina y Sars utilizando la red social Twitter (Bobicev, Sokolova, Jafer, & Schramm, 2012) (Sharma & Mangat, 2016)(Kristanto, Prasetyo, & Pramana, 2019)(Lopez, Vasu, & Gallemore, 2020). Los trabajos científicos en el área de Data Mining y Machine Learning facilitan enormes posibilidades para mejorar el análisis de sentimientos a corto plazo.

Existe la necesidad de saber los sentimientos de actividades positivas o negativas que realizan las personas durante el aislamiento social. Para las autoridades es de

importancia saber actividades que realizan las personas, esto permitiría elaborar estrategias adecuadas en respuesta a la emergencia sanitaria.

El presente trabajo de investigación aplica una perspectiva innovadora desde el punto de vista de aplicación de algoritmos de aprendizaje supervisado, los criterios de selección de algoritmos son: simplicidad y efectividad que serán implementados en el lenguaje R, Python y el software Knime Analytics, al mismo tiempo se propone un Clasificador Léxico de Palabras para entender el contexto del comentario y poder mejorar la clasificación de sentimientos.

2. Trabajos relacionados

La clasificación de sentimientos es un área relacionado con el Procesamiento de Lenguaje Natural, Lingüística Computacional y Minería de Texto (Karamibekr & Ghorbani, 2012), los datos pueden ser extraídos de base de datos estructurados y no estructurados. Anis Zarrad (Zarrad, Jaloud, & Alsmadi, 2014) realizó un estudio de la opinión pública respecto a la infección del virus Mers-Cov en Arabia Saudita, en Twitter analizaron opiniones como: métodos de prevención y servicios ofrecidos por el Ministerio de Salud, construyó un clasificador léxico de polaridad con 1100 palabras negativas y 850 palabras positivas, e incluyó 8222 palabras entre positivas, negativas y neutro del diccionario léxico Multi-Perspective Question Answerin (MPQA). Evaluó 1 500 000 tweets, resultó que el 21.9% es positivo, 39.8% negativo y 38.2% neutro. Por otro lado; Than (Tran & Lee, 2016) realizó la comprensión de reacciones de los ciudadanos y la propagación de información relacionada con el Ébola en Twitter, logró adquirir conocimientos sobre reacciones de los ciudadanos y la propagación con temas del Ébola, además proporciona una base de análisis y respuestas futuros a crisis de salud pública.

Beryl (Beryl Joylin, Aswathi, Suma, & Victor, 2016) analizó los sentimientos positivos, negativos y neutros sobre el brote de Ébola utilizando datos de Twitter basado en Procesamiento de Lenguaje Natural, el resultado muestra el mayor porcentaje de tweets negativos, las palabras más frecuentes fueron: lágrimas, hospitalizado y empeora, las palabras positivas fueron: estudiar, me gusta, juntos y chistes. El trabajo de Purname (Kristanto et al., 2019) tuvo como objetivo evaluar los sentimientos positivos o negativos de Tweets para quienes utilizan los servicios de salud en Indonesia, aplicaron el algoritmo Naive Bayes para obtener resultados óptimos y concluye que el servicio de salud tiene el 70% de sentimientos negativos y 72% positivos para temas relacionados a información de salud.

Por otra parte, Li (Li et al., 2020) menciona que la información situacional de la pandemia Covid-19 es valioso para el público y autoridades, esto permite evitar la propagación, esta evaluación situacional fue realizado en la red social Weibo de China con datos relacionados a Covid-19, se utilizó la técnica de Procesamiento de Lenguaje Natural, Support Vector Machine, Naive Bayes y Random Forest, los comentarios tienen las palabras claves como: new coronavirus y unknown pneumonia, obtuvieron 36 746 comentarios desde 30/12/2019 hasta 01/02/2020. Al evaluar los resultados concluyeron que el mejor algoritmo fue Random Forest con 65% de precisión, también indican la necesidad de utilizar diferentes estrategias para publicar información situacional de Covid-19. Sin embargo, López (Lopez et al., 2020) evalúa identificar los discursos

populares sobre la pandemia de Covid-19 y políticas implementados para gestionarlo con datos de Twitter, de los 6 387 896 Tweets el 58.16% es idioma ingles y 16.66% de idioma español, las palabras claves de búsqueda fueron: virus, coronavirus, ncov19, ncov2019 y covid.

El grupo de investigación CoronaTracker (Amira et al., 2020) desarrolló una aplicación web para pronosticar el brote de Covid-19, al mismo tiempo, realizaron análisis de sentimientos positivos o negativos de noticias para comprender la influencia en el comportamiento de personas, política y economía. Analizando los datos encontraron 2548 artículos negativos con palabras frecuentes incertidumbre y enfermedad, y 561 artículos positivos con palabras frecuentes colaboración y fortaleza.

Con lo descrito anteriormente se observa la importancia de compartir información en redes sociales acerca de enfermedades y especialmente del Covid-19, pero aún hay escasa información situacional de las personas en casa durante el tiempo de aislamiento social obligatorio por la Covid-19, no considerar medidas respecto a esta información podría generar daños emocionales, sin embargo, es necesario identificar esta información de manera integral para ayudar a las autoridades en realizar actividades de apoyo social mediante el uso de internet, radio o televisión.

3. Metodología




Figura 1 – Etapas para el análisis de sentimientos mediante el Clasificador Léxico de Palabras

La metodología consta de realizar dos evaluaciones, la Figura 1 muestra las evaluaciones que se realizan para mejorar las clasificaciones de sentimientos, primero se tiene que realizar la evaluación 1 para encontrar el mejor algoritmo con mayor porcentaje de precisión (Accuracy), luego el algoritmo elegido será implementado en la evaluación 2 con la utilización del Analizador Léxico de Palabras, al final se realiza una comparación para ver quien clasificó mejor, DLEE3 es Diccionario Léxico Emociones en Español 3.

3.1. Etapa 1: recolección de datos

Para este estudio se creó una API (Application Programming Interface) en Twitter, luego se desarrolló una aplicación en el lenguaje R utilizando la librería rtweet para descargar los Tweets públicos sin necesidad de consentimiento porque tiene fines académicos, después se exportó los datos en hojas de cálculo, en este proceso se obtuvo 200 000 Tweets y retweets del 16/03/2020 al 30/04/2020 en este periodo fue donde hubo mayor participación de la población mediante los comentarios en las redes sociales. Los parámetros de búsqueda fueron: hashtag {#Dia1, #Dia2, #Dia3,..., #Dia46} con idioma Español en el territorio Peruano.

También se hizo la recolección de palabras positivas y negativas para crear un diccionario léxico, cada palabra del diccionario permite enseñar a los comentarios de Tweet, por esta razón; se utilizó las palabras de National Research Council (NRC) Word-Emotion Association Lexicon (Mohammad, 2013), Mining and Summarizing Customer Reviews (Hu & Liu, 2004) y la colección de palabras de Chen Yanqing (Chen & Skiena, 2014), luego se realizó la unión de los tres conjuntos de palabras logrando obtener 8989 palabras, donde 3382 son positivos y 5607 negativos en idioma Español. La unión de estas palabras en el presente trabajo le denominamos Diccionario Léxico de Emociones en Español (DLEE).

3.2. Etapa 2: pre-procesamiento

Los Tweets extraídos tienen las siguientes características: texto, caracteres alfanuméricos, espacios en blanco, emoticón, palabras mayúsculas y minúsculas. Para encontrar una mejor clasificación y generar conocimientos de este Tweet debe ser pre-procesada antes de iniciar la selección de características. Las consideraciones empleadas para limpiar los Tweet fueron la eliminación de: registros duplicados, urls, números, espacios en blanco, caracteres especiales, punto, palabras pequeñas hasta 3 caracteres y convertir mayúscula a minúscula.

3.3. Etapa 3: extracción y selección de características

En la investigación se crea la Bolsa de palabras, Frecuencia de Términos y la conversión del Documento a Vector para extraer las características de los Tweets.

Sentimiento según DLEE: antes de realizar el entrenamiento del modelo, se debe enseñar el sentimiento si un Tweet es positivo o negativo, para este proceso se utilizó el DLEE según las palabras y su nivel de frecuencia en el Tweet.

Nº	Tweet	Polaridad	Frecuencia Relativa
1	#CuarentenaTotal día 1. Dormí la mitad del día y la otra mitad pensé en dormir. Llevo bien el aislamiento	Negativo	0.182
		Negativo	0.091
		Positivo	0.091
2	Día 7: que hago, me estoy volviendo loco	Negativo	0.2
3	#YoMeQuedoEnCasa ustedes igual https://t.co/zvMvVc6tak	Positivo	0.5

Tabla 1 – Ejemplo de Tweets con sentimiento según DLEE

La Tabla 1 representa 3 Tweets con Sentimientos y Frecuencias Relativas utilizando el DLEE, para seleccionar el sentimiento correcto en caso un Tweet tenga de 2 a más sentimientos (ver Tweet 1 de la Tabla 1) se considera el valor más alto de la Frecuencia Relativa, porque representa la frecuencia de apariciones de palabras negativas o positivas que contiene cada Tweet. Luego se realiza el filtro de Frecuencias Relativas mayor o igual a 0.15 para ser considerados en el conjunto de datos para el modelo de entrenamiento.

Bolsa de palabras: la bolsa contiene las apariciones de palabras en cada Tweet, se considera como medida cuantitativa para luego convertir cada documento de texto en formato de vector.

Nº	Tweet	Bolsa
1	#YoMeQuedoEnCasa #Día1: Hogar dulce hogar. Día 7: Ya no es tan dulce, se me acabó el azúcar.	hogar
		dulce
		tan
		acabó
		azúcar

Tabla 2 – Ejemplo de bolsa de palabras de un Tweet

Nº	Tweet	división	leche	familiar	hogar	dulce	tan	acabó	azúcar
1	#YoMeQuedoEnCasa #Día1: Hogar dulce hogar. Día 7: Ya no es tan dulce, se me acabó el azúcar.	0	0	0	1	1	1	1	1
2	#Día6: división familiar por el dulce de leche.	1	1	1	0	1	0	0	0

Tabla 3 – Ejemplo de la bolsa de palabras en vector

Luego de obtener la bolsa de palabras de todos los Tweets analizados, se determinó la Frecuencia de Términos de cada palabra, esto permitió hacer una análisis y determinar las palabras más frecuentes que se mencionan a continuación: *perdón, me gusta,*

nuevo, superado, aislamiento, soporta, extraño, aprendí y tranquilidad. La Tabla 2 muestra un Tweet con 5 términos que forma parte de la bolsa de palabras, la Tabla 3 es la representación de la bolsa de palabras en formato vector y esto se realiza para cada Tweet, donde al vector se asigna el valor 1 *si contiene la palabra* caso contrario se asigna el valor 0, este proceso se realizó para cada uno de los Tweets.

3.4.Etapa 4: aplicación del clasificador

Luego de realizar la extracción de características del conjunto de datos, se realiza el entrenamiento y prueba del modelo. Para la aplicación se utilizaron los algoritmos clasificadores Support Vector Machine (SVM), Decision Tree, Logistic Regression, Random Forest y Naive Bayes implementados en lenguaje R, Python y Software Knime Analytics. La cantidad de Tweets utilizados para la creación del modelo fue de 1000 segmentado de la siguiente manera: 630 comentarios positivos y 370 comentarios negativos, los comentarios positivos y negativos fueron obtenidos a partir de la aplicación del DLEE. Para la ejecución del modelo se utilizó 80% de los datos para el entrenamiento y 20% para la prueba.

3.5.Etapa 5: clasificador léxico de palabras

En esta sección es la parte de le evaluación 2 (propuesta) consiste en mejorar la precisión (Accuracy) del mejor algoritmo clasificador de la etapa 4: aplicación del clasificador o evaluación 1. Se implementó un Clasificador Léxico con mínimo de 3 palabras juntas, también generamos un nuevo Diccionario Léxico de Emociones en Español 3 abreviado (DLEE3) que consta de 3 palabras fusionadas con emociones positivas y negativas, luego estas palabras fueron convertidas en vector para asignar los valores binarios de pertenencia.

N°	Tweet	Nueva Bolsa
1	#YoMeQuedoEnCasa #Día1: Hogar dulce hogar. Día 7: Ya no es tan dulce, se me acabó el azúcar.	hogar dulce tan acabó azúcar

Tabla 4 – Ejemplo de nueva bolsa de 3 palabras juntas

```
1: función asignar_pertenencia ():
2: palabras_eval1 = [ ] // vector de bolsa de palabras de evaluación 1
3: comentario_eval1 = [ ] // comentarios de evaluación 1 (vector binario)
4: palabras_eval2 = [ ] // vector de bolsa de palabras para evaluación 2
5: comentario_eval2 = [ ] // comentarios para evaluación 2 (vector binario)
6: para i <- o hasta cantidad (palabras_eval1):
7: palabras_eval2[i] = concatenar (palabras_eval1[i],palabras_eval1[i+1],palabras_eval1[i+2])
8: comentario_eval2[i]=comentario_eval1[i+1]+comentario_eval1[i+2]+comentario_eval1[i+3]
9: para k <- o hasta cantidad (palabras_eval2):
10: si (comentario_eval2[i] >= 2) entonces
11: vector_palabras_nuevas[k] = 1
12: caso contrario
13: vector_palabras_nuevas[k] = 0
14: fin función
```

Figura 2 – Función de asignación de polaridad a nueva bolsa de palabras

La Figura 2 forma parte del algoritmo Clasificador Léxico de Palabras, en esta parte del algoritmo la función denominada *asignar_pertenencia()* cumple el proceso de concatenar como mínimo tres palabras juntas, en caso que solo queden un o dos palabras al final se considera una de ellas. Luego hacer una validación para asignar el valor 1 si contiene las palabras en DLEE3 caso contrario asignar el valor 0, este proceso es iterativo hasta validar todos los comentarios, la Tabla 5 muestra un ejemplo de las palabras asignadas con 1 y 0.

Nº	Tweet	división leche familiar	hogar dulce tan	Acabó azúcar
1	#YoMeQuedoEnCasa #Día1: Hogar dulce hogar. Día 7: Ya no es tan dulce, se me acabó el azúcar.	0	1	1
2	#Día6: división familiar por el dulce de leche.	1	0	0

Tabla 5 – Ejemplo de la bolsa de 3 palabras en vector

3.6.Etapa 6: aplicación del clasificador con el mejor algoritmo

Después de la etapa 4 o evaluación 1, en esta sección se debe aplicar el mejor algoritmo de clasificación según los resultados de la evaluación 1. Para esta evaluación 2 se aplica el mismo proceso de recolección de datos, pre-procesamiento, extracción y selección de características (ver Figura 1), también se utiliza el mismo conjunto de datos de Tweets con las siguientes cantidades: 1000 Tweets con 630 positivos y 370 negativos, estas servirán para el entrenamiento y prueba del modelo, realizando la siguiente segmentación 80% de datos para entrenamiento y 20% para pruebas (en la sección 4.2 se muestra el algoritmo utilizado como mejor clasificador).

4. Resultados de la experimentación

A continuación, se presenta los resultados de la experimentación.

4.1. Resultado evaluación 1

En esta sección evaluamos la precisión de los algoritmos clasificadores utilizando la Matriz de Confusión: verdad positiva, verdad negativo, falso positivo y falso negativo. Un Tweet se considera como verdadero positivo si se identifica correctamente como sentimiento positivo, y un Tweet es verdadero negativo si se clasifica correctamente como sentimiento negativo.

Nº	Clasificación-Clase	Positivo	Negativo
SVM	Positivo	114	13
	Negativo	18	55
Decision Tree	Positivo	115	12
	Negativo	29	44

Nº	Clasificación-Clase	Positivo	Negativo
Logistic Regression	Positivo	115	12
	Negativo	19	54
Random Forest	Positivo	122	5
	Negativo	40	33
Naive Bayes	Positivo	71	2
	Negativo	103	24

Tabla 6 – Matriz de confusión evaluación 1 (Knime Analytics)

La Tabla 6 muestra los resultados de los 5 algoritmos utilizados, se puede ver que clasificaron casi igual en los sentimientos positivos. Por otro lado, Support Vector Machine y Logistic Regresión clasificaron mejor en los comentarios negativos. Si buscamos más comentarios con palabras negativas hasta cumplir 140 caracteres o incluir emoticones en el Tweet esto podría mejorar la clasificación.

Precisión (Accuracy)			
Algoritmos	Knime Analytics	Lenguaje R	Lenguaje Python
SVM	84.50%	83.50%	85.25%
Decision Tree	79.50%	80.00%	82.00%
Logistic Regression	84.50%	65.55%	75.45%
Random Forest	77.50%	79.50%	80.50%
Naive Bayes	47.50%	50.35%	52.00%

Tabla 7 – Comparación de porcentaje de precisión evaluación 1

Por otro lado, la Tabla 7 representa la comparación de precisión de los algoritmos clasificadores utilizando en lenguaje R, Python y el software Knime Analytics, en todos los casos se utilizaron el mismo conjunto de datos de Tweet, y también de aplico el mismo procedimiento como se muestra en la Figura 1. Se observa quien tuvo mejor precisión en clasificar es el algoritmo Support Vector Machine utilizando el lenguaje Python y el software Knime Analytics con 85.25% y 84.5% respectivamente.

4.2.Resultado evaluación 2

En la evaluación 1 se puede ver que el algoritmo Support Vector Machine es quien clasificó mejor con 85.25% (Accuracy), por esta razón en la fase de clasificación de evaluación 2 (propuesta) se aplica el algoritmo SVM. En los resultados de la experimentación de SVM se puede ver una mejora de precisión alcanzado el 91.5% de clasificación de los sentimientos. La Tabla 8 muestra la cantidad de clasificación de positivos y negativos de SVM utilizando el Clasificador Léxico de Palabras.

Nº	Clasificación-Clase	Positivo	Negativo
SVM	Positivo	122	5
	Negativo	12	61

Tabla 8 – Matriz de confusión evaluación 2 con SVM

4.3. Resultados generales

Luego de preparar el texto, se realizó el cálculo de la frecuencia de palabras contenidas en los 200 000 tweets. La Figura 3 muestra las primeras 10 palabras más frecuentes relacionadas a la pandemia y cuarentena (aislamiento social) se obtuvo los siguientes resultados: *cuarentena* igual a 48 873, *covid* igual a 17 410, *casa* igual a 9782 y *coronavirus* igual a 8999 veces.




Figura 3 – Las 10 palabras más frecuentes



Figura 4 – Nube de palabras positivas y negativas en cuarentena

Asimismo, la Figura 4 son nubes de palabras más frecuentes entre positivas y negativas, estas frecuencias se logró por medio del Diccionario Léxico de Emociones en Español

(DLEE), el tamaño de cada texto (palabra) representa la frecuencia de aparición en los Tweets. La Figura 4 muestra las siguientes palabras positivas: Favor, Bien, Ganas, Mejor, Gracias y Aprendí son palabras recurrentes, mientras en palabras negativas son: Extraño, Aislamiento, Síntomas, Menos, Ansiedad, Solo, Emergencia, Carajo y Sin.

4.4. Discusión

A continuación, se muestra la discusión de la evaluación y resultados obtenidos.

Evaluación de precisión (Accuracy) de los algoritmos de clasificación: según la evaluación 1 los resultados se encuentran en la Tabla 7 y la mejor precisión es 85.25% con SVM utilizando Python, la segunda es 84.5% con SVM utilizando Knime Analytics, los algoritmos y herramientas utilizadas claramente demuestra que SVM tiene la mejor precisión, los análisis realizados tiene relación con el trabajo de Li (Li et al., 2020) para verificar la información situación de la pandemia Coronavirus, obteniendo el 65% de precisión con el algoritmo Random Forest, en tal sentido, el presente trabajo tiene una mejor precisión respecto al planteamiento de Li. Para mejorar la precisión de 85.25% de la evaluación 1, se empleó la evaluación 2 con SVM y aplicando el Clasificador Léxico de Palabras logrando el 91.5% de precisión, por esta razón se deduce que mediante clasificadores léxicos y algoritmos de clasificación permite mejorar la precisión de los sentimientos.

Diccionario Léxico de Emociones en Español (DLEE): como se pudo ver la propuesta de este diccionario tiene la unión de palabras de investigaciones (Mohammad, 2013) (Hu & Liu, 2004) (Chen & Skiena, 2014) logrando acumular 8989 palabras, el DLEE permitió mejorar la clasificación de sentimientos a diferencia de Zarrad (Zarrad et al., 2014) que solo utilizó 8222 palabras.

Palabras más frecuentes: la Figura 3 tiene las 10 palabras más frecuentes utilizados en los tweets relacionados al aislamiento social, las palabras son: cuarentena, covid, casa y hoy, estas palabras se asocian con seguir indicaciones del Gobierno de permanecer en casa, por ejemplo: “#cuarentena Día 10 hoy estoy en casa”, este tweet podría relacionar con: clases, ejercicios, cocinando, extraño, películas, trabajo remoto, cantar, bailar, solo, ansiedad, síntomas. A diferencia de los otros estudios, en el presente trabajo de investigación se hizo más énfasis en las emociones o sentimientos que han expresado en el tiempo de aislamiento social permaneciendo en casa.

Palabras positivas y negativas: por las nubes de palabras positivas y negativas de la Figura 4 se observa que la mayoría de personas utilizan el verbo *Extrañar*, significa que extrañan las actividades que realizaban antes de iniciar el aislamiento social, pero en el lado positivo vemos que las personas envían mensajes amables utilizando las palabras *Bien*, *Ganas*, *Mejor* y *Gracias*, significa que están tranquilos en casa y mencionando que se cuiden mucho y que se debe seguir las recomendaciones del Gobierno.

5. Conclusiones

Con los resultados obtenidos en la presente investigación, se indica la necesidad de publicar información referente al aislamiento social, dicha información debe estar relacionada con las palabras positivas o negativas encontradas en esta investigación,

también se debe buscar entretener mediante radio, televisión o internet con actividades que más comentaron como: canto, baile, ejercicios, cocina y clases virtuales. Además, los resultados de comentarios positivos, negativo y el modelo predictivo serán útiles para investigadores o profesionales que tenga como objetivo contribuir en futuras emergencias para evitar que las personas salgan de casa.

Asimismo, se concluye que el Clasificador Léxico de Palabras y el DLEE3 ayudó al algoritmo de clasificación SVM a mejorar la precisión hasta un 91.5%, si evaluamos con más datos podría mejorar la clasificación. Por otro lado, según las evaluaciones 1 y 2 manifiestan que el algoritmo SVM utilizando Python y Knime Analytics tiene mejor clasificación para datos de sentimientos, así mismo al utilizar análisis léxico permite entender mejor el contexto de las frases. Como trabajo futuro se va mejorar el Clasificador Léxico de Palabras para unir más de 3 palabras y entender mejor el contexto del sentimiento utilizando redes neuronales, también se pretende analizar y predecir los Tweets que mencionen a medicamentos o remedios que permitieron recuperarse de este tipo de enfermedades u otras.

Referencias

- Amira, F., Hamzah, B., Lau, C. H., Nazri, H., Ligot, D. V., Lee, G., ... Sdn, D. (2020). CoronaTracker : World-wide COVID-19 Outbreak Data Analysis and Prediction CoronaTracker : World-wide COVID-19 Outbreak Data Analysis and Prediction. *Worl Health Organization*, (March). <https://doi.org/http://dx.doi.org/10.2471/BLT.20.255695>
- Beryl Joylin, A., Aswathi, T., Suma, P., & Victor, N. (2016). Sentiment analysis on “ebola” outbreak using twitter data. *International Journal of Pharmacy and Technology*, 8(4), 25835–25842. Retrieved from <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85018212351&partnerID=40&md5=8f598f4c4cafo42825a1586a8675e400>
- Bobicev, V., Sokolova, M., Jafer, Y., & Schramm, D. (2012). Learning sentiments from tweets with personal health information. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 7310 LNAI, 37–48. https://doi.org/10.1007/978-3-642-30353-1_4
- Chen, Y., & Skiena, S. (2014). Building sentiment lexicons for all major languages. *52nd Annual Meeting of the Association for Computational Linguistics, ACL 2014 - Proceedings of the Conference*, 2, 383–389. <https://doi.org/10.3115/v1/p14-2063>
- Dong, E. (2020). Coronavirus COVID-19 Global Cases by the Center for Systems Science and Engineering (CSSE) - Map. Retrieved from The Lancet. Infectious diseases website: <https://gisanddata.maps.arcgis.com/apps/opsdashboard/index.html#/bda7594740fd40299423467b48e9ecf6>
- Dong, E., Du, H., & Gardner, L. (2020). An interactive web-based dashboard to track COVID-19 in real time. *The Lancet. Infectious Diseases*, 3099(20), 19–20. [https://doi.org/10.1016/S1473-3099\(20\)30120-1](https://doi.org/10.1016/S1473-3099(20)30120-1)

- Hu, M., & Liu, B. (2004). Mining and Summarizing Customer Reviews. *Proceedings of the Tenth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 168–177. <https://doi.org/10.1145/1014052.1014073>
- Karamibekr, M., & Ghorbani, A. A. (2012). Verb oriented sentiment classification. *Proceedings - 2012 IEEE/WIC/ACM International Conference on Web Intelligence, WI 2012*, 327–331. <https://doi.org/10.1109/WI-IAT.2012.122>
- Kristanto, S. P., Prasetyo, J. A., & Pramana, E. (2019). Naive Bayes Classifier on Twitter Sentiment Analysis BPJS of HEALTH. *Proceedings - 2019 2nd International Conference of Computer and Informatics Engineering: Artificial Intelligence Roles in Industrial Revolution 4.0, IC2IE 2019*, 24–28. <https://doi.org/10.1109/IC2IE47452.2019.8940900>
- Li, L., Zhang, Q., Wang, X., Zhang, J., Wang, T., Gao, T.-L., ... Wang, F.-Y. (2020). Characterizing the Propagation of Situational Information in Social Media During COVID-19 Epidemic: A Case Study on Weibo. *IEEE Transactions on Computational Social Systems*, 7(2), 1–7. <https://doi.org/10.1109/TCSS.2020.2980007>
- Lopez, C. E., Vasu, M., & Gallemore, C. (2020). *Understanding the perception of COVID-19 policies by mining a multilanguage Twitter dataset*. 1–4.
- Mohammad, S. M. (2013). Sentiment and Emotion Lexicons. Retrieved from National Research Council Canada website: <http://saifmohammad.com/WebPages/lexicons.html>
- Organization, W. H. (2020a). Pneumonia of unknown cause China. Retrieved from Emergencies preparedness, response, Disease outbreak new website: <https://www.who.int/csr/don/05-january-2020-pneumonia-of-unkown-cause-china/en/>
- Organization, W. H. (2020b). Preguntas y respuestas sobre la enfermedad por coronavirus (COVID-19). Retrieved April 1, 2020, from Emergencias Sanitarias, Enfermedades, Nuevo coronavirus 2019 website: <https://www.who.int/es/emergencies/diseases/novel-coronavirus-2019/advice-for-public/q-a-coronaviruses>
- Sharma, S., & Mangat, V. (2016). Relevance vector machine classification for big data on Ebola outbreak. *Proceedings on 2015 1st International Conference on Next Generation Computing Technologies, NGCT 2015*, (September), 639–643. <https://doi.org/10.1109/NGCT.2015.7375199>
- Tran, T., & Lee, K. (2016). Understanding citizen reactions and Ebola-related information propagation on social media. *Proceedings of the 2016 IEEE/ACM International Conference on Advances in Social Networks Analysis and Mining, ASONAM 2016*, 106–111. <https://doi.org/10.1109/ASONAM.2016.7752221>
- Wu, J. T., Leung, K., & Leung, G. M. (2020). Nowcasting and forecasting the potential domestic and international spread of the 2019-nCoV outbreak originating in Wuhan, China: a modelling study. *The Lancet*, 395(10225), 689–697. [https://doi.org/10.1016/S0140-6736\(20\)30260-9](https://doi.org/10.1016/S0140-6736(20)30260-9)

- Xu, K., Wang, F., Jia, X., & Wang, H. (2016). *The Impact of Sampling on Big Data Analysis of Social Media: A Case Study on Flu and Ebola*. 1–6. <https://doi.org/10.1109/glocom.2015.7416974>
- Zarrad, A., Jaloud, A., & Alsmadi, I. (2014). The Evaluation of the Public Opinion - A Case Study: MERS-CoV Infection Virus in KSA. *2014 IEEE/ACM 7th International Conference on Utility and Cloud Computing*, 664–670. <https://doi.org/10.1109/UCC.2014.107>

© 2021. This work is published under
<https://creativecommons.org/licenses/by-nc-nd/4.0>(the
“License”). Notwithstanding the ProQuest Terms and
Conditions, you may use this content in accordance with the
terms of the License.