



INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO
ESCOM

Trabajo Terminal

**Plataforma Web para la Denuncia Segura y Prevención de Riesgos
Digitales**

2026-B009

Presentan

Edgar Jair Flores Espinosa

Jose Bryan Omar Jimenez Velazquez

Leilani Shareni Santos Rivera

Directores

M. en C. Ulises Velez Saldaña

Dr. Jessie Paulina Guzmán Flores

Índice General

Glosario	VI
1. Introducción	1
2. Análisis del problema	2
2.1. Problema General	2
2.2. Problemas específicos	2
2.3. Causas	2
2.4. Solución	2
3. Estado del Arte	3
3.1. Plataformas Gubernamentales	4
3.1.1. Sistema Integral de Denuncias Ciudadanas (SIDECA)	4
3.1.2. Denuncia Digital y Sistemas Estatales	5
3.1.3. Servicios de Procuración Digital: MP Virtual y Denuncia Anónima	6
3.2. Aplicaciones Móviles y Plataformas Ciudadanas	6
3.2.1. Aplicaciones de Denuncia Georreferenciada	6
3.3. Plataformas Internacionales	7
3.3.1. Whistlelink	7
3.3.2. EQS Integrity Line	8
3.3.3. NAVEX / WhistleB	8
3.3.4. Whistleblower Software	8
3.4. Plataformas Académicas e Institucionales	9
3.4.1. BullyButton	9
3.4.2. Ventanilla Escolar	9
3.4.3. Alerta IPN	9
3.4.4. UNAM - Denuncia Línea	10
3.5. Análisis Comparativo de Plataformas	10

4. Marco Teórico	12
4.1. Problema de clasificación en el contexto de la DDP	12
4.1.1. Taxonomía de denuncias	13
4.1.2. Clasificación binaria y lógica de admisión	14
4.1.3. Ciclo de vida de los datos en el aprendizaje supervisado	15
5. Marco Teórico	17
5.1. Problema de clasificación en el contexto de la DDP	17
5.1.1. Taxonomía de denuncias	18
5.1.2. Clasificación binaria y lógica de admisión	19
5.1.3. Ciclo de vida de los datos en el aprendizaje supervisado	20
5.2. Fundamentos de Procesamiento de Lenguaje Natural	21
5.2.1. Álgebra lineal en espacios vectoriales de alta dimensión	22
5.2.2. Preprocesamiento de la queja	23
5.3. Representación Vectorial del Texto	25
5.3.1. Modelos de Bolsa de Palabras y TF-IDF	25
5.3.2. Word Embeddings Estáticos — spaCy (es_core_news_lg)	26
5.3.3. Sentence Transformers — SBERT (paraphrase-multilingual-mpnet-base-v2)	26
5.4. Ingeniería de Características Híbridas	28
5.4.1. Codificación de variables normativas	28
5.4.2. Concatenación y Factor de Amplificación (α)	30
5.4.3. Simulación de producción: entrenamiento con metadatos e inferencia en modo autónomo	31
5.5. Modelos de Aprendizaje Automático Evaluados	31
5.5.1. Máquinas de Soporte Vectorial (SVM)	32
5.5.2. Regresión Logística	33
5.5.3. Ensamble de Árboles — Random Forest	33
5.5.4. Ensemble por Votación Suave	34
5.6. Estrategias de Entrenamiento y Validación Robusta	34
5.6.1. Validación Cruzada K -Fold Estratificada	35
5.6.2. Evaluación mediante Métricas de Inteligencia	35
5.6.3. Carga Perezosa y Serialización con joblib	37
6. Propuesta de proyecto	39
7. Trabajo Realizado	40
7.1. Interacción con el Cliente	40

7.2. Microservicio de Atención al Quejoso	41
7.2.1. Backend del Microservicio	41
7.2.2. Frontend del Quejoso	42
7.3. Modelo y Desarrollo del Clasificador	42
7.3.1. Corpus y Protocolo de Evaluación	42
7.3.2. Ingeniería de Características y Arquitectura del <i>Pipeline</i>	43
7.3.3. Selección del Modelo de Producción	43
8. Resultados Obtenidos	44

Índice de figuras

Índice de tablas

3.1. Comparativa de capacidades tecnológicas identificadas	10
5.1. Features jurídicos estructurados derivados del Artículo 4º.	29

Glosario

Acuerdo de Conclusión: Documento final que cierra el expediente, pudiendo resultar en una recomendación, un cese de actos o un pronunciamiento de improcedencia.

Acuse de Recibo: Comprobante digital generado por el sistema que confirma que la DDP ha recibido la solicitud, otorgando un folio único de seguimiento.

Análisis de Patrones: Uso de algoritmos para identificar comportamientos repetitivos o anomalías (como focos de corrupción) dentro de grandes volúmenes de datos.

Análisis Bidimensional: Evaluación de datos cruzando dos variables distintas (ej. tipo de queja vs. ubicación geográfica) para obtener información estratégica.

Anonimato Bidireccional: Capacidad de un sistema para permitir la comunicación entre denunciante e investigador sin que ninguna de las partes conozca la identidad real de la otra.

API REST: Interfaz de programación de aplicaciones que utiliza peticiones HTTP para transferir datos entre componentes de software.

Arquitectura de Cero Conocimiento (Zero-Knowledge): Diseño de seguridad donde el servidor no tiene acceso a las llaves de cifrado del usuario, siendo incapaz de ver los datos almacenados.

Arquitectura de Microservicios: Estilo arquitectónico que estructura una aplicación como un conjunto de servicios pequeños, autónomos y acoplados de forma mínima.

Arquitectura Monolítica: Modelo de software donde todos los componentes del sistema están entrelazados en un solo programa, dificultando su escalabilidad.

AUC-ROC: Curva que mide la capacidad del modelo para distinguir entre clases; un área cercana a 1 indica un desempeño óptimo en la clasificación.

Autenticación Robusta: Proceso de validación de identidad que utiliza credenciales institucionales verificables (Boleta o Número de Empleado).

Autonomía Técnica: Capacidad de la DDP para emitir criterios y recomendaciones de forma independiente, sin influencia de otras autoridades.

Big Data: Conjuntos de datos tan grandes y complejos que requieren aplicaciones informáticas no tradicionales para su procesamiento.

Bolsa de Palabras (BoW): Técnica de representación de texto basada en la frecuencia de aparición de cada palabra, sin considerar el orden gramatical.

Caducidad / Rezago Administrativo: Situación que ocurre cuando un trámite no se realiza dentro de los plazos legales, afectando la eficiencia institucional.

Catálogo de Derechos Vulnerados: Listado estructurado de los derechos establecidos en la Ley Orgánica que sirve de base para la clasificación mediante PLN.

Cifrado de Extremo a Extremo (E2EE): Sistema de comunicación donde solo los usuarios finales pueden leer los mensajes, protegiendo la información de intermediarios.

Clasificador Neuro-simbólico: Enfoque de IA que combina redes neuronales (para aprendizaje) con lógica basada en reglas (para razonamiento).

Comunidad Politécnica: Conjunto de estudiantes, docentes, personal administrativo y egresados del IPN.

Competencia: Facultad o atribución legal que tiene un órgano (DDP) para conocer y resolver un asunto específico basado en su normativa.

Crowdsourcing: Modelo de obtención de servicios o ideas mediante la colaboración abierta de una comunidad o grupo de personas.

DDP (Defensoría de los Derechos Politécnicos): Órgano encargado de velar por los derechos de la comunidad del IPN.

Debido Proceso: Conjunto de formalidades esenciales que deben observarse en cualquier procedimiento legal para asegurar un resultado justo.

Disponibilidad: Capacidad de un sistema de permanecer operativo y accesible durante un periodo de tiempo determinado.

Escalabilidad: Propiedad de un sistema para manejar una cantidad creciente de trabajo o su potencial para ser ampliado.

Estado del Arte: Análisis de los conocimientos, tecnologías y soluciones más avanzados que existen actualmente sobre un tema de investigación.

Expediente Digital: Repositorio electrónico que centraliza documentación, evidencias multimedia y actuaciones jurídicas de un caso.

F1-Score: Métrica reina que representa el promedio balanceado entre Precisión y Recall, útil para evaluar la calidad global del modelo.

Flujo Operativo: Secuencia estandarizada de etapas por las que debe pasar una queja, desde su recepción hasta su archivo definitivo.

Georreferenciación / Geolocalización: Técnica que permite asignar una ubicación geográfica exacta (coordenadas) a un reporte o evento.

Grid Search: Búsqueda exhaustiva para encontrar los mejores hiperparámetros de un modelo probando todas las combinaciones posibles.

GRC (Governance, Risk, and Compliance): Estrategia para gestionar el gobierno corporativo, los riesgos y el cumplimiento legal de una organización.

Hiperplano: Frontera o muro matemático en un espacio multidimensional que separa las distintas clases (ej. quejas competentes de improcedentes).

Independencia Condicional: Supuesto del algoritmo Naive Bayes donde se asume que la presencia de una palabra no afecta a otra, simplificando el cálculo de probabilidades.

Infraestructura On-Premise: Modelo de despliegue donde los servidores y el software se encuentran físicamente dentro de las instalaciones de la institución.

Inferencia Bayesiana: Modelo estadístico de probabilidad que actualiza la estimación de un fenómeno a medida que se adquiere más evidencia.

Inmutabilidad de los Datos: Propiedad que asegura que la información registrada no puede ser alterada o borrada, garantizando la integridad del expediente.

Integridad Documental: Garantía de que los documentos que integran el expediente digital no han sido manipulados desde su carga original.

IPN (Instituto Politécnico Nacional): Institución pública mexicana de educación media superior, superior y posgrado.

Java Spring Boot: Framework diseñado para simplificar el desarrollo de aplicaciones Java basadas en microservicios.

Justicia Restaurativa: Enfoque de justicia centrado en reparar el daño causado a las víctimas, en lugar de solo castigar al infractor.

Ley Orgánica: Marco legal máximo que rige la estructura, fines y organización del Instituto Politécnico Nacional.

Manual de Organización / Procedimientos: Documentos normativos que definen las funciones y los pasos operativos internos de la Defensoría.

Margen: Distancia entre los vectores de soporte y el hiperplano; el sistema busca maximizar esta distancia para reducir errores de clasificación.

Matriz de Confusión: Tabla que permite visualizar el desempeño de un algoritmo, mostrando los aciertos y las confusiones (falsos positivos y negativos).

Máxima Verosimilitud (MLE): Método para estimar las probabilidades de un modelo basándose en la frecuencia de aparición de los datos en el entrenamiento.

Medidas de Protección: Acciones urgentes dictadas para salvaguardar la integridad de la persona quejosa durante la investigación.

Naive Bayes: Algoritmo probabilístico que clasifica quejas basándose en el contenido de sus palabras bajo un supuesto de independencia.

Oficio de Solicitud de Informe: Documento oficial para requerir a una autoridad que rinda su declaración sobre los hechos de una queja.

PLN / NLP (Procesamiento de Lenguaje Natural): Rama de la IA que permite a las máquinas entender, interpretar y manipular el lenguaje humano.

PostgreSQL: Sistema de gestión de bases de datos relacional orientado a objetos y de código abierto.

Precisión: Métrica que indica qué tan exacto es el sistema cuando clasifica una queja como positiva, evitando falsas alarmas.

Primer Contacto: Etapa inicial donde se recibe la solicitud y se realiza el filtrado preliminar de la queja.

Procedencia: Calificación de una solicitud que cumple con los requisitos legales para ser admitida y analizada de fondo.

Punto de Falla Único: Componente de un sistema que, en caso de fallar, provoca que todo el sistema deje de funcionar.

Quejoso: Persona que interpone una queja o denuncia por una presunta vulneración de sus derechos.

Radicación: Acto formal de registrar y asignar un número de expediente a una queja para iniciar su proceso legal.

RBAC (Role-Based Access Control): Método de control de acceso que restringe o permite funciones del sistema según el rol asignado al usuario.

Recall (Sensibilidad): Capacidad del sistema para detectar todos los casos positivos reales, asegurando que ninguna queja válida sea ignorada.

Reglas de Negocio: Políticas institucionales que el software debe ejecutar automáticamente para garantizar la validez del proceso.

SaaS (Software as a Service): Modelo de distribución de software donde los datos se alojan en servidores externos y se accede vía web.

Similitud de Coseno: Medida métrica utilizada para determinar qué tan parecidos son dos documentos de texto en un espacio vectorial.

SMOTE (Synthetic Minority Over-sampling Technique): Técnica de balanceo de datos que crea ejemplos sintéticos para clases minoritarias, permitiendo un aprendizaje parejo.

Soberanía de Datos: Principio que establece que los datos están sujetos a las leyes y control de la institución donde se generan.

Stemming y Lematización: Procesos lingüísticos para reducir palabras a su raíz o forma base (lema) para facilitar el análisis.

Suavizado de Laplace (α): Ajuste matemático que suma un valor pequeño a los conteos para evitar probabilidades de cero en palabras no vistas previamente.

SVM (Support Vector Machine): Algoritmo de aprendizaje supervisado que busca el hiperplano óptimo para clasificar datos en diferentes categorías.

Términos Procesales / Plazos Legales: Lapsos de tiempo obligatorios otorgados por la normativa para realizar una acción jurídica.

- TF-IDF:** Técnica de pesaje que resalta palabras clave de un problema y resta importancia a palabras comunes o irrelevantes.
- TLS (Transport Layer Security):** Protocolo criptográfico que proporciona comunicaciones seguras por red, cifrando los datos en tránsito.
- Tokenización:** Proceso de fragmentar una cadena de texto en unidades más pequeñas llamadas tokens (palabras o símbolos).
- Trazabilidad:** Capacidad de seguir el historial, la aplicación y la ubicación de un expediente a través de todas sus etapas.
- Triaje Administrativo:** Proceso de selección y priorización de quejas basado en urgencia, competencia legal y gravedad.
- Truco del Kernel (Kernel Trick):** Técnica que proyecta datos a dimensiones superiores para encontrar una separación lineal donde antes no era posible.
- Validación Cruzada (K-Fold):** Método de evaluación que divide los datos en K partes para asegurar que el sistema sea robusto con diferentes subconjuntos de datos.
- Variables de Holgura (ξ):** Parámetro de flexibilidad en un modelo SVM que permite que algunos puntos crucen la frontera para manejar datos con ruido.
- Vectores de Soporte:** Puntos o quejas que se encuentran más cerca de la frontera de decisión y definen la posición del hiperplano.
- Ventana de Contexto:** Rango de palabras que el modelo analiza alrededor de un término objetivo para aprender su significado semántico.
- Whistleblowing:** Acto de denunciar internamente o ante las autoridades actividades ilegales o poco éticas dentro de una organización.
- Word Embeddings:** Representación de palabras como vectores en un espacio multidimensional donde la cercanía geométrica indica cercanía semántica.
- Word2Vec / GloVe:** Modelos específicos utilizados para generar embeddings basados en el contexto local o estadísticas globales del texto.

Capítulo 1

Introducción

Capítulo 2

Análisis del problema

2.1 Problema General

2.2 Problemas específicos

2.3 Causas

2.4 Solución

Capítulo 3

Estado del Arte

La transformación digital ha impulsado el desarrollo de plataformas orientadas a la gestión electrónica de denuncias, quejas y mecanismos de protección de derechos. En este contexto, las organizaciones gubernamentales, corporativas y académicas han incorporado sistemas digitales capaces de automatizar la recepción de reportes, el seguimiento de expedientes y la administración de evidencia electrónica.

Sin embargo, la evolución de estas plataformas no ha sido homogénea. Mientras algunos sistemas priorizan la validez jurídica y el cumplimiento normativo, otros se enfocan en la anonimización de datos, la movilidad, la trazabilidad o la integración de mecanismos de seguridad informática. Esto ha provocado que muchas soluciones resulten insuficientes para contextos institucionales, particularmente en entornos universitarios donde convergen aspectos administrativos, jurídicos, académicos y de protección de derechos humanos.

En el caso de la DPP, la necesidad de una plataforma implica considerar elementos que van más allá de un sistema de recepción de quejas/denuncias.

Asimismo, la creciente digitalización de los servicios institucionales ha evidenciado limitaciones importantes en los sistemas tradicionales centralizados, especialmente en aspectos relacionados con:

- La protección e integridad de la información.
- La automatización de procesos administrativos.
- La escalabilidad de la infraestructura tecnológica.
- La trazabilidad de expedientes digitales.

- La protección de la identidad del denunciante.

En este sentido, el presente capítulo analiza las principales plataformas nacionales e internacionales relacionadas con nuestra idea de propuesta, con el objetivo de identificar las capacidades tecnológicas existentes, las limitaciones arquitectónicas predominantes y las brechas funcionales que justifican el desarrollo de una solución especializada para el IPN.

Los criterios considerados permiten evaluar tanto aspectos funcionales como características arquitectónicas relacionadas con seguridad, escalabilidad y capacidad de adaptación institucional.

Los principales criterios de evaluación son los siguientes:

- **Escalabilidad Arquitectónica:** Capacidad del sistema para soportar crecimiento en usuarios, servicios y procesamiento sin degradar significativamente su rendimiento.
- **Seguridad y Confidencialidad:** Mecanismos implementados para proteger la información sensible, incluyendo cifrado, autenticación y control de acceso.
- **Trazabilidad y Seguimiento:** Nivel de visibilidad que posee el usuario sobre el estado y avance de su denuncia.
- **Automatización Administrativa:** Uso de tecnologías que permitan reducir procesos manuales mediante clasificación automática, reglas de negocio o asistencia inteligente.
- **Soporte Multimedia:** Capacidad de almacenar y gestionar evidencia digital como imágenes, audio, video y documentos.

A partir de estos criterios se desarrolló el análisis comparativo de las plataformas seleccionadas, permitiendo identificar las principales fortalezas, limitaciones y brechas tecnológicas existentes en el estado actual de las soluciones de denuncia digital.

3.1 Plataformas Gubernamentales

3.1.1 Sistema Integral de Denuncias Ciudadanas (SIDECA)

El Sistema Integral de Denuncias Ciudadanas (SIDECA) constituye una de las principales plataformas gubernamentales de recepción de quejas administrativas en México, centralizando denuncias relacionadas con servidores públicos federales [6].

Desde una perspectiva funcional, el sistema permite la recepción continua de denuncias mediante formularios electrónicos y proporciona mecanismos básicos de seguimiento mediante folios únicos y contraseñas de acceso [7]. Asimismo, incorpora soporte para evidencia multimedia, incluyendo documentos, audio y video.

No obstante, el análisis arquitectónico del SIDECE evidencia diversas limitaciones técnicas relevantes:

- La plataforma opera bajo un esquema predominantemente centralizado, lo que limita la flexibilidad de escalamiento y aumenta la dependencia de infraestructura única.
- El proceso de clasificación de denuncias depende en gran medida de la interpretación manual del usuario y del personal administrativo.
- Los mecanismos de seguimiento presentan visibilidad limitada para el denunciante, restringiéndose a estados generales de avance.
- No se identifican componentes avanzados de análisis automatizado, inteligencia artificial o mecanismos predictivos para detección de patrones.

3.1.2 Denuncia Digital y Sistemas Estatales

A nivel estatal, diversas entidades federativas han incorporado plataformas digitales orientadas a la recepción de denuncias y querellas. Entre los casos más representativos se encuentra el sistema **Denuncia Digital** implementado por la Ciudad de México [9].

Esta plataforma permite iniciar procedimientos relacionados con delitos no violentos mediante autenticación electrónica utilizando mecanismos como la *Llave CDMX* o firma electrónica gubernamental. Su principal aportación radica en la digitalización parcial del inicio de carpetas de investigación.

El análisis comparativo entre entidades federativas muestra una importante fragmentación tecnológica:

- **Estados con digitalización avanzada:** Algunas entidades permiten videodenuncias, ratificación remota y gestión electrónica relativamente completa.
- **Modelos híbridos:** Otros estados únicamente permiten la captura preliminar de datos, requiriendo posteriormente comparecencia presencial.
- **Entidades con rezago tecnológico:** Persisten instituciones que carecen de plataformas especializadas y dependen de canales telefónicos o buzones físicos.

3.1.3 Servicios de Procuración Digital: MP Virtual y Denuncia Anónima

La Fiscalía General de Justicia de la Ciudad de México ha incorporado servicios digitales complementarios como el **MP Virtual** y el sistema de **Denuncia Anónima** [11].

El módulo MP Virtual permite formalizar determinados procedimientos jurídicos de manera remota, facilitando la validación documental y reduciendo la necesidad de comparecencia inmediata [12].

Por otra parte, el sistema de denuncia anónima implementa mecanismos básicos de protección de identidad para reportes relacionados con delitos de alto impacto.

Desde el punto de vista tecnológico, estas plataformas representan avances relevantes en términos de accesibilidad y digitalización de trámites; sin embargo, continúan dependiendo de infraestructuras centralizadas y modelos tradicionales de administración de servicios.

Además, no se identifican mecanismos avanzados relacionados con:

- Arquitecturas desacopladas.
- Procesamiento inteligente de denuncias.
- Modelos avanzados de anonimización.
- Analítica de comportamiento o patrones administrativos.

3.2 Aplicaciones Móviles y Plataformas Ciudadanas

3.2.1 Aplicaciones de Denuncia Georreferenciada

La evolución de los servicios digitales ha impulsado el desarrollo de aplicaciones móviles orientadas a la denuncia ciudadana y la participación colaborativa.

Uno de los referentes más representativos es la aplicación **Incorruptible**, diseñada para registrar actos de corrupción mediante mecanismos de geolocalización y participación ciudadana [13].

Entre las principales funcionalidades identificadas destacan:

- Registro georreferenciado de incidentes.
- Publicación colaborativa de reportes.

- Integración de evidencia multimedia.
- Cuantificación económica de daños reportados.

De forma complementaria, el **Sistema de Atención Mexiquense (SAM)** integra servicios web, móviles y telefónicos para canalizar denuncias hacia distintas dependencias administrativas [14].

A pesar de su flexibilidad operativa y facilidad de acceso, este tipo de aplicaciones presentan limitaciones relevantes en contextos institucionales formales:

- Ausencia de mecanismos robustos de validación institucional.
- Escasa trazabilidad jurídica.
- Limitada integración con procesos administrativos especializados.
- Riesgos asociados a exposición pública de información sensible.

Estas limitaciones dificultan su adaptación directa a entornos universitarios donde la protección de datos personales y la formalización administrativa son elementos críticos.

3.3 Plataformas Internacionales

El mercado internacional de plataformas de denuncia y cumplimiento normativo ha desarrollado soluciones avanzadas enfocadas principalmente en sectores corporativos y regulatorios.

Estas plataformas destacan por incorporar mecanismos avanzados de seguridad, anonimización y administración de casos, aunque frecuentemente presentan limitaciones relacionadas con costos, complejidad de implementación y adaptación a marcos institucionales específicos.

3.3.1 Whistlelink

Whistlelink es una plataforma orientada a la gestión anónima de denuncias corporativas, destacando por su soporte multilingüe y canales bidireccionales de comunicación anónima [15].

Su principal ventaja radica en la reducción de barreras de acceso para denunciantes internacionales; sin embargo, presenta limitaciones relacionadas con personalización institucional avanzada y adaptación a flujos administrativos complejos.

3.3.2 EQS Integrity Line

EQS Integrity Line constituye una de las soluciones corporativas más robustas del mercado europeo, diseñada para cumplir con normativas internacionales de protección al denunciante [16].

La plataforma incorpora herramientas avanzadas de administración de casos, generación de reportes y monitoreo organizacional.

No obstante, su complejidad operativa y elevada carga administrativa pueden dificultar su implementación en entornos educativos o instituciones públicas con recursos limitados.

3.3.3 NAVEX / WhistleB

NAVEX y su solución WhistleB utilizan infraestructura en la nube para garantizar alta disponibilidad y escalabilidad [17].

Entre sus fortalezas destacan:

- Integración con plataformas GRC.
- Infraestructura escalable.
- Gestión centralizada de cumplimiento.

Sin embargo, la dependencia de proveedores externos de nube puede representar restricciones relacionadas con soberanía de datos y políticas institucionales gubernamentales.

3.3.4 Whistleblower Software

Whistleblower Software destaca por implementar mecanismos avanzados de cifrado y modelos de arquitectura Zero-Knowledge [18].

Este enfoque fortalece significativamente la confidencialidad de la información y la protección del denunciante.

A pesar de ello, su orientación principal hacia entornos corporativos limita su adecuación directa a estructuras administrativas universitarias de gran escala.

3.4 Plataformas Académicas e Institucionales

3.4.1 BullyButton

BullyButton es una plataforma enfocada en la detección y reporte de casos de acoso escolar [21].

Su diseño prioriza la simplicidad operativa y la facilidad de uso para estudiantes; sin embargo, carece de mecanismos formales de trazabilidad jurídica y administración avanzada de expedientes.

3.4.2 Ventanilla Escolar

Ventanilla Escolar funciona como un canal de orientación y comunicación entre instituciones educativas y autoridades federales [22].

Aunque centraliza información relevante para usuarios educativos, no incorpora funcionalidades completas para seguimiento de denuncias ni administración formal de casos.

3.4.3 Alerta IPN

Alerta IPN constituye uno de los principales mecanismos institucionales de reporte dentro del Instituto Politécnico Nacional [23].

Su funcionalidad se orienta principalmente a reportes de emergencia y situaciones de riesgo dentro de instalaciones institucionales.

No obstante, la plataforma no contempla procesos relacionados con:

- Gestión jurídica de expedientes.
- Clasificación administrativa automatizada.
- Seguimiento integral de casos.
- Protección avanzada de identidad.

3.4.4 UNAM - Denuncia Línea

La plataforma Denuncia Línea de la UNAM representa uno de los referentes más relevantes en gestión universitaria de denuncias en México [24].

Su principal fortaleza radica en la existencia de protocolos institucionales consolidados y procedimientos administrativos claramente definidos.

Sin embargo, el análisis tecnológico evidencia limitaciones relacionadas con:

- Escalabilidad arquitectónica.
- Integración de inteligencia artificial.
- Automatización de triaje.
- Modularidad de servicios.

3.5 Análisis Comparativo de Plataformas

Con base en los criterios de evaluación previamente definidos, se realizó una síntesis comparativa de las principales capacidades tecnológicas identificadas en las plataformas analizadas.

La evaluación presentada considera exclusivamente funcionalidades documentadas oficialmente o identificadas durante el análisis técnico de cada sistema.

Característica	Fed.	Loc.	Int.	Móv.	Acad.	Propuesta
IA / NLP	Bajo	Bajo	Medio	Bajo	Bajo	Alto
Escalabilidad	Bajo	Bajo	Alto	Medio	Bajo	Alto
Anonimato	Medio	Medio	Alto	Bajo	Bajo	Alto
Geolocalización	Bajo	Bajo	Bajo	Alto	Bajo	Alto
Seguridad Avanzada	Bajo	Medio	Alto	Bajo	Bajo	Alto
Especialización Universitaria	Bajo	Bajo	Bajo	Bajo	Medio	Alto

Tabla 3.1: Comparativa de capacidades tecnológicas identificadas

El análisis comparativo evidencia que las plataformas existentes presentan capacidades parciales y altamente fragmentadas.

Las principales brechas tecnológicas identificadas son:

- Ausencia de integración entre seguridad avanzada y especialización universitaria.
- Dependencia predominante de arquitecturas centralizadas.
- Escasa incorporación de inteligencia artificial para clasificación automática de casos.
- Limitada interoperabilidad institucional.
- Deficiencias en mecanismos avanzados de trazabilidad y seguimiento.
- Carencia de modelos robustos de anonimización y protección de identidad adaptados a entornos académicos.

Asimismo, se identificó que ninguna de las plataformas estudiadas integra simultáneamente capacidades de automatización administrativa, protección avanzada de datos, escalabilidad modular y adaptación específica al contexto del Instituto Politécnico Nacional.

El análisis realizado demuestra que las plataformas actuales de denuncia digital han evolucionado significativamente en términos de digitalización administrativa y accesibilidad tecnológica. Sin embargo, la mayoría de las soluciones existentes continúan presentando limitaciones importantes relacionadas con escalabilidad, automatización inteligente, protección de identidad y adaptación institucional especializada.

Las plataformas gubernamentales priorizan el cumplimiento normativo y la formalización administrativa, aunque mantienen modelos tecnológicos rígidos y centralizados. Por otra parte, las soluciones internacionales incorporan mecanismos avanzados de seguridad y anonimización, pero presentan restricciones relacionadas con costos, complejidad operativa y adecuación al contexto jurídico mexicano.

En el ámbito académico, los sistemas existentes ofrecen mecanismos básicos de atención y reporte, aunque carecen de arquitecturas modernas orientadas a interoperabilidad, inteligencia artificial y trazabilidad avanzada de expedientes.

En consecuencia, se identifica una oportunidad tecnológica para el desarrollo de una plataforma especializada que integre capacidades modernas de seguridad, modularidad, automatización y gestión institucional, adaptadas específicamente a las necesidades operativas de la DDP

Capítulo 4

Marco Teórico

Con el fin de optimizar el flujo operativo dentro de la Defensoría de Derechos Politécnicos (DDP), se implementará un sistema de clasificación para determinar la competencia o incompetencia de una queja. Este sistema brindará apoyo directamente en la etapa de primer contacto; con ello se busca transformar el análisis normativo en un modelo computacional capaz de identificar la competencia de manera consistente y eficiente. Para lograrlo, el sistema se apoya en cuatro pilares conceptuales que se desarrollan en este capítulo: el marco legal que define el problema de clasificación, los fundamentos del Procesamiento de Lenguaje Natural que permiten interpretar la narrativa de las quejas, las técnicas de representación vectorial que traducen ese lenguaje en señales numéricas, y los modelos de aprendizaje automático que aprenden a distinguir entre quejas competentes e incompetentes.

4.1 Problema de clasificación en el contexto de la DDP

El problema central de este proyecto consiste en automatizar la decisión de admisibilidad de una queja ante la Defensoría de Derechos Politécnicos, decisión que actualmente depende del criterio manual del personal de primer contacto y genera inconsistencias operativas. Este problema parte del marco legal presentado en el Acuerdo publicado en la Gaceta Politécnica, Número Extraordinario 622, donde se establece a la DDP como el órgano encargado de promover, proteger y defender los derechos de la comunidad frente a actos u omisiones de las autoridades del Instituto. Por lo tanto, comprender los límites normativos de la competencia institucional es el primer paso para diseñar un clasificador que replique la lógica jurídica con precisión.

En el Artículo 3° del mismo Acuerdo se establece que la Defensoría es competente para conocer quejas relacionadas con presuntas violaciones a los derechos de la comunidad politécnica; sin embargo, el Artículo 4° delimita los márgenes en las materias en que la Defensoría **no** es competente:

1. Afectaciones de carácter colectivo.
2. Resoluciones disciplinarias.
3. Derechos de naturaleza laboral.
4. Evaluaciones académicas de profesores, comisiones dictaminadoras o consejos técnicos consultivos escolares, salvo que en dicha evaluación se violen notoriamente los derechos de los interesados.
5. Procedimientos y resoluciones instaurados por el Órgano Interno de Control en el Instituto.

El proceso de recepción de quejas descrito en el Artículo 13 establece que el personal de la Defensoría debe determinar en primera instancia si la queja es competente o incompetente. Esta decisión, aparentemente sencilla, presenta en la práctica alta ambigüedad derivada de la redacción de los hechos. Dicha dependencia del criterio manual genera tres conflictos críticos:

1. El consumo excesivo de tiempo administrativo.
2. La variabilidad de interpretaciones ante casos similares.
3. La saturación operativa debida al incremento constante de solicitudes.

En consecuencia, el problema se define como una tarea de *Procesamiento de Lenguaje Natural* (PLN) y *clasificación supervisada*, donde el sistema debe aprender a identificar los patrones lingüísticos y normativos que separan una queja competente de una incompetente.

4.1.1 Taxonomía de denuncias

Las denuncias recibidas por la DDP no se clasifican únicamente por su contenido textual, sino por una estructura jerárquica de validación normativa que el sistema debe aprender a reconocer; por ello, establecer una taxonomía clara es condición previa para construir cualquier modelo de clasificación. Transformar una narrativa jurídica en un conjunto de datos procesable por algoritmos de aprendizaje automático requiere organizar el conocimiento normativo de forma sistemática. En el contexto de la Defensoría, esta taxonomía se apoya en dos reglas críticas:

1. **Pertenencia a la comunidad y jerarquía.** Define si las personas involucradas pertenecen a la comunidad politécnica. El sistema deberá identificar la existencia de un quejoso con su estatus institucional y la autoridad a quien se imputa la violación. Sin esta validación de identidad, la queja carece de base para ser procesada.
2. **Exclusiones del Artículo 4°.** Constituye el núcleo del clasificador. Las denuncias se categorizan según la presencia de los cinco criterios de exclusión mencionados anteriormente. Esta regla se traduce en el sistema como siete campos binarios —características estructuradas— que procesan el análisis normativo:
 - Naturaleza laboral vs. derechos politécnicos.
 - Evaluación académica pura vs. vulneración de derechos en evaluación.
 - Afectación individual vs. colectiva.
 - Resolución disciplinaria vs. acto de autoridad.
 - Procedimientos del OIC vs. acto u omisión de autoridad institucional.

Esta estructuración permite que el problema de clasificación no dependa únicamente del texto libre, sino de reglas establecidas en el Artículo 4°. Al final del proceso taxonómico, el sistema asigna a cada expediente una etiqueta binaria definitiva: *Competente* o *No Competente* (canalización a otra instancia o desechamiento), lo que constituye la variable de salida de los modelos de clasificación supervisada.

4.1.2 Clasificación binaria y lógica de admisión

Una vez definida la taxonomía normativa, el siguiente paso es determinar la forma en que el clasificador producirá su veredicto; este sistema adopta un esquema de **clasificación binaria**, decisión fundamentada directamente en el Artículo 13 del Acuerdo número extraordinario 622. A diferencia de otros sistemas de categorización temática —que discriminan entre dominios como deportes, política o finanzas— el clasificador de la DDP produce un veredicto dicotómico: *Competente* o *No Competente*. Esta simplificación a dos clases responde a la lógica de admisión procesal por tres razones fundamentales:

1. **Naturaleza del flujo administrativo.** Dentro de la DDP, el primer contacto actúa como una compuerta. No existe un estado intermedio: una queja o es admitida para su investigación, o

es desechada y canalizada a otra instancia. La clasificación binaria representa fielmente este proceso de toma de decisiones institucional.

2. **Optimización del entrenamiento.** Desde la perspectiva del aprendizaje automático, concentrar la muestra en dos etiquetas permite una mayor densidad de datos por categoría. Dado que el volumen de expedientes históricos etiquetados es finito, un modelo binario es más robusto y menos propenso al error que un modelo multiclase que intentara identificar simultáneamente el tipo específico de exclusión: laboral, académica o disciplinaria.
3. **Reducción del falso negativo.** La lógica de admisión prioriza la protección de los derechos de la comunidad. Al configurar el problema como binario, es posible ajustar el umbral de decisión del modelo —especialmente en algoritmos como SVM— para minimizar los falsos negativos, asegurando que ninguna queja potencialmente competente sea descartada por una clasificación errónea.

Por lo tanto, si el modelo predice la clase *No Competente*, el sistema asiste al personal sugiriendo la fundamentación legal basada en el Artículo 4°. Si la predicción es *Competente*, el expediente fluye automáticamente hacia la etapa de radicación en la Subdefensoría, logrando así la meta de reducir los tiempos de respuesta institucional.

4.1.3 Ciclo de vida de los datos en el aprendizaje supervisado

Para que la clasificación binaria opere de manera confiable, la narrativa jurídica del quejoso debe recorrer un flujo técnico que la transforme en una señal numérica apta para el aprendizaje automático; en consecuencia, el ciclo de vida de los datos estructura en seis etapas el puente entre el texto libre y la decisión del modelo. Este ciclo asegura la trazabilidad y la integridad de la información jurídica en cada una de sus fases:

1. **Captura de datos.** El ciclo inicia en la interfaz de registro donde el quejoso proporciona de forma estructurada su identidad institucional y, de forma no estructurada, el relato de los hechos. Esta etapa asegura que la entrada cumpla con los requisitos mínimos de admisión definidos en el Artículo 13.
2. **Preprocesamiento y limpieza.** La narrativa libre se somete a técnicas de PLN. Se eliminan elementos de ruido, se normaliza el texto y se identifican términos clave que corresponden a las exclusiones normativas del Artículo 4°.

3. **Vectorización y enriquecimiento.** El texto se convierte en representaciones vectoriales (*embeddings*). Simultáneamente, el sistema inyecta las características jurídicas binarias extraídas del expediente, aplicando el factor de amplificación α para dar peso a la señal normativa sobre la semántica.
4. **Entrenamiento y ajuste.** Utilizando un conjunto de datos histórico previamente etiquetado, el modelo aprende a identificar las fronteras de decisión legal. Se emplean técnicas de validación cruzada para medir la robustez de la generalización.
5. **Inferencia y sugerencia.** Ante una queja nueva, el modelo procesa los vectores y genera una predicción de competencia acompañada de un nivel de probabilidad. El sistema asiste al personal humano mostrando el veredicto sugerido y la posible fundamentación legal.
6. **Retroalimentación.** El ciclo se cierra cuando el personal jurídico valida o corrige la sugerencia del modelo. Estas decisiones se reincorporan al repositorio de datos para el reentrenamiento futuro, permitiendo que el clasificador evolucione conforme cambian los criterios institucionales.

Capítulo 5

Marco Teórico

Con el fin de optimizar el flujo operativo dentro de la Defensoría de Derechos Politécnicos (DDP), se implementará un sistema de clasificación para determinar la competencia o incompetencia de una queja. Este sistema brindará apoyo directamente en la etapa de primer contacto; con ello se busca transformar el análisis normativo en un modelo computacional capaz de identificar la competencia de manera consistente y eficiente. Para lograrlo, el sistema se apoya en cuatro pilares conceptuales que se desarrollan en este capítulo: el marco legal que define el problema de clasificación, los fundamentos del Procesamiento de Lenguaje Natural que permiten interpretar la narrativa de las quejas, las técnicas de representación vectorial que traducen ese lenguaje en señales numéricas, y los modelos de aprendizaje automático que aprenden a distinguir entre quejas competentes e incompetentes.

5.1 Problema de clasificación en el contexto de la DDP

El problema central de este proyecto consiste en automatizar la decisión de admisibilidad de una queja ante la Defensoría de Derechos Politécnicos, decisión que actualmente depende del criterio manual del personal de primer contacto y genera inconsistencias operativas. Este problema parte del marco legal presentado en el Acuerdo publicado en la Gaceta Politécnica, Número Extraordinario 622, donde se establece a la DDP como el órgano encargado de promover, proteger y defender los derechos de la comunidad frente a actos u omisiones de las autoridades del Instituto. Por lo tanto, comprender los límites normativos de la competencia institucional es el primer paso para diseñar un clasificador que replique la lógica jurídica con precisión.

En el Artículo 3° del mismo Acuerdo se establece que la Defensoría es competente para conocer quejas relacionadas con presuntas violaciones a los derechos de la comunidad politécnica; sin embargo, el Artículo 4° delimita los márgenes en las materias en que la Defensoría **no** es competente:

1. Afectaciones de carácter colectivo.
2. Resoluciones disciplinarias.
3. Derechos de naturaleza laboral.
4. Evaluaciones académicas de profesores, comisiones dictaminadoras o consejos técnicos consultivos escolares, salvo que en dicha evaluación se violen notoriamente los derechos de los interesados.
5. Procedimientos y resoluciones instaurados por el Órgano Interno de Control en el Instituto.

El proceso de recepción de quejas descrito en el Artículo 13 establece que el personal de la Defensoría debe determinar en primera instancia si la queja es competente o incompetente. Esta decisión, aparentemente sencilla, presenta en la práctica alta ambigüedad derivada de la redacción de los hechos. Dicha dependencia del criterio manual genera tres conflictos críticos:

1. El consumo excesivo de tiempo administrativo.
2. La variabilidad de interpretaciones ante casos similares.
3. La saturación operativa debida al incremento constante de solicitudes.

En consecuencia, el problema se define como una tarea de *Procesamiento de Lenguaje Natural* (PLN) y *clasificación supervisada*, donde el sistema debe aprender a identificar los patrones lingüísticos y normativos que separan una queja competente de una incompetente.

5.1.1 Taxonomía de denuncias

Las denuncias recibidas por la DDP no se clasifican únicamente por su contenido textual, sino por una estructura jerárquica de validación normativa que el sistema debe aprender a reconocer; por ello, establecer una taxonomía clara es condición previa para construir cualquier modelo de clasificación. Transformar una narrativa jurídica en un conjunto de datos procesable por algoritmos de aprendizaje automático requiere organizar el conocimiento normativo de forma sistemática. En el contexto de la Defensoría, esta taxonomía se apoya en dos reglas críticas:

1. **Pertenencia a la comunidad y jerarquía.** Define si las personas involucradas pertenecen a la comunidad politécnica. El sistema deberá identificar la existencia de un quejoso con su estatus institucional y la autoridad a quien se imputa la violación. Sin esta validación de identidad, la queja carece de base para ser procesada.
2. **Exclusiones del Artículo 4°.** Constituye el núcleo del clasificador. Las denuncias se categorizan según la presencia de los cinco criterios de exclusión mencionados anteriormente. Esta regla se traduce en el sistema como siete campos binarios —características estructuradas— que procesan el análisis normativo:
 - Naturaleza laboral vs. derechos politécnicos.
 - Evaluación académica pura vs. vulneración de derechos en evaluación.
 - Afectación individual vs. colectiva.
 - Resolución disciplinaria vs. acto de autoridad.
 - Procedimientos del OIC vs. acto u omisión de autoridad institucional.

Esta estructuración permite que el problema de clasificación no dependa únicamente del texto libre, sino de reglas establecidas en el Artículo 4°. Al final del proceso taxonómico, el sistema asigna a cada expediente una etiqueta binaria definitiva: *Competente* o *No Competente* (canalización a otra instancia o desechamiento), lo que constituye la variable de salida de los modelos de clasificación supervisada.

5.1.2 Clasificación binaria y lógica de admisión

Una vez definida la taxonomía normativa, el siguiente paso es determinar la forma en que el clasificador producirá su veredicto; este sistema adopta un esquema de **clasificación binaria**, decisión fundamentada directamente en el Artículo 13 del Acuerdo número extraordinario 622. A diferencia de otros sistemas de categorización temática —que discriminan entre dominios como deportes, política o finanzas— el clasificador de la DDP produce un veredicto dicotómico: *Competente* o *No Competente*. Esta simplificación a dos clases responde a la lógica de admisión procesal por tres razones fundamentales:

1. **Naturaleza del flujo administrativo.** Dentro de la DDP, el primer contacto actúa como una compuerta. No existe un estado intermedio: una queja o es admitida para su investigación, o

es desechada y canalizada a otra instancia. La clasificación binaria representa fielmente este proceso de toma de decisiones institucional.

2. **Optimización del entrenamiento.** Desde la perspectiva del aprendizaje automático, concentrar la muestra en dos etiquetas permite una mayor densidad de datos por categoría. Dado que el volumen de expedientes históricos etiquetados es finito, un modelo binario es más robusto y menos propenso al error que un modelo multiclase que intentara identificar simultáneamente el tipo específico de exclusión: laboral, académica o disciplinaria.
3. **Reducción del falso negativo.** La lógica de admisión prioriza la protección de los derechos de la comunidad. Al configurar el problema como binario, es posible ajustar el umbral de decisión del modelo —especialmente en algoritmos como SVM— para minimizar los falsos negativos, asegurando que ninguna queja potencialmente competente sea descartada por una clasificación errónea.

Por lo tanto, si el modelo predice la clase *No Competente*, el sistema asiste al personal sugiriendo la fundamentación legal basada en el Artículo 4°. Si la predicción es *Competente*, el expediente fluye automáticamente hacia la etapa de radicación en la Subdefensoría, logrando así la meta de reducir los tiempos de respuesta institucional.

5.1.3 Ciclo de vida de los datos en el aprendizaje supervisado

Para que la clasificación binaria opere de manera confiable, la narrativa jurídica del quejoso debe recorrer un flujo técnico que la transforme en una señal numérica apta para el aprendizaje automático; en consecuencia, el ciclo de vida de los datos estructura en seis etapas el puente entre el texto libre y la decisión del modelo. Este ciclo asegura la trazabilidad y la integridad de la información jurídica en cada una de sus fases:

1. **Captura de datos.** El ciclo inicia en la interfaz de registro donde el quejoso proporciona de forma estructurada su identidad institucional y, de forma no estructurada, el relato de los hechos. Esta etapa asegura que la entrada cumpla con los requisitos mínimos de admisión definidos en el Artículo 13.
2. **Preprocesamiento y limpieza.** La narrativa libre se somete a técnicas de PLN. Se eliminan elementos de ruido, se normaliza el texto y se identifican términos clave que corresponden a las exclusiones normativas del Artículo 4°.

3. **Vectorización y enriquecimiento.** El texto se convierte en representaciones vectoriales (*embeddings*). Simultáneamente, el sistema inyecta las características jurídicas binarias extraídas del expediente, aplicando el factor de amplificación α para dar peso a la señal normativa sobre la semántica.
4. **Entrenamiento y ajuste.** Utilizando un conjunto de datos histórico previamente etiquetado, el modelo aprende a identificar las fronteras de decisión legal. Se emplean técnicas de validación cruzada para medir la robustez de la generalización.
5. **Inferencia y sugerencia.** Ante una queja nueva, el modelo procesa los vectores y genera una predicción de competencia acompañada de un nivel de probabilidad. El sistema asiste al personal humano mostrando el veredicto sugerido y la posible fundamentación legal.
6. **Retroalimentación.** El ciclo se cierra cuando el personal jurídico valida o corrige la sugerencia del modelo. Estas decisiones se reincorporan al repositorio de datos para el reentrenamiento futuro, permitiendo que el clasificador evolucione conforme cambian los criterios institucionales.

5.2 Fundamentos de Procesamiento de Lenguaje Natural

El **Procesamiento de Lenguaje Natural** (PLN) es la rama de la inteligencia artificial que estudia cómo dotar a las computadoras de la capacidad de leer, interpretar y generar texto humano. Su importancia radica en que el lenguaje natural —a diferencia de los datos numéricos o tabulares— es inherentemente ambiguo, dependiente del contexto y rico en matices que una máquina no puede procesar directamente. Para que un algoritmo pueda razonar sobre un texto, este debe primero transformarse en una representación matemática que preserve su significado.

En el contexto de este proyecto, el PLN cumple un rol central: las quejas que recibe la DDP llegan como narrativas libres, redactadas en lenguaje coloquial o semijurídico por personas sin formación legal. Esto introduce desafíos particulares que no están presentes en dominios más estandarizados: el vocabulario especializado varía entre quejosos, la estructura argumentativa puede ser implícita, y la clasificación jurídica correcta depende no solo de las palabras usadas sino de la relación normativa que existe entre los hechos descritos y los artículos del Acuerdo 622. Por lo tanto, dos quejas léxicamente similares pueden tener clasificaciones opuestas —una competente y otra no— según el contexto institucional que las rodea.

Para abordar estos desafíos, el sistema requiere dos tipos de herramientas PLN que se desarrollan en las subsecciones siguientes: primero, el fundamento matemático que permite representar documentos como vectores comparables; y después, las transformaciones lingüísticas que preparan y limpian el texto antes de que ese fundamento matemático pueda aplicarse.

5.2.1 Álgebra lineal en espacios vectoriales de alta dimensión

Para que una computadora pueda comparar documentos, determinar cuáles son similares entre sí o trazar una frontera que separe categorías, primero necesita que esos documentos existan como objetos matemáticos. El **álgebra lineal** provee ese lenguaje: permite representar cualquier texto como un vector —una lista ordenada de números— y luego medir relaciones entre vectores con precisión aritmética. Esta representación es el fundamento sobre el que operan todos los vectorizadores y clasificadores empleados en este sistema; sin ella, no existiría un mecanismo para que el modelo aprenda qué quejas son parecidas entre sí ni cómo trazar la línea que separa las competentes de las incompetentes.

La idea central es que cualquier documento puede representarse como un punto en un **espacio vectorial de alta dimensión** $\mathbb{R}^d$, donde d es el número de características que describen al documento. Documentos semánticamente similares —por ejemplo, dos quejas sobre acoso académico— ocuparán regiones cercanas en ese espacio; documentos disímiles —una queja laboral y una queja por evaluación— quedarán alejados. La **similitud coseno** formaliza esta noción de cercanía entre dos documentos $\mathbf{u}$ y $\mathbf{v}$:

$$\text{sim}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|} = \frac{\sum_{i=1}^d u_i v_i}{\sqrt{\sum_{i=1}^d u_i^2} \cdot \sqrt{\sum_{i=1}^d v_i^2}} \quad (5.1)$$

donde $\text{sim} \in [-1, 1]$. Un valor cercano a 1 indica alta similitud semántica; esta métrica es la base del razonamiento por proximidad que subyace a todos los vectorizadores empleados en el sistema.

La elección de cuántas dimensiones usar para representar los documentos no es arbitraria. En este proyecto se trabaja con:

- 300 dimensiones esto es por SpaCy la cual fue entrenada por Explosion AI usando word2vec y esta ultima fue entrenada originalmente por Mikolov et al. (2013) con vectores de 300 dimensiones, convirtiéndose en el estándar de la industria.
- 768 dimensiones por SentenceBert. Ese número viene de la arquitectura BERT base, que usa capas de atención con una dimensión oculta de 768. Cuando Reimers y Gurevych construyeron SBERT sobre BERT, el vector de salida del pooling final hereda esa dimensión.

A mayor dimensión, el modelo puede capturar matices semánticos más finos —por ejemplo, distinguir entre “*no se me permitió acceder*” y “*accedí sin autorización*”— pero también requiere mayor capacidad computacional y datos suficientes para evitar la *maldición de la dimensionalidad*: conforme crece d , el volumen del espacio aumenta exponencialmente y los datos se vuelven muy dispersos, lo que dificulta encontrar vecinos significativos. Sobre estos espacios, el sistema ejecuta cuatro operaciones elementales del álgebra lineal:

- **Suma de vectores:** permite combinar representaciones de tokens individuales en una representación de documento.
- **Promedio ponderado:** base del vectorizador de spaCy.
- **Producto punto y norma:** usados internamente por SVM para calcular márgenes de separación.
- **Concatenación horizontal:** operación central de la arquitectura híbrida para unir embeddings de texto con features jurídicos.

Sin embargo, para que estas operaciones produzcan vectores con significado real, el texto de entrada debe estar limpio y estandarizado. Un modelo no puede extraer un vector confiable de una queja llena de errores tipográficos, abreviaturas inconsistentes o términos sinónimos tratados como palabras distintas. De ahí la necesidad del preprocesamiento descrito en la subsección siguiente.

5.2.2 Preprocesamiento de la queja

Antes de que el álgebra lineal pueda operar sobre el texto, la narrativa libre del quejoso debe pasar por una cadena de transformaciones que reduzcan el ruido y estandaricen la representación lingüística; este preprocesamiento es especialmente relevante en textos jurídicos, donde variaciones ortográficas, errores tipográficos o sinónimos coloquiales de términos normativos pueden afectar directamente la calidad de los embeddings. Las transformaciones se aplican en el siguiente orden:

Tokenización

La **tokenización** segmenta el texto continuo en unidades mínimas de significado (tokens). spaCy realiza una tokenización sensible al contexto que distingue, por ejemplo, contracciones y signos de puntuación:

"me negó el acceso" → [me, negó, el, acceso]

Lematización

La **lematización** reduce cada token a su forma canónica (*lema*), eliminando variaciones morfológicas:

negaron → negar, discriminado → discriminar, estudiantiles → estudiantil

Filtrado de palabras vacías

Las **palabras vacías** (*stop words*) son términos de alta frecuencia y bajo contenido semántico (artículos, preposiciones, conjunciones). En textos jurídicos, sin embargo, ciertas palabras que en otros contextos serían vacías — como “no”, “sin” o “nunca” — pueden ser jurídicamente decisivas. spaCy permite personalizar esta lista para el dominio específico de la Defensoría.

Análisis morfosintáctico con spaCy

El modelo `es_core_news_lg` de spaCy realiza, además de la tokenización y lematización, un análisis morfosintáctico completo que asigna a cada token su categoría gramatical (*POS tagging*) y sus dependencias sintácticas. Esto permite identificar, por ejemplo, que en la oración:

“El director me negó el acceso al laboratorio”

el sujeto es *director* (autoridad), el verbo es *negar* (acto de omisión) y el complemento es *acceso al laboratorio* (derecho afectado). Esta información estructural enriquece la representación semántica más allá del léxico superficial, y sienta las bases para la etapa de vectorización descrita en la sección siguiente.

5.3 Representación Vectorial del Texto

Una vez que el texto ha sido normalizado mediante el preprocesamiento, el siguiente desafío consiste en convertirlo en representaciones numéricas que los algoritmos de aprendizaje automático puedan procesar; la representación vectorial del texto es, por lo tanto, el puente entre el lenguaje natural y los clasificadores. A continuación se presenta la evolución de estas técnicas desde los modelos estadísticos hasta los modelos de lenguaje contextuales de última generación, mostrando en cada etapa por qué los enfoques más sencillos son insuficientes para el dominio jurídico de la DDP.

5.3.1 Modelos de Bolsa de Palabras y TF-IDF

Los modelos estadísticos de representación textual constituyen el punto de partida histórico de la vectorización y permiten comprender, por contraste, las limitaciones que motivan el uso de embeddings semánticos en este sistema. Los **modelos de Bolsa de Palabras** (*Bag of Words*, BoW) representan un documento como un vector de frecuencias de términos sobre el vocabulario total del corpus. En BoW cada palabra individual se convierte en una dimensión separada del espacio vectorial: si un conjunto de texto tiene n palabras, el espacio vectorial resultante tendrá n dimensiones, y la posición de un documento en ese espacio está determinada por la cantidad de veces que aparece cada término. Formalmente:

$$\mathbf{v}_{BoW}(d) = [f(t_1, d), f(t_2, d), \dots, f(t_V, d)] \quad (5.2)$$

donde $f(t_i, d)$ es la frecuencia del término t_i en el documento d y V es el tamaño del vocabulario.

TF-IDF (*Term Frequency – Inverse Document Frequency*) refina este enfoque ponderando cada término según su frecuencia en el documento y su rareza en el corpus:

$$\text{tf-idf}(t, d, D) = \underbrace{\frac{f(t, d)}{\sum_{t'} f(t', d)}}_{\text{TF}} \times \log \underbrace{\frac{|D|}{|\{d' \in D : t \in d'\}|}}_{\text{IDF}} \quad (5.3)$$

Limitaciones críticas para el dominio jurídico. Aunque son computacionalmente eficientes, estos modelos son inadecuados para clasificar quejas de la DDP por dos razones fundamentales:

1. **Pérdida del orden y contexto:** Las frases “*el director negó el acceso*” y “*el acceso negó al director*” generan el mismo vector, aunque tienen significados radicalmente distintos.

2. **Sesgo léxico superficial:** El término “*calificación*” tendría alta frecuencia tanto en quejas por evaluación académica (No Competente) como en quejas por extorsión académica (Competente), haciendo imposible la distinción correcta.

Estos modelos se presentan como antecedentes necesarios para contextualizar la superioridad de los enfoques basados en embeddings empleados en este sistema.

5.3.2 Word Embeddings Estáticos — spaCy (es_core_news_lg)

Dado que los modelos estadísticos pierden el contexto semántico, la siguiente generación de técnicas representa cada palabra como un vector denso aprendido de grandes corpus; esta representación, conocida como **embedding estático**, resuelve la limitación semántica de BoW al colocar palabras relacionadas —como *acoso* y *hostigamiento*— en regiones cercanas del espacio vectorial. Los embeddings estáticos representan cada palabra como un vector denso en $\mathbb{R}^{300}$, entrenado sobre grandes corpus en español mediante el algoritmo *word2vec*. [65]

El modelo `es_core_news_lg` de spaCy [66] fue entrenado sobre el corpus *Spanish Web Crawl* y genera vectores de 300 dimensiones por token. La representación de un documento completo se obtiene promediando los vectores de los tokens informativos:

$$\mathbf{v}_{spaCy}(d) = \frac{1}{|T|} \sum_{t \in T} \mathbf{w}_t, \quad T = \{t \in d \mid \text{has_vector}(t) \wedge \neg \text{is_stop}(t)\} \quad (5.4)$$

donde $\mathbf{w}_t \in \mathbb{R}^{300}$ es el vector del token t y T es el conjunto de tokens informativos (con vector disponible y no vacías).

No obstante, al promediar todos los vectores del documento se pierde el orden sintáctico y el contexto local. La frase “*el profesor me acosó condicionando la calificación*” y la frase “*el profesor condicionó la calificación — sin acosar*” generarían vectores cercanos, a pesar de tener clasificaciones jurídicas distintas. Esta limitación motiva el uso de modelos contextuales como Sentence-BERT, presentados a continuación.

5.3.3 Sentence Transformers — SBERT (paraphrase-multilingual-mpnet-base-v2)

Para superar la insensibilidad al orden y al contexto de los embeddings estáticos, se requiere un modelo que genere una representación de toda la oración tomando en cuenta las relaciones entre

sus partes; **Sentence-BERT (SBERT)** satisface este requisito y representa el estado del arte en codificación semántica de textos.[64] A diferencia de los embeddings estáticos, SBERT genera un único vector de representación para toda la oración, capturando las relaciones entre palabras a lo largo del texto completo mediante la arquitectura *Transformer*.

Arquitectura Transformer

El bloque central del Transformer es el mecanismo de **atención multi-cabeza** (*multi-head self-attention*), que calcula para cada token su relevancia en función de todos los demás tokens del documento:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (5.5)$$

donde Q , K y V son las matrices de consulta, clave y valor derivadas de los embeddings de entrada, y d_k es la dimensión de la clave.[63] Este mecanismo permite que el modelo asigne mayor peso a los tokens contextualmente relevantes. Por ejemplo, en la queja:

“Me reprobó porque no acepté salir con él”

el mecanismo de atención aprende a conectar *reprobó* con *acepté salir*, identificando que la relación causal entre ambos constituye un acto de acoso, no una evaluación académica pura.

Entrenamiento contrastivo de SBERT

SBERT extiende BERT con una capa de *pooling* sobre los estados ocultos y se entrena mediante aprendizaje contrastivo con pares de oraciones semánticamente equivalentes y no equivalentes:

$$\mathcal{L}_{contrastiva} = \sum_{(i,j)} [\text{sim}(\mathbf{e}_i, \mathbf{e}_j) - y_{ij}]^2 \quad (5.6)$$

donde $y_{ij} = 1$ si las oraciones i y j son semánticamente equivalentes y $y_{ij} = 0$ en caso contrario.

Modelo empleado

El modelo `paraphrase-multilingual-mpnet-base-v2` fue entrenado sobre más de 50 idiomas, incluido el español. Genera embeddings de **768 dimensiones** por documento y ha demostrado superioridad frente a los promedios de *word embeddings* en tareas de clasificación de texto corto y mediano. Esta capacidad es crítica para distinguir los casos límite de la DDP, donde el acto jurídicamente relevante puede estar expresado en una sola oración dentro de un párrafo más extenso.

5.4 Ingeniería de Características Híbridas

Aunque los embeddings semánticos capturan el significado del texto, los modelos puramente textuales pueden aprender correlaciones léxicas espurias en lugar de la lógica jurídica subyacente; por ello, una de las contribuciones centrales de este sistema es la **arquitectura híbrida** que combina la representación semántica del texto con conocimiento normativo estructurado. Esta arquitectura opera en dos pasos: primero codifica los criterios del Artículo 4° como variables binarias, y después las fusiona con el embedding textual mediante una concatenación amplificada que equilibra ambas señales.

5.4.1 Codificación de variables normativas

Los cinco criterios de incompetencia del Artículo 4° se traducen en **siete variables binarias** (features jurídicos) que codifican el análisis normativo de cada queja de forma estructurada; esta codificación es el mecanismo que permite al clasificador razonar con base en la ley y no solo en la semántica del texto. Las variables y su descripción normativa se presentan en la Tabla [5.1](#):

Tabla 5.1: Features jurídicos estructurados derivados del Artículo 4°.

# Variable	Descripción normativa
1 es_conflicto_laboral_art4_I	El fondo del conflicto es una relación laboral o sindical (salarios, plazas, escalafón, prestaciones).
2 es_evaluacion_academica_pura_art4_II	La queja versa <i>únicamente</i> sobre la valoración del aprendizaje por parte de un profesor o comisión.
3 hay_vulneracion_notoria_en_evaluacion	Existe una violación de derechos dentro de un proceso evaluativo (extorsión, acoso, discriminación).
4 es_resolucion_disciplinaria_art4_III	La queja impugna una resolución disciplinaria ya emitida.
5 es_afectacion_colectiva_art4_IV	La afectación descrita es grupal, no individual.
6 involucra_oic_art4_V	El asunto está siendo conocido por el Órgano Interno de Control.
7 hay_acto_u_omision_autoridad	Existe un acto u omisión de una autoridad institucional que vulnera derechos políticos.

Estas variables se representan como un vector $\mathbf{f} \in \{0, 1\}^7$ y se determinan a partir del análisis del expediente, ya sea de forma manual durante la construcción del corpus o de forma automática en una etapa futura mediante un modelo extractor. La lógica de consistencia entre las variables y la clase asignada es la siguiente:

- Si clase = No Competente por razón laboral: es_conflicto_laboral_art4_I = 1, resto = 0.
- Si clase = Competente: hay_acto_u_omision_autoridad = 1, todas las fracciones del Art. 4° = 0.
- La variable 3 (hay_vulneracion_notoria) solo puede ser 1 cuando la variable 2 (es_evaluacion_academica_pura) también es 1 y la clase es *Competente*: esto modela la excepción de la fracción IV del Artículo 4°.

5.4.2 Concatenación y Factor de Amplificación (α)

Una vez codificadas las variables normativas, es necesario fusionarlas con el embedding semántico de manera que ambas señales contribuyan equitativamente a la decisión del clasificador; para ello, la unión se realiza mediante **concatenación horizontal** junto con un factor de amplificación α que compensa la diferencia de escala entre los vectores:

$$\mathbf{x}_{final} = [\mathbf{e} \parallel \alpha \cdot \mathbf{f}] \in \mathbb{R}^{d+7} \quad (5.7)$$

donde $d \in \{300, 768\}$ según el vectorizador empleado y α es el **factor de amplificación**.

Justificación matemática del factor α

Sin amplificación ($\alpha = 1$), los 7 features jurídicos quedan efectivamente opacados por las d dimensiones del embedding, cuya norma promedio es significativamente mayor. Para ilustrarlo, considérese la contribución relativa de cada componente a la norma del vector concatenado:

$$\frac{\|\alpha \cdot \mathbf{f}\|}{\|\mathbf{e}\| + \|\alpha \cdot \mathbf{f}\|} = \frac{\alpha\sqrt{7}}{\|\mathbf{e}\| + \alpha\sqrt{7}} \quad (5.8)$$

Con $\|\mathbf{e}\| \approx 15$ (valor típico para embeddings de Sentence-BERT normalizados) y $\alpha = 1$:

$$\frac{1 \cdot \sqrt{7}}{15 + \sqrt{7}} \approx \frac{2,65}{17,65} \approx 15 \%$$

Con $\alpha = 3$:

$$\frac{3\sqrt{7}}{15 + 3\sqrt{7}} \approx \frac{7,94}{22,94} \approx 35 \%$$

El valor $\alpha = 3,0$ fue seleccionado experimentalmente como el punto de equilibrio donde la señal jurídica tiene peso suficiente para influir en las fronteras de decisión del clasificador, sin dominar completamente sobre la información semántica del texto.

5.4.3 Simulación de producción: entrenamiento con metadatos e inferencia en modo autónomo

La arquitectura híbrida introduce una asimetría importante entre el escenario de entrenamiento y el escenario de producción, que debe modelarse explícitamente para evitar que el sistema sea sobreoptimista en sus métricas de evaluación; esta asimetría surge porque, durante la construcción del corpus, el personal jurídico anota manualmente los siete atributos booleanos del Artículo 4°, mientras que en producción el sistema recibe únicamente el relato libre del quejoso sin anotación previa. Esta asimetría se modela mediante dos modos de operación diferenciados:

1. **Modo asistido.** El personal de primer contacto completa el formulario con los atributos jurídicos mientras atiende al quejoso. El clasificador opera con el vector completo $\mathbf{x}_{final} = [\mathbf{e} || \alpha \cdot \mathbf{f}]$, aprovechando tanto la semántica del texto como la señal normativa estructurada.
2. **Modo autónomo.** Los atributos jurídicos se fijan en cero ($\mathbf{f} = \mathbf{0}$), de forma que el clasificador basa su veredicto exclusivamente en la representación semántica del texto: $\mathbf{x}_{final} = [\mathbf{e} || \mathbf{0}]$. Este modo representa el escenario de producción real y constituye la condición de estrés bajo la cual se evalúa la robustez de los modelos.

La distinción entre ambos modos tiene implicaciones directas para la selección del clasificador óptimo: un modelo que dependa excesivamente de la señal normativa amplificada puede exhibir métricas perfectas durante el entrenamiento, pero degradarse significativamente en producción cuando dicha señal no está disponible. Por esta razón, el criterio de selección del modelo final privilegia el desempeño en modo autónomo sobre el desempeño con metadatos.

5.5 Modelos de Aprendizaje Automático Evaluados

Con el vector de características híbridas definido, el siguiente paso es elegir el algoritmo que mejor aprenda las fronteras de decisión legal a partir de él; para garantizar la selección del clasificador óptimo para el dominio jurídico de la DDP, se evaluaron cuatro configuraciones de algoritmos de aprendizaje supervisado con distintos paradigmas de construcción de fronteras de decisión. Cada modelo aporta una perspectiva diferente sobre los datos, y su comparación permite identificar cuál se adapta mejor a la distribución de las quejas en el espacio vectorial.

5.5.1 Máquinas de Soporte Vectorial (SVM)

Las **Máquinas de Soporte Vectorial** (*Support Vector Machines*, SVM) son algoritmos de clasificación que buscan el **hiperplano de máximo margen** que separa las clases en el espacio de características, lo que las hace especialmente robustas ante casos límite como las quejas que se ubican en la frontera entre competente e incompetente. [61] Dado un conjunto de entrenamiento $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ con $y_i \in \{-1, +1\}$, la SVM resuelve el problema de optimización:

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \quad \text{s.a.} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \quad (5.9)$$

donde C es el parámetro de regularización que controla la tolerancia al error de clasificación ($C = 0,5$ en este sistema) y ξ son variables de holgura que permiten clasificación blanda.

Kernel RBF

Para datos no linealmente separables en el espacio original, la SVM proyecta los datos a un espacio de mayor dimensión mediante la **función de kernel**. El kernel de Base Radial (*Radial Basis Function*, RBF) empleado en este sistema calcula la similitud entre dos puntos como:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2\right) \quad (5.10)$$

donde γ controla el radio de influencia de cada vector de soporte. El kernel RBF es especialmente adecuado para embeddings de alta dimensión porque puede construir fronteras de decisión no lineales arbitrariamente complejas, adaptándose a la distribución de los casos jurídicos en el espacio semántico.

Ventaja en el dominio jurídico

La SVM con kernel RBF maximiza el margen de separación entre las clases, lo que le confiere una robustez natural ante casos límite: quejas que caen en la frontera entre *Competente* y *No Competente* se clasifican según el hiperplano de máximo margen, no según la densidad local de puntos. No obstante, esta ventaja geométrica está condicionada a la disponibilidad de una señal de entrada suficientemente discriminativa; cuando los atributos jurídicos no están presentes, la eficacia del clasificador depende enteramente de la calidad del embedding semántico.

5.5.2 Regresión Logística

A diferencia de la SVM —que construye una frontera geométrica de máximo margen— la **Regresión Logística** es un modelo lineal que estima directamente la probabilidad de pertenencia a cada clase, lo que le confiere una interpretabilidad valiosa en el contexto jurídico donde la explicabilidad de la decisión puede ser requerida institucionalmente. La probabilidad de pertenencia a la clase positiva se estima mediante la función logística (sigmoide):

$$P(y = 1 \mid \mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^\top \mathbf{x} + b)}} \quad (5.11)$$

Los parámetros $\mathbf{w}$ y b se estiman minimizando la función de pérdida de entropía cruzada binaria:

$$\mathcal{L}(\mathbf{w}, b) = -\frac{1}{n} \sum_{i=1}^n \left[y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i) \right] + \lambda \|\mathbf{w}\|^2 \quad (5.12)$$

donde λ es el término de regularización L2. La configuración empleada en este sistema es `max_iter=1000` con $C = 0,3$. Adicionalmente, los coeficientes w_j son directamente interpretables: un coeficiente positivo asociado a una dimensión del embedding indica que ese componente favorece la clasificación como *Competente*, lo que facilita la auditoría del modelo.

5.5.3 Ensemble de Árboles — Random Forest

Donde la SVM y la Regresión Logística construyen una sola frontera de decisión, el **Random Forest** resuelve el problema mediante la agregación de múltiples árboles de decisión entrenados sobre subconjuntos aleatorios de los datos; esta estrategia de ensemble reduce la varianza de la predicción individual y confiere al modelo una notable capacidad de generalización. [62] Formalmente:

$$\hat{y}_{RF}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x}) \quad (5.13)$$

donde B es el número de árboles ($B = 300$ en este sistema) y T_b es el b -ésimo árbol entrenado sobre una muestra bootstrap. Los árboles de decisión particionan el espacio de características con cortes ortogonales a los ejes, construyendo regiones de decisión rectangulares de forma recursiva. Aunque en espacios de dimensión muy alta esta estrategia puede ser menos eficiente que el hiperplano de máximo margen de la SVM, el promedio de un número grande de árboles con submuestreo aleatorio

de características reduce significativamente la varianza y resulta especialmente robusto cuando la representación semántica del texto no está apoyada por atributos estructurados.

5.5.4 Ensemble por Votación Suave

Dado que cada clasificador individual tiene fortalezas complementarias, una estrategia de *ensemble* que combine sus predicciones puede alcanzar un desempeño superior al de cualquiera de ellos por separado; la **votación suave** (*soft voting*) aprovecha esta propiedad promediando las probabilidades predichas por múltiples clasificadores base para obtener una predicción final más estable. [?]

$$\hat{y} = \arg \max_c \frac{1}{M} \sum_{m=1}^M p_m(c | \mathbf{x}) \quad (5.14)$$

donde M es el número de modelos base y $p_m(c | \mathbf{x})$ es la probabilidad que el modelo m asigna a la clase c . A diferencia de la **votación dura** —que cuenta votos de clase— la votación suave aprovecha la magnitud de la confianza de cada clasificador, lo que generalmente produce predicciones más calibradas cuando los clasificadores base tienen tasas de error no correlacionadas.

En este sistema, el *ensemble* integra SVM-RBF, Regresión Logística y Random Forest. La motivación es que cada clasificador tiene fortalezas complementarias: SVM maximiza el margen geométrico, la Regresión Logística produce probabilidades linealmente calibradas, y Random Forest captura fronteras no lineales por partición del espacio. Si sus errores no están correlacionados, el *ensemble* reduce la varianza de la predicción individual respecto a cualquiera de los modelos base. Para que el `VotingClassifier` pueda operar en modo `voting="soft"`, todos los estimadores deben exponer el método `predict_proba`; dado que `SVC` no lo implementa de forma nativa, se envuelve en `CalibratedClassifierCV`, que estima probabilidades mediante validación cruzada interna sobre el conjunto de entrenamiento.

5.6 Estrategias de Entrenamiento y Validación Robusta

La selección del mejor clasificador no puede basarse en métricas obtenidas sobre los mismos datos usados para entrenarlo, ya que esto produciría una estimación optimista del desempeño real; por ello, las estrategias de entrenamiento y validación robusta garantizan que las métricas reportadas reflejen la capacidad de generalización real del sistema y no sean artefactos de una partición particular de los datos.

5.6.1 Validación Cruzada K -Fold Estratificada

La **validación cruzada K -fold** es la estrategia central para estimar el desempeño de los modelos de manera confiable: divide el conjunto de datos en K particiones de tamaño aproximadamente igual y rota el conjunto de evaluación de manera que todos los datos sean usados para prueba exactamente una vez. En cada iteración, $K - 1$ particiones se usan para entrenamiento y la restante para evaluación, obteniendo una estimación promedio del desempeño:

$$\overline{F1}_{CV} = \frac{1}{K} \sum_{k=1}^K F1_k \quad (5.15)$$

La variante **estratificada** garantiza que la proporción de clases se mantiene en cada pliegue, lo cual es crítico ante corpus con posible desbalance entre quejas competentes e incompetentes. En este proyecto se empleó $K = 5$, lo que significa que en cada iteración el 80 % de los datos se usa para entrenamiento y el 20 % restante para evaluación. Además del promedio, la desviación estándar entre pliegues (σ_{CV}) se usa como medida de **estabilidad** del modelo:

$$\sigma_{CV} = \sqrt{\frac{1}{K} \sum_{k=1}^K (F1_k - \overline{F1}_{CV})^2} \quad (5.16)$$

Un σ_{CV} cercano a cero indica que el modelo no es sensible a la partición específica de los datos, condición deseable para un sistema de apoyo en producción.

Nota de implementación. En la implementación de este proyecto, la validación cruzada $K = 5$ se aplica exclusivamente sobre el conjunto de entrenamiento (70 % del corpus, 367 casos), no sobre el dataset completo. Esto significa que cada *fold* evalúa aproximadamente 73 casos internos del entrenamiento. Esta validación se complementa con un conjunto *holdout* independiente del 15 % (79 casos), completamente aislado durante el entrenamiento y la selección de hiperparámetros, cuyo F1 ponderado —evaluado en modo autónomo, sin atributos jurídicos— constituye el criterio definitivo de selección del modelo.

5.6.2 Evaluación mediante Métricas de Inteligencia

Las métricas de evaluación deben reflejar las prioridades institucionales de la DDP y no únicamente la exactitud global del modelo; en consecuencia, se emplean métricas que distinguen entre los

distintos tipos de error, asignando mayor peso al error con mayor costo institucional: clasificar como incompetente una queja que sí debía ser atendida. Para comprender estas métricas, es necesario establecer primero los cuatro resultados posibles de una clasificación binaria, organizados en la **matriz de confusión**:

- **Verdadero Positivo (TP)**: la queja es competente y el modelo la clasifica como competente.
- **Verdadero Negativo (TN)**: la queja es incompetente y el modelo la clasifica como incompetente.
- **Falso Positivo (FP)**: la queja es incompetente pero el modelo la clasifica como competente.
- **Falso Negativo (FN)**: la queja es competente pero el modelo la clasifica como incompetente. En el contexto de la DDP, este es el error más grave: implica descartar una queja que debía ser atendida.

Accuracy

La **exactitud** (*accuracy*) mide la proporción de predicciones correctas sobre el total de instancias:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (5.17)$$

En el contexto de la DDP, donde las consecuencias de un falso negativo son más graves que las de un falso positivo, la accuracy por sí sola no es suficiente. Por ello, se complementa con las métricas de Precisión, Recall y F1-Score.

Precisión, Recall y F1-Score

$$\text{Precisión} = \frac{TP}{TP + FP} \quad (5.18)$$

La **Precisión** mide qué proporción de las quejas clasificadas como competentes realmente lo son; penaliza las falsas alarmas.

$$\text{Recall} = \frac{TP}{TP + FN} \quad (5.19)$$

El **Recall** mide qué proporción de las quejas realmente competentes fueron identificadas correctamente; penaliza los casos omitidos. En el contexto de la DDP el Recall tiene mayor peso institucional: un Recall bajo implica que quejas legítimas están siendo descartadas sin revisión.

$$F1 = \frac{2 \cdot \text{Precisión} \cdot \text{Recall}}{\text{Precisión} + \text{Recall}} \quad (5.20)$$

El **F1-Score** es la media armónica entre Precisión y Recall, ofreciendo un balance que penaliza los extremos donde una métrica es alta a costa de la otra. El **F1 ponderado** (*weighted F1*) extiende este cálculo a ambas clases, ponderando por el número de instancias de cada una:

$$F1_w = \sum_{c \in C} \frac{n_c}{N} \cdot F1_c \quad (5.21)$$

donde n_c es el número de instancias de la clase c y N el total. Esta métrica es la principal para la selección del modelo óptimo en este sistema.

Análisis de la varianza σ

La desviación estándar del F1 en validación cruzada (σ_{CV}) complementa el valor medio al revelar la estabilidad del modelo. Un modelo con $\overline{F1}_{CV} = 0,98$ y $\sigma_{CV} = 0,04$ puede ser menos confiable que uno con $\overline{F1}_{CV} = 0,97$ y $\sigma_{CV} = 0,00$, pues el primero es sensible a la distribución particular de los datos en cada pliegue.

5.6.3 Carga Perezosa y Serialización con **joblib**

Una vez seleccionado el modelo óptimo, este debe ser almacenado y puesto en producción de manera que garantice la reproducibilidad de sus predicciones y minimice el tiempo de arranque del sistema; para ello se combinan la **carga perezosa** y la **serialización con joblib**, dos patrones de diseño que optimizan la eficiencia operativa del clasificador en producción.

La **carga perezosa** (*lazy loading*) inicializa los recursos computacionalmente costosos —como la carga del modelo de Sentence-BERT o el modelo de spaCy— únicamente en el momento en que son requeridos por primera vez, no al inicio del programa. La **serialización** convierte el objeto Python completo —vectorizador y clasificador juntos— en un archivo binario **.pkl**:

Pipeline(vectorizador, clasificador) $\xrightarrow{\text{joblib.dump}}$ modelo.pkl $\xrightarrow{\text{joblib.load}}$ Pipeline listo para inferencia

Esta estrategia es técnicamente relevante por tres razones:

1. **Integridad:** Vectorizador y clasificador se serializan juntos, eliminando el riesgo de usar un clasificador entrenado con un vectorizador distinto al de producción.
2. **Eficiencia:** joblib emplea compresión paralela y mapeo de memoria (*memory mapping*), resultando significativamente más rápido que pickle estándar para arrays numéricos de gran tamaño como los parámetros internos de Sentence-BERT.
3. **Reproducibilidad:** El archivo .pkl incluye la semilla aleatoria (`random_state=42`) y todos los hiperparámetros, garantizando que las predicciones son idénticas entre sesiones y entornos de ejecución.

La convención de nomenclatura de los archivos serializados es:

`<vectorizador>__<clasificador>__<timestamp>.pkl`

lo que permite trazabilidad temporal de los modelos entrenados y facilita la comparación y auditoría de versiones en el contexto institucional de la DDP.

Capítulo 6

Propuesta de proyecto

Capítulo 7

Trabajo Realizado

Este capítulo presenta el reporte técnico detallado de los avances consolidados durante la primera etapa del Trabajo Terminal. El desarrollo abarca cuatro componentes críticos e interdependientes: la interacción con el cliente para el levantamiento de requerimientos institucionales, el modelado de procesos de negocio, el desarrollo integral del microservicio de atención al quejoso —incluyendo su *backend* en Spring Boot y su *frontend* en Angular— y, finalmente, la implementación del motor de inteligencia artificial para la clasificación automática de quejas.

Cada fase se ejecutó bajo una arquitectura de microservicios, asegurando que el producto de cada etapa alimente de forma coherente a la siguiente. Este capítulo no solo documenta el código escrito, sino que evidencia la arquitectura del "edificio" tecnológico construido, cumpliendo con los estándares de diseño y validación requeridos.

7.1 Interacción con el Cliente y Levantamiento de Requerimientos

La definición precisa de los requerimientos constituyó el punto de partida obligado. No es posible diseñar una solución técnica sin una comprensión profunda del contexto operativo. Por ello, se llevaron a cabo sesiones de trabajo con el personal de la Defensoría de los Derechos Politécnicos (DDP).

El objetivo fue identificar las causas y consecuencias del proceso manual vigente, el cual presentaba cuellos de botella en la etapa de clasificación. A través de estas reuniones, se establecieron las reglas de negocio que rigen el ciclo de vida de una queja según el Artículo 4 del Reglamento de

la Defensoría. Estas interacciones permitieron pasar de un problema abstracto a un conjunto de requerimientos funcionales y técnicos que se detallan en las secciones posteriores.

7.2 Modelado de Procesos de Negocio (BPMN)

Para garantizar que el sistema se alinee con la operativa institucional, se formalizó el flujo de trabajo mediante el estándar BPMN (*Business Process Model and Notation*). Este diagrama permite identificar los actores involucrados (Quejoso y Personal de la DDP), los puntos de decisión y las actividades que el sistema automatiza.

Como se observa en la Figura ??, el flujo inicia con la interacción del quejoso en el portal. Un punto crítico es la transición hacia el módulo de clasificación automática, el cual reduce la carga administrativa al sugerir la categoría jurídica de forma inmediata tras la captura de la narrativa de hechos.


The image is a placeholder for a BPMN diagram, indicated by the text 'BMPN_Diagrama.jpg'.

Figura 7.1: Diagrama BPMN del proceso de gestión y atención de quejas.

7.3 Microservicio de Atención al Quejoso

Este microservicio constituye el punto de entrada del ciudadano al sistema. Su propósito es gestionar el ciclo de vida completo de una queja, garantizando la persistencia, integridad y seguridad de la información.

7.3.1 Análisis Funcional mediante Casos de Uso

Para delimitar las responsabilidades del sistema, se elaboró el diagrama de casos de uso que se presenta en la Figura ???. Este análisis permite separar las funciones del usuario quejoso de las capacidades administrativas.




Figura 7.2: Diagrama de Casos de Uso del Microservicio de Atención al Quejoso.

Se identificaron cuatro agrupaciones funcionales principales:

- **Gestión de Accesos:** Implementación de servicios de registro, inicio de sesión (Login) y recuperación de contraseña bajo protocolos de seguridad robustos.

- **Ciclo de Vida de la Queja:** Funcionalidades para el registro de la narrativa de hechos, edición de campos permitidos y eliminación lógica de registros antes de su formalización.
- **Gestión de Evidencia Digital:** Módulo encargado del almacenamiento y vinculación unívoca de archivos adjuntos que respaldan la queja.
- **Seguimiento del Caso:** Capacidad del usuario para consultar el estatus de su expediente en tiempo real y descargar acuses con validez legal.

7.3.2 Implementación Técnica: Backend y Frontend

La construcción del microservicio se realizó bajo un esquema de desacoplamiento total:

- **Backend (Spring Boot):** Se desarrolló una API REST que expone los servicios de negocio. Se utilizó JPA/Hibernate para la capa de persistencia, asegurando una base de datos normalizada que registra cada transición de estado de la queja. La seguridad se gestionó mediante tokens JWT para proteger los *endpoints*.
- **Frontend (Angular):** Se implementó una interfaz de usuario reactiva. Los formularios de captura incluyen validaciones en tiempo real para asegurar que la narrativa de los hechos tenga la calidad necesaria para ser procesada por el clasificador.

7.4 Clasificador Automático de Quejas

El núcleo de inteligencia del sistema reside en este componente. Su función es determinar la categoría jurídica de la queja basándose en el texto libre proporcionado por el usuario.

7.4.1 Ingeniería de Características

Cada queja se transforma en un vector híbrido que combina:

1. **Componente Semántico:** Representación vectorial del texto obtenida mediante modelos de lenguaje (spaCy/SBERT).
2. **Componente Jurídico:** Siete atributos booleanos derivados del Artículo 4 del Reglamento.

Para evitar la dilución de la señal normativa, se aplicó un factor de amplificación $\alpha = 3,0$ sobre los atributos jurídicos antes de la concatenación, permitiendo que el modelo priorice los elementos legales sin ignorar el contexto semántico de los hechos.

7.4.2 Resultados de la Validación

Tras evaluar ocho configuraciones de *machine learning*, se seleccionó el modelo de **Random Forest con vectorización spaCy**. Este modelo alcanzó un F1-score ponderado de **0.9873** en el conjunto de prueba *holdout*. El clasificador fue serializado mediante la librería *joblib* e integrado al ecosistema de microservicios para permitir inferencias en tiempo real durante el registro de la queja.

7.5 Resumen de la Etapa

La integración de estos componentes transforma una petición ciudadana desestructurada en un registro digital procesable y clasificado. El trabajo realizado en esta fase sienta las bases sólidas para el Trabajo Terminal 2, donde se expandirán las capacidades de resolución y administración del sistema.

Capítulo 8

Resultados Obtenidos

Bibliografía

- [1] Instituto Politécnico Nacional, “*Ley Orgánica del Instituto Politécnico Nacional*”, Diario Oficial de la Federación, Ciudad de México, México. Disponible en: <https://www.ipn.mx/assets/files/defensoria/docs/manuales/ley-org%C3%A1nica-ipn.pdf>
- [2] Instituto Politécnico Nacional, “*Reglamento Interno del Instituto Politécnico Nacional*”, Gaceta Politécnica, Ciudad de México, México. Disponible en: <https://www.ipn.mx/assets/files/defensoria/docs/manuales/reglamento-interno.pdf>
- [3] Instituto Politécnico Nacional, “*Acuerdo de creación de la Defensoría de los Derechos Politécnicos*”, Gaceta Politécnica, no. 622 (Extraordinaria), pp. 3-7, 31 ene. 2006. Disponible en: <https://www.ipn.mx/assets/files/imageninstitucional/docs/gaceta-extraordinaria/2006/01/622-31-enero-gaceta-extra-.pdf>
- [4] Instituto Politécnico Nacional, “*Manual de Organización de la Defensoría de los Derechos Politécnicos*”, Dirección de Planeación y Organización, Ciudad de México, México, oct. 2022. Disponible en: <https://www.ipn.mx/assets/files/defensoria/docs/manuales/modd2022.pdf>
- [5] Instituto Politécnico Nacional, “*Manual de Procedimientos de la Defensoría de los Derechos Politécnicos*”, Dirección de Planeación y Organización, Ciudad de México, México, oct. 2024. Disponible en: <https://www.ipn.mx/assets/files/defensoria/docs/manuales/mp-ddp.pdf>
- [6] Secretaría de la Función Pública, “*Sistema Integral de Denuncias Ciudadanas (SIDECE)*”, Gobierno de México. Disponible en: <https://sidec.buengobierno.gob.mx/>
- [7] Agencia Mexicana de Cooperación Internacional para el Desarrollo (AMEXCID), “*Catálogo de Capacidades Mexicanas: Sistema Integral de Quejas y Denuncias Ciudadanas (SIDECE)*”, SRE. Disponible en: <https://de.sre.gob.mx/capacidades/instituciones-mexicanas/sfp/sistema-integral-de-quejas-y-denuncias-ciudadanas-sidec>

- [8] Secretaría Anticorrupción y Buen Gobierno, “*Implementan SFP, BID y GovLab proyecto de mejora al Sistema Integral de Denuncias Ciudadanas (SIDECA)*”, Gob.mx, 22 jul. 2018. Disponible en: <https://www.gob.mx/buengobierno/prensa/implementan-sfp-bid-y-govlab-proyecto-de-mejora-al-sistema-integral-de-denuncias-ciudadanas-sidec>
- [9] Gobierno de la Ciudad de México, “*Denuncia Digital*”, Fiscalía General de Justicia de la CDMX. Disponible en: <https://denunciadigital.cdmx.gob.mx/>
- [10] Denuncia.org, “*Denuncia en línea: Consulta si en tu estado la Fiscalía cuenta con la opción de denuncia digital*”, Impunidad Cero, 2026. Disponible en: <https://denuncia.org/denuncia-digital/>
- [11] Fiscalía General de Justicia de la Ciudad de México, “*Servicios en Línea: Denuncia Digital, Denuncia Anónima y MP Transparente*”, FGJ-CDMX, 2026. Disponible en: <https://www.fgjcdmx.gob.mx/servicios/en-linea>
- [12] Gobierno de la Ciudad de México, “*MP Virtual: Ratificación de Querellas y Actas Especiales*”, FGJ-CDMX. Disponible en: <https://mpvirtual.fgjcdmx.gob.mx/CiberDenuncia/TerminosCondiciones.aspx>
- [13] Nación321, “*5 apps que nos ayudan a combatir la corrupción*”, Grupo Multimedia Lauman, SAPI de CV, 16 feb. 2024. Disponible en: <https://www.nacion321.com/ciudadanos/5-apps-que-nos-ayudan-a-combatir-la-corrupcion>
- [14] Secretaría de la Contraloría del Gobierno del Estado de México, “*Sistema de Atención Mexiquense (SAM)*”, GEM, 2026. Disponible en: <https://www.secogem.gob.mx/sam/tramite.asp>
- [15] Whistlelink, “*The All-in-One Whistleblowing Solution*”, Whistlelink.com, 2026. Disponible en: <https://www.whistlelink.com/>
- [16] EQS Group, “*EQS Integrity Line: The leading whistleblowing system in Europe*”, EQS.com, 2026. Disponible en: <https://www.eqs.com/es/soluciones-gobierno-corporativo/integrity-line/>
- [17] NAVEX Global, “*WhistleB: Whistleblowing Solutions for a Modern Workplace*”, Navex.com, 2026. Disponible en: <https://www.navex.com/en-us/products/whistleb/>

- [18] Whistleblower Software by Whistleblowing Solutions ApS, “*The simple, secure, and compliant whistleblowing system*”, Whistleblowersoftware.com, 2026. Disponible en: <https://whistleblowersoftware.com/es>
- [19] Lefebvre, “*Centinela: Canal de denuncias para el cumplimiento normativo*”, Lefebvre.es, 2026. Disponible en: <https://lefebvre.es/soluciones/centinela/canal-denuncias/>
- [20] Coloriuris, “*Canal de Denuncias: Cumplimiento de la Ley 2/2023 y Directiva (UE) 2019/1937*”, Coloriuris.net, 2026. Disponible en: <https://www.coloriuris.net/canal-de-denuncias/>
- [21] Bully Button, “*The Bully Button: Reporting and Prevention System*”, BullyButton.com, 2026. Disponible en: <http://bullybutton.com/>
- [22] Secretaría de Educación Pública, “*Ventanilla Escolar: Orientación y Quejas*”, Gobierno de México. Disponible en: <https://www.gob.mx/sep/acciones-y-programas/ventanilla-escolar>
- [23] Instituto Politécnico Nacional, “*Protocolo Alerta IPN: Seguridad Institucional*”, Secretaría General del IPN. Disponible en: <https://www.ipn.mx/seguridad/>
- [24] Universidad Nacional Autónoma de México, “*Sistema de Denuncia en Línea de la Defensoría de los Derechos Universitarios*”, UNAM. Disponible en: <https://www.defensoria.unam.mx/denuncia/>
- [25] Procuraduría Federal de la Defensa del Trabajo, “*PROFEDET Digital: Servicios de orientación y seguimiento*”, Gobierno de México. Disponible en: <https://www.gob.mx/profedet>
- [26] Instituto Politécnico Nacional, “*Protocolo para la Prevención, Detección, Atención y Sanción de la Violencia de Género en el Instituto Politécnico Nacional*”, Gaceta Politécnica, Número 1726, Ciudad de México, México, mayo 2023.
- [27] BBVA, “*Arquitectura de software o sistemas: ¿qué es y ejemplos?*”, bbva.com, 2021. [En línea]. Disponible: <https://www.bbva.com/es/innovacion/arquitectura-de-software-o-sistemas-que-es-y-ejemplos/>. [Accedido: 10-abr-2026].
- [28] UTEL, “*Atributos de calidad del software*”, SCALA. [En línea]. Disponible: https://gc.scalahed.com/recursos/files/r161r/w26023w/L1IDS118_l2_s3.pdf. [Accedido: 10-abr-2026].

- [29] Microsoft, “¿Qué es la escalabilidad?”, Microsoft Learn, 2023. [En línea]. Disponible: <https://learn.microsoft.com/es-es/biztalk/core/what-is-scalability>. [Accedido: 10-abr-2026].
- [30] IBM, “¿Qué es una arquitectura monolítica?”, ibm.com. [En línea]. Disponible: <https://www.ibm.com/think/topics/monolithic-architecture>. [Accedido: 10-abr-2026].
- [31] Amazon Web Services (AWS), “Construcción de una arquitectura distribuida y escalable”, aws.amazon.com. [En línea]. Disponible: <https://aws.amazon.com/startups/learn/building-scalable-distributed-architecture?lang=es>. [Accedido: 10-abr-2026].
- [32] Amazon Web Services (AWS), “¿Qué son los microservicios?”, aws.amazon.com. [En línea]. Disponible: <https://aws.amazon.com/es/microservices/>. [Accedido: 10-abr-2026].
- [33] IBM, “¿Qué es la arquitectura de tres capas?”, ibm.com. [En línea]. Disponible: <https://www.ibm.com/mx-es/think/topics/three-tier-architecture>. [Accedido: 10-abr-2026].
- [34] NGINX, “nginx”, nginx.org. [En línea]. Disponible: <https://nginx.org/en/>. [Accedido: 10-abr-2026].
- [35] B. Khanal, “Nginx: The Lightweight Powerhouse for Modern Web Serving”, Medium, 2023. [En línea]. Disponible: <https://medium.com/@bishal.khanal.2057/nginx-the-lightweight-powerhouse-for-modern-web-serving-717f7cc628da>. [Accedido: 10-abr-2026].
- [36] Oracle, “¿Qué es la tecnología Java y para qué la necesito?”, java.com. [En línea]. Disponible: https://www.java.com/es/download/help/whatis_java.html. [Accedido: 10-abr-2026].
- [37] IBM, “¿Qué es Java?”, ibm.com. [En línea]. Disponible: <https://www.ibm.com/mx-es/think/topics/java>. [Accedido: 10-abr-2026].
- [38] IBM, “¿Qué es Spring Boot?”, ibm.com. [En línea]. Disponible: <https://www.ibm.com/mx-es/think/topics/java-spring-boot>. [Accedido: 10-abr-2026].
- [39] Amazon Web Services (AWS), “¿Qué es Python?”, aws.amazon.com. [En línea]. Disponible: <https://aws.amazon.com/es/what-is/python/>. [Accedido: 10-abr-2026].
- [40] Angular, “What is Angular?”, angular.dev. [En línea]. Disponible: <https://angular.dev/overview>. [Accedido: 10-abr-2026].

- [41] Imagina Formación, “*Conoce las ventajas de utilizar Angular*”, imaginaformacion.com. [En línea]. Disponible: <https://imaginaformacion.com/tutoriales/conoce-las-ventajas-de-utilizar-angular>. [Accedido: 10-abr-2026].
- [42] IBM, “*¿Qué es PostgreSQL?*”, ibm.com. [En línea]. Disponible: <https://www.ibm.com/mx-es/think/topics/postgresql>. [Accedido: 10-abr-2026].
- [43] Red Hat, “*¿Qué es Docker?*”, redhat.com. [En línea]. Disponible: <https://www.redhat.com/es/topics/containers/what-is-docker>. [Accedido: 10-abr-2026].
- [44] GitHub, “*Acerca de GitHub y Git*”, docs.github.com. [En línea]. Disponible: <https://docs.github.com/es/get-started/start-your-journey/about-github-and-git>. [Accedido: 10-abr-2026].
- [45] E. Linis, “*Conceptos Básicos de Git*”, Gist GitHub. [En línea]. Disponible: <https://gist.github.com/erlinis/57a55dfb0337f5cd15cd>. [Accedido: 10-abr-2026].
- [46] Villamizar, M., et al. *Evaluating the Monolithic and the Microservice Architecture Pattern to Deploy Web Applications in the Cloud*. Universidad de los Andes, Colombia.
- [47] Tanenbaum, A. S., et al. *Arquitectura de Sistemas Distribuidos*.
- [48] Microsoft Ibérica. *Guía de Arquitectura N-Capas orientada al Dominio con .NET 4.0*.
- [49] Poza Luján, J. L. *Propuesta de arquitectura distribuida de control inteligente basada en políticas de calidad de servicio*. Universitat Politècnica de València.
- [50] Coti Colop, B. M. *Reglas del Negocio en Arquitectura Tres Capas*. Universidad de San Carlos de Guatemala.
- [51] Álvarez Caules, C. *Spring Boot Actuator*. Arquitectura Java. Recuperado de: <https://www.arquitecturajava.com/spring-boot-actuator/>
- [52] Spring Security. *OAuth 2.0 Resource Server JWT*. VMware, Inc. Recuperado de: <https://docs.spring.io/spring-security/reference/servlet/oauth2/resource-server/jwt.html>
- [53] Spring Cloud. *Spring Cloud Config & Netflix Eureka*. VMware, Inc. Recuperado de: <https://spring.io/projects/spring-cloud>
- [54] Fielding, R. T. *Architectural Styles and the Design of Network-based Software Architectures*. University of California, Irvine.

- [55] Kleppmann, M. *Designing Data-Intensive Applications: The Big Ideas Behind Reliable, Scalable, and Maintainable Systems*. O'Reilly Media.
- [56] Rescorla, E. *The Transport Layer Security (TLS) Protocol Version 1.3*. RFC 8446, Internet Engineering Task Force (IETF).
- [57] Stopford, B. *Designing Event-Driven Systems: Concepts and Patterns for Streaming Services with Apache Kafka*. O'Reilly Media.
- [58] Nygard, M. T. *Release It!: Design and Deploy Production-Ready Software*. Pragmatic Bookshelf.
- [59] Burns, B., Beda, J., y Hightower, K. *Kubernetes: Up and Running: Dive into the Future of Infrastructure*. O'Reilly Media.
- [60] Schönig, H. J. *Mastering PostgreSQL 15: Advanced techniques to build and manage scalable, reliable, and fault-tolerant database applications*. Packt Publishing.
- [61] C. Cortes y V. Vapnik, “Support-Vector Networks”, *Machine Learning*, vol. 20, no. 3, pp. 273–297, sep. 1995. DOI: <https://doi.org/10.1007/BF00994018>
- [62] L. Breiman, “Random Forests”, *Machine Learning*, vol. 45, no. 1, pp. 5–32, oct. 2001. DOI: <https://doi.org/10.1023/A:1010933404324>
- [63] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser e I. Polosukhin, “Attention is All You Need”, en *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, pp. 5998–6008, 2017. Disponible en: <https://arxiv.org/abs/1706.03762>
- [64] N. Reimers e I. Gurevych, “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks”, en *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)*, pp. 3982–3992, Hong Kong, China, nov. 2019. Disponible en: <https://arxiv.org/abs/1908.10084>
- [65] T. Mikolov, I. Sutskever, K. Chen, G. S. Corrado y J. Dean, “Distributed Representations of Words and Phrases and their Compositionality”, en *Advances in Neural Information Processing Systems 26 (NIPS 2013)*, pp. 3111–3119, 2013. Disponible en: <https://arxiv.org/abs/1310.4546>
- [66] M. Honnibal, I. Montani, S. Van Landeghem y A. Boyd, “spaCy: Industrial-strength Natural Language Processing in Python”, Zenodo, 2020. DOI: <https://doi.org/10.5281/zenodo.1212303>

- [67] F. Pedregosa *et al.*, “*Scikit-learn: Machine Learning in Python*”, *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. Disponible en: <http://www.jmlr.org/papers/volume12/pedregosa11a/pedregosa11a.pdf>