INSTITUTO POLITÉCNICO NACIONAL

ESCUELA SUPERIOR DE CÓMPUTO

ESCOM

Trabajo Terminal

2026-B009

“Plataforma Web para la Denuncia Segura y Prevenciòn de Riesgos Digitales”

Presentan

Edgar Jair Flores Espinosa

Jose Bryan Omar Jimenez Velazquez

Leilani Shareni Santos Rivera

Directores

Dr. Jessie Paulina Guzman Flores

M. en C. Ulises Velez Saldaña

20 de Noviembre de 2026

INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO
SUBDIRECCIÓN ACADÉMICA

No. de TT: 2026-B009

Fecha de presentación de TT-II: 20 de Noviembre de 2026

Documento Técnico

"Plataforma Web para la Denuncia Segura y Prevención de Riesgos Digitales"

Presentan:

Edgar Jair Flores Espinosa, Jose Bryan Omar Jimenez Velazquez, Leilani Shareni Santos Rivera

Directores:

Dr. Jessie Paulina Guzman Flores

M. en C. Ulises Velez Saldaña

RESUMEN

En este trabajo terminal se desarrolló una plataforma web para la denuncia segura y prevención de riesgos digitales. La solución propuesta permite a los usuarios reportar situaciones de riesgo digital de manera segura y anónima, facilitando la identificación y respuesta ante estos casos. La plataforma integra funcionalidades de registro, seguimiento y análisis de denuncias, contribuyendo a un entorno digital más seguro para todos los usuarios.

Palabras clave: denuncia segura, prevención de riesgos digitales, plataforma web, seguridad digital.

[1] josebryanomar2004@gmail.com

Advertencia

"Este documento contiene información desarrollada por la Escuela Superior de Cómputo del Instituto Politécnico Nacional, a partir de datos y documentos con derecho de propiedad y por lo tanto, su uso quedará restringido a las aplicaciones que explícitamente se convengan."

La aplicación no convenida exime a la escuela su responsabilidad técnica y da lugar a las consecuencias legales que para tal efecto se determinen.

Información adicional sobre este reporte técnico podrá obtenerse en:

La Subdirección Académica de la Escuela Superior de Cómputo del Instituto Politécnico Nacional, situada en Av. Juan de Dios Bátiz s/n Teléfono: 57296000, extensión 52000.

Índice general

1. Introducción **1**

2. Planteamiento del Problema **5**

2.1. Problema general 5

2.2. Problemas específicos 5

2.3. Causas 6

2.4. Alcances 8

2.5. Limitaciones 8

3. Estado del Arte **11**

3.1. Comparativa de plataformas 11

3.2. Brechas tecnológicas identificadas 12

4. Marco Teórico **13**

4.1. Fundamentos de arquitectura de software 13

4.1.1. Atributos de calidad 13

4.1.2. Del monolito a los microservicios 14

4.1.3. Arquitectura en capas 15

4.1.4. Comunicación entre servicios 15

4.1.5. Persistencia de datos 15

4.2. Tecnologías de construcción y ejecución 16

4.2.1. Plataforma del lado del servidor 16

4.2.2. Interfaz de usuario 16

4.2.3. Contenedores 16

4.2.4. Proxy inverso 17

4.2.5. Control de versiones 17

4.3. Seguridad aplicada al software 17

4.3.1. Autenticación basada en tokens 17

4.3.2. Almacenamiento seguro de contraseñas . . . 18
4.3.3. Control de acceso basado en roles . . . 18
4.3.4. Intercambio de recursos entre orígenes . . . 18
4.3.5. Cifrado en tránsito . . . 19
4.4. Fundamentos de Procesamiento de Lenguaje Natural . . . 19
4.4.1. Preprocesamiento de textos . . . 19
4.4.2. Representación vectorial del texto . . . 20
4.4.3. Modelos codificadores: Sentence Transformers y MiniLM . . . 21
4.4.4. Similitud coseno . . . 22
4.5. Búsqueda de antecedentes y detección de posibles duplicidades . . . 22
4.5.1. Recuperación de información . . . 23
4.5.2. Similitud léxica y semántica . . . 23
4.5.3. Fragmentación de documentos para recuperación semántica . . . 24
4.5.4. Recuperación híbrida y fusión de rankings . . . 24
4.5.5. Indexación y reutilización de representaciones semánticas . . . 25
4.5.6. Identificación de documentos relacionados . . . 25
4.5.7. Evaluación de recuperación de antecedentes . . . 25
4.5.8. Métricas de ordenamiento y evaluación experimental . . . 26
4.6. Generación automática de resúmenes . . . 27
4.6.1. Resumen extractivo y abstractivo . . . 27
4.6.2. Selección extractiva mediante Maximum Marginal Relevance . . . 28
4.6.3. Modelos de lenguaje basados en Transformers . . . 28
4.6.4. Generación autoregresiva y cuantización de modelos de lenguaje . . . 29
4.6.5. Fidelidad y consistencia factual . . . 29
4.6.6. Evaluación de resúmenes generados . . . 30

5. Análisis y Diseño **31**
5.1. Descripción general de la solución . . . 31
5.2. Actores del sistema . . . 32
5.3. Especificación de requerimientos . . . 33
5.3.1. Requerimientos funcionales del quejoso . . . 33
5.3.2. Requerimientos funcionales del personal de recepción . . . 35
5.3.3. Requerimientos funcionales de Primer Contacto . . . 36
5.3.4. Requerimientos funcionales de Subdefensoría . . . 37
5.3.5. Requerimientos funcionales de la Defensora . . . 37
5.3.6. Criterios funcionales de los componentes de inteligencia artificial . . . 38

5.3.7. Requerimientos no funcionales . . . 39
5.3.8. Reglas de negocio . . . 40
5.4. Casos de uso . . . 42
5.4.1. Casos de uso de apoyo al análisis de Primer Contacto . . . 47
5.5. Ciclo de vida del expediente . . . 47
5.6. Diseño de la arquitectura . . . 48
5.6.1. Vista de componentes . . . 48
5.6.2. Vista de despliegue . . . 49
5.6.3. Diseño de la comunicación entre servicios . . . 50
5.6.4. Diseño de la seguridad y el control de acceso . . . 50
5.6.5. Decisiones de diseño y alternativas descartadas . . . 51
5.7. Diseño de la base de datos . . . 53
5.7.1. Correspondencia entre reglas de negocio y mecanismos de integridad . . . 53
5.8. Diseño de los componentes de inteligencia artificial . . . 54
5.8.1. Diseño del componente de búsqueda de antecedentes . . . 55
5.8.2. Diseño del componente de generación de resúmenes . . . 56
5.8.3. Integración de los servicios con Primer Contacto . . . 56
5.8.4. Decisiones de diseño y alternativas consideradas . . . 57
5.9. Diseño de la interfaz de usuario . . . 57

6. Implementación y evaluación del prototipo **59**
6.1. Entorno de desarrollo y herramientas . . . 59
6.2. Implementación del lado del servidor . . . 60
6.2.1. Estructura común de un microservicio . . . 60
6.2.2. Verificación de tokens y control de acceso . . . 61
6.2.3. Manejo centralizado de errores . . . 61
6.2.4. Documentación de la interfaz de programación . . . 61
6.2.5. Puntos de acceso implementados . . . 62
6.3. Implementación de las aplicaciones web . . . 63
6.3.1. Estructura común . . . 63
6.3.2. Interceptores y guardas . . . 63
6.3.3. Detección de cambios sin zonas . . . 63
6.4. Empaquetado en contenedores y despliegue . . . 64
6.4.1. Configuración externalizada . . . 65
6.4.2. Publicación segura y cifrado del canal . . . 65
6.5. Implementación de la búsqueda de antecedentes . . . 66

6.5.1. Preparación del índice y fragmentación 66
6.5.2. Recuperación y ordenamiento 66
6.6. Implementación de la generación de resúmenes 67
6.6.1. Ejecución del editor lingüístico 67
6.6.2. Respuesta y revisión humana 67
6.7. Evaluación experimental de los componentes de inteligencia artificial 67
6.8. Pruebas y verificación 68
6.9. Estado de avance por componente 69

7. Módulos de la Plataforma **71**
7.1. Portal del quejoso 71
7.2. Respuesta de la persona señalada 71
7.3. Panel de Recepción 71
7.4. Panel de Primer Contacto 72
7.5. Panel de Subdefensoría 72
7.6. Panel de la Defensora 72

8. Pruebas **75**
8.1. Estrategia de pruebas 75
8.1.1. Niveles y técnicas 75
8.1.2. Prioridad basada en riesgo 76
8.1.3. Entorno y criterios 76
8.2. Pruebas de funcionalidad 76
8.2.1. Pruebas unitarias 76
8.2.2. Pruebas de integración y de sistema 77
8.3. Pruebas de mantenibilidad 79
8.3.1. Guía de estilo 79
8.4. Pruebas de usabilidad 80
8.5. Pruebas de fiabilidad 81
8.6. Pruebas de seguridad 82
8.6.1. Matriz de permisos extraída del código 82
8.6.2. Casos de prueba de seguridad 82
8.7. Pruebas de capacidad 84
8.8. Pruebas de confidencialidad 85
8.9. Pruebas de los componentes de inteligencia artificial 86
8.9.1. Evaluación de recuperación de antecedentes 86

8.9.2. Funcionamiento del índice y respuesta de antecedentes 88
8.9.3. Generación de resúmenes e integración con los servicios 88
8.9.4. Alcance de los resultados de inteligencia artificial 89
8.10. Resumen de resultados 89

Referencias **91**

Índice de figuras

Índice de tablas

3.1. Comparativa general de plataformas de denuncia digital 12

4.1. Comparación entre arquitectura monolítica y de microservicios 14

5.1. Actores, roles e interfaces del sistema 32
5.2. Requerimientos funcionales del actor Quejoso 34
5.3. Requerimientos funcionales del actor Personal de recepción 35
5.4. Requerimientos funcionales del actor Analista de Primer Contacto 36
5.5. Requerimientos funcionales del actor Abogado de Subdefensoría 37
5.6. Requerimientos funcionales del actor Defensora 38
5.7. Criterios funcionales de los servicios de inteligencia artificial 38
5.8. Requerimientos no funcionales de la plataforma 39
5.9. Reglas de negocio de la plataforma 40
5.10. Casos de uso del actor Quejoso 42
5.11. Casos de uso del actor Personal de recepción 43
5.12. Casos de uso del actor Analista de Primer Contacto 44
5.13. Casos de uso del actor Abogado de Subdefensoría 45
5.14. Casos de uso del actor Defensora 46
5.15. Casos de uso de apoyo mediante inteligencia artificial 47
5.16. Microservicios de la plataforma y su responsabilidad 48
5.17. Reglas de enrutamiento del proxy inverso público 49
5.18. Esquema de la base de datos por tabla y servicio propietario 53
5.19. Reglas de negocio y mecanismo que las hace cumplir 54
5.20. Decisiones técnicas de los componentes de inteligencia artificial 57

6.1. Herramientas empleadas y su función en el proyecto 59
6.2. Puntos de acceso principales por microservicio 62
6.3. Matriz de despliegue en contenedores 64
6.4. Estado de avance por componente al cierre de la etapa 69

7.1. Reglas de “Casos que requieren atención” 73

8.1. Pruebas unitarias por microservicio 77
8.2. Pruebas de integración y de sistema 78
8.3. Pruebas de mantenibilidad 79
8.4. Pruebas de usabilidad 80
8.5. Pruebas de fiabilidad 81
8.6. Pruebas de seguridad 82
8.7. Pruebas de capacidad 84
8.8. Pruebas de confidencialidad 85
8.9. Resultados de recuperación en 200 quejas sintéticas extensas 87
8.10. Resultados en 15 consultas sintéticas contrastivas 87
8.11. Defectos abiertos y acción correctiva 90

Capítulo 1

Introducción

El presente documento expone los avances del Trabajo Terminal 2026-B009, desarrollado en colaboración con la Defensoría de los Derechos Politécnicos (DDP) del Instituto Politécnico Nacional (IPN), cuyo propósito es diseñar e implementar una plataforma web que contribuya a optimizar los procesos de recepción, atención y seguimiento de quejas. Para ello, se analizan las necesidades operativas de la institución, las limitaciones de los procedimientos actuales y las alternativas tecnológicas que pueden contribuir a su mejora. La propuesta contempla la integración de herramientas de inteligencia artificial orientadas a la recuperación de antecedentes, la identificación de posibles duplicidades y la generación de resúmenes narrativos, como mecanismos de apoyo para las actividades del personal de la Defensoría.

El Instituto Politécnico Nacional (IPN) es una institución pública de educación media superior y superior que ofrece programas académicos en distintas áreas del conocimiento. Su organización, funcionamiento y atribuciones se encuentran regulados por disposiciones institucionales específicas que establecen su estructura y las funciones de sus órganos internos [1]. En este marco institucional se encuentra la Defensoría de los Derechos Politécnicos, órgano encargado de promover, proteger y defender los derechos de la comunidad politécnica.

La Defensoría de los Derechos Politécnicos desempeña sus funciones dentro de la estructura institucional del IPN, de acuerdo con las atribuciones establecidas en su marco normativo [2], [3]. Su actuación comprende actividades relacionadas con la orientación, recepción y atención de asuntos que involucran posibles vulneraciones de derechos. Si bien la DDP cuenta con atribuciones y funciones propias para el cumplimiento de sus responsabilidades, estas se desarrollan dentro del marco jurídico e institucional del IPN. El cumplimiento de dichas funciones requiere procedimientos que permitan administrar la información de manera organizada y dar seguimiento a las quejas presentadas por la comunidad politécnica.

Los procedimientos de atención de quejas de la DDP presentan áreas de oportunidad relacionadas con la digitalización y la organización de sus actividades internas. De acuerdo con el análisis de sus procesos y la documentación institucional, determinadas actividades de recepción, revisión y seguimiento requieren la intervención directa del personal responsable [4]. Esta dependencia puede incrementar la carga administrativa, dificultar la consulta de información y limitar la automatización de tareas repetitivas.

Asimismo, la revisión de las quejas requiere analizar los hechos descritos por los quejosos, consultar expedientes anteriores e identificar posibles coincidencias con casos previamente registrados. Estas actividades pueden demandar tiempo cuando la información se encuentra distribuida en dis-

tintos registros o cuando las descripciones presentan diferencias en su redacción. Por ello, resulta pertinente incorporar mecanismos tecnológicos que faciliten la recuperación de antecedentes, la identificación de posibles duplicidades y el énfasis en el contenido relevante de las quejas, además de apoyar la gestión y consulta de los expedientes.

La transformación digital ofrece alternativas para mejorar la administración de información y la ejecución de procesos institucionales. En el ámbito de la atención de quejas, las plataformas informáticas permiten centralizar registros, establecer mecanismos de seguimiento y controlar el acceso a información sensible. Sin embargo, la incorporación de tecnología no debe limitarse a sustituir documentos físicos por formularios electrónicos, sino que debe responder a las necesidades de los usuarios y a las características de los procedimientos existentes. Por esta razón, el desarrollo de una solución para la DDP requiere considerar tanto la gestión administrativa de los casos como las actividades de análisis que intervienen durante su atención.

A partir de las necesidades identificadas, el Trabajo Terminal propone el desarrollo de una plataforma web para administrar el proceso de atención de quejas dentro de la Defensoría. La solución contempla funcionalidades para el registro de quejas, la gestión de expedientes, el seguimiento de casos y la administración de usuarios conforme a sus responsabilidades institucionales. También considera la incorporación de herramientas que apoyen determinadas actividades de análisis y consulta de información. De esta manera, la plataforma busca integrar en un mismo entorno los componentes necesarios para facilitar la operación del personal y mantener organizada la información generada durante las distintas etapas de atención.

Uno de los componentes de inteligencia artificial del proyecto está orientado a la detección de posibles duplicidades y la recuperación de antecedentes mediante técnicas de Procesamiento de Lenguaje Natural (PLN). Este modelo analiza la similitud semántica entre una nueva queja y los expedientes previamente registrados, con el propósito de recuperar antecedentes relacionados e identificar posibles duplicidades que requieran una revisión posterior. Para ello, se emplean técnicas de representación vectorial de textos y recuperación de información que permiten comparar las descripciones de los hechos, incluso cuando se utilizan expresiones diferentes. Los resultados proporcionan al personal de la Defensoría una referencia para localizar antecedentes y reconocer posibles quejas duplicadas, sin sustituir la revisión necesaria para determinar si corresponden a un mismo caso.

El segundo componente de inteligencia artificial se enfoca en la generación automática de resúmenes narrativos a partir de las quejas presentadas por los integrantes de la comunidad politécnica. Su finalidad es transformar descripciones extensas, informales o poco estructuradas en textos concisos y coherentes que conserven los acontecimientos relevantes del relato original. Para ello, se consideran modelos de lenguaje capaces de procesar información textual y generar síntesis en lenguaje natural, estableciendo como criterios de evaluación la fidelidad al contenido original, la conservación de los hechos relevantes y la ausencia de información no sustentada en el relato del quejoso. Este componente busca facilitar la lectura de las quejas y enfatizar sus hechos principales, así como apoyar al personal responsable durante la revisión y documentación de los casos.

La plataforma contempla una arquitectura basada en microservicios para organizar sus funcionalidades en componentes independientes. Este enfoque permite separar responsabilidades, facilitar el mantenimiento y desarrollar modificaciones en determinados módulos sin intervenir directamente en la totalidad del sistema [5], [6]. Entre los componentes considerados se encuentran el portal del quejoso, los módulos administrativos, la gestión de expedientes, los mecanismos de autenticación y autorización, y los servicios relacionados con el procesamiento de información mediante inteligen-

cia artificial. La comunicación entre estos componentes requiere definir interfaces, reglas de acceso y mecanismos de intercambio de datos que permitan mantener la integridad y disponibilidad de la información.

El desarrollo del proyecto se apoya en el levantamiento y análisis de requerimientos realizado en colaboración con personal de la Defensoría. Mediante reuniones de trabajo y revisión de procedimientos institucionales, se identificaron actividades, responsabilidades y reglas de negocio relacionadas con la atención de quejas. Esta información permitió representar procesos mediante diagramas BPMN, elaborar propuestas de interfaces y diseñar estructuras de datos acordes con las necesidades identificadas. Asimismo, se realizaron actividades de implementación de componentes de backend y frontend, junto con pruebas funcionales y experimentales orientadas a revisar el comportamiento de las soluciones desarrolladas. Estos trabajos constituyen la base para continuar con la integración y validación de la plataforma.

La integración de herramientas digitales y de procesamiento de lenguaje natural constituye el enfoque tecnológico propuesto para atender las necesidades identificadas en la DDP. Se espera que la plataforma contribuya a organizar la información, facilitar el seguimiento de expedientes y proporcionar herramientas de apoyo para determinadas actividades administrativas y de análisis. No obstante, el alcance de estos beneficios deberá determinarse mediante las pruebas y evaluaciones correspondientes. En los capítulos siguientes se presentan los antecedentes, fundamentos teóricos, requerimientos, decisiones de diseño, actividades de implementación y procedimientos de evaluación que sustentan el desarrollo del Trabajo Terminal.

Capítulo 2

Planteamiento del Problema

Este capítulo presenta el análisis de las principales problemáticas identificadas en los procesos actuales de atención y gestión de quejas dentro de la DDP. Se describen las causas que originan dichas limitaciones operativas y tecnológicas, así como la propuesta de solución planteada para optimizar la administración de expedientes, mejorar la trazabilidad de la información y fortalecer la eficiencia institucional mediante una plataforma digital integral.

2.1. Problema general

El problema central radica en las limitaciones de los mecanismos actuales para gestionar de manera integral, organizada y eficiente los procedimientos relacionados con la atención de quejas. Esta situación representa un desafío para la operación, debido a la necesidad de mantener la continuidad de los expedientes, facilitar el acceso oportuno a la información y asegurar una coordinación adecuada durante las distintas etapas del procedimiento. Por ello, resulta necesario analizar las dificultades particulares que intervienen en la gestión de quejas y que, en conjunto, conforman la problemática identificada en la Defensoría.

2.2. Problemas específicos

La gestión de quejas en la Defensoría de los Derechos Politécnicos presenta diversas dificultades operativas que se manifiestan durante las etapas de recepción, revisión, atención y seguimiento de las solicitudes. A partir del levantamiento de requerimientos y del análisis de los procedimientos institucionales, se identificaron las siguientes problemáticas que afectan la organización de la información, la continuidad de los expedientes y las actividades del personal responsable.

- **Seguimiento de quejas:** El seguimiento de una queja implica conocer su estado, las actuaciones realizadas y las actividades pendientes. Las dificultades para consultar esta información de manera oportuna pueden afectar la continuidad del procedimiento y la coordinación entre las áreas responsables de su atención.
- **Carga operativa en las actividades administrativas:** El personal de la Defensoría realiza actividades de registro, revisión, consulta y actualización de información durante la atención

de quejas. Estas tareas requieren tiempo y atención constante, especialmente cuando deben gestionarse múltiples solicitudes de manera simultánea.

- **Revisión de narrativas extensas:** Algunas quejas presentadas por los integrantes de la comunidad politécnica contienen descripciones extensas de los acontecimientos. Su revisión requiere identificar los hechos relevantes, comprender la secuencia de los sucesos y reconocer la información necesaria para continuar con el procedimiento, lo que representa una actividad que demanda tiempo al personal responsable.

- **Presentación reiterada de quejas:** De acuerdo con lo señalado por el personal de la Defensoría, existen situaciones en las que los quejosos presentan nuevamente una solicitud relacionada con hechos previamente reportados, particularmente cuando consideran que no han recibido una respuesta. Esta situación puede generar registros potencialmente duplicados y requerir revisiones adicionales para determinar si corresponden a un expediente existente o contienen información nueva.

- **Consulta de antecedentes relacionados:** Durante la revisión de una queja puede ser necesario consultar expedientes anteriores relacionados con los hechos descritos o con las personas involucradas. La localización y comparación de estos registros representa una dificultad operativa, especialmente cuando existen diferencias en la manera de describir acontecimientos similares.

- **Coordinación entre las áreas responsables:** La atención de las quejas involucra la participación de diferentes áreas institucionales, cuyas actividades requieren mantener continuidad en el intercambio de información. Las dificultades para consultar las actuaciones y conocer el avance de los procedimientos pueden complicar la coordinación y el seguimiento de los casos.

- **Administración de información sensible:** Los expedientes pueden contener datos personales, documentos y descripciones de situaciones que requieren un tratamiento confidencial. Su administración representa un desafío debido a la necesidad de mantener la integridad de la información, controlar su consulta y conservar un registro de las actuaciones realizadas por el personal autorizado.

Estas problemáticas reflejan las dificultades que intervienen en la administración y atención de quejas dentro de la Defensoría. Aunque se manifiestan en distintas actividades del procedimiento, mantienen una relación directa con la organización de la información, la continuidad de los expedientes y la carga operativa del personal. Su análisis permite identificar los factores que contribuyen a su aparición, los cuales se desarrollan en el siguiente apartado.

2.3. Causas

Las problemáticas identificadas en la gestión de quejas de la Defensoría de los Derechos Politécnicos se relacionan con diversos factores administrativos, operativos y tecnológicos que intervienen en el desarrollo de sus procedimientos internos. A partir del análisis de los procesos institucionales y de la información obtenida durante el levantamiento de requerimientos, se reconocen condiciones que pueden contribuir a las dificultades de organización, consulta y seguimiento de los expedientes.

Estos factores se encuentran relacionados entre sí, por lo que resulta necesario analizarlos desde una perspectiva integral.

La dependencia de actividades manuales constituye uno de los factores que contribuyen a las dificultades operativas durante la atención de quejas. Los procedimientos institucionales requieren que el personal realice tareas de registro, revisión, actualización y consulta de información en distintas etapas del proceso [4]. Cuando estas actividades dependen principalmente de la intervención humana y carecen de mecanismos que faciliten su ejecución, el tiempo disponible del personal debe distribuirse entre tareas administrativas y actividades que requieren un análisis más detallado. Esta condición puede limitar la capacidad operativa de las áreas responsables, particularmente cuando deben atender varias solicitudes de manera simultánea.

La integración limitada de la información representa otro factor que puede dificultar la continuidad de los procedimientos institucionales. La gestión de una queja involucra documentos, registros y actuaciones generados durante diferentes etapas de atención, cuya consulta requiere mantener una relación clara con el expediente correspondiente. Cuando la información se administra mediante mecanismos independientes o parcialmente integrados, resulta más complejo conservar una visión completa y actualizada del desarrollo de cada caso. Esta situación también puede dificultar el intercambio de información entre las áreas que participan en el procedimiento.

Las características de las narrativas presentadas por los quejosos también influyen en el tiempo necesario para revisar las solicitudes. Debido a que los usuarios describen los acontecimientos desde su propia perspectiva, los escritos pueden variar considerablemente en extensión, estructura, claridad y nivel de detalle. Algunas narraciones incluyen información repetida, antecedentes extensos o acontecimientos que no siguen necesariamente un orden cronológico, lo que exige una lectura cuidadosa para identificar los hechos relevantes. La diversidad de estas características dificulta establecer un tiempo uniforme de revisión y aumenta la atención que debe dedicarse a determinados expedientes.

La falta de mecanismos especializados para relacionar la información de diferentes expedientes puede contribuir a las dificultades para identificar antecedentes y posibles registros duplicados. Las solicitudes relacionadas con un mismo asunto no siempre presentan una redacción idéntica, debido a que los quejosos pueden describir nuevamente los acontecimientos utilizando expresiones diferentes o incorporando información adicional. Asimismo, distintos expedientes pueden compartir personas involucradas, circunstancias o características sin corresponder necesariamente al mismo hecho. Estas variaciones hacen que la identificación de relaciones entre registros requiera una comparación cuidadosa de su contenido y contexto.

La comunicación y coordinación entre las áreas responsables constituye otro factor relevante en la gestión institucional de quejas. Durante el procedimiento pueden intervenir diferentes integrantes del personal, cada uno con funciones y responsabilidades específicas conforme a la organización de la Defensoría [3]. La continuidad de las actuaciones depende de que la información generada en una etapa se encuentre disponible para quienes participan posteriormente. Por ello, los mecanismos utilizados para registrar, comunicar y consultar los avances de cada expediente influyen en la coordinación de las actividades institucionales.

La naturaleza de la información administrada por la Defensoría establece condiciones particulares para su tratamiento y conservación. Los expedientes pueden contener datos personales, evidencias y descripciones de situaciones que requieren confidencialidad, por lo que su consulta debe realizarse conforme a las responsabilidades del personal autorizado. Esta necesidad exige mantener controles sobre el acceso, modificación y resguardo de los registros durante las distintas etapas del

procedimiento. En consecuencia, la gestión de la información debe considerar tanto las necesidades operativas de la institución como las obligaciones relacionadas con su protección.

En conjunto, los factores descritos permiten comprender las condiciones que contribuyen a las dificultades identificadas en los procesos de atención de quejas. Su relación evidencia que la problemática no se limita a una actividad particular, sino que involucra aspectos administrativos, documentales, organizacionales y tecnológicos. Este análisis proporciona una base para delimitar el alcance del Trabajo Terminal y establecer las funcionalidades que se contemplarán para atender las necesidades identificadas.

2.4. Alcances

El Trabajo Terminal 2026-B009 contempla el desarrollo de una plataforma web para la gestión de quejas de la Defensoría de los Derechos Politécnicos (DDP) del Instituto Politécnico Nacional. El sistema abarca los procesos de recepción, registro, revisión, atención y seguimiento de quejas, mediante la administración de expedientes digitales.

La plataforma contempla módulos diferenciados para los roles de quejoso, recepcionista, personal de primer contacto, subdefensor y defensor. Sus funcionalidades incluyen el registro de solicitudes, la administración de documentos y evidencias, el seguimiento de expedientes, las notificaciones y el historial de actuaciones, de acuerdo con los permisos correspondientes a cada usuario.

Como parte del sistema, se integran dos componentes de inteligencia artificial: un modelo de búsqueda de antecedentes y detección de posibles duplicidades mediante similitud semántica, y un modelo de generación de resúmenes narrativos que facilite la revisión de las quejas. Ambos funcionan como herramientas de apoyo para el personal de la Defensoría, sin sustituir su criterio ni las decisiones institucionales.

El desarrollo utiliza una arquitectura basada en microservicios e incorpora mecanismos de autenticación, autorización y control de acceso para proteger la información administrada. La plataforma está orientada a su utilización mediante navegadores web, sin contemplar el desarrollo de una aplicación móvil nativa ni la integración con sistemas externos al alcance definido.

El sistema no contempla la emisión automatizada de resoluciones o dictámenes jurídicos, ya que estas actividades corresponden exclusivamente al personal autorizado de la Defensoría.

2.5. Limitaciones

El desarrollo, implementación y evaluación del Trabajo Terminal están sujetos a restricciones académicas, tecnológicas e institucionales que pueden influir en el alcance y funcionamiento de la plataforma. Las principales limitaciones identificadas son las siguientes:

- **Tiempo de desarrollo:** al tratarse de un proyecto académico con un periodo de ejecución definido, la implementación, integración y validación de los módulos se encuentran sujetas al calendario de entregas establecido. Por ello, algunas funcionalidades pueden permanecer en desarrollo durante las etapas intermedias del proyecto.

- **Disponibilidad de datos:** el desarrollo y la evaluación de los modelos de inteligencia artificial dependen de la disponibilidad de expedientes históricos. Ante las restricciones de acceso a información institucional sensible, se utilizan conjuntos de datos de prueba, por lo que los resultados obtenidos no necesariamente representan el comportamiento de los modelos ante casos reales de la Defensoría.
- **Precisión de los modelos:** la recuperación de antecedentes mediante similitud semántica puede identificar casos relacionados que no correspondan a una duplicidad real, así como omitir coincidencias relevantes. Por su parte, el modelo de generación de resúmenes puede presentar omisiones, interpretaciones incorrectas o información no sustentada en el texto original. En consecuencia, sus resultados requieren supervisión humana.
- **Infraestructura tecnológica:** el funcionamiento de la plataforma y de los modelos de inteligencia artificial depende de los recursos computacionales disponibles, particularmente de la capacidad de procesamiento, memoria y almacenamiento. Estas condiciones pueden limitar el rendimiento y la ejecución simultánea de determinados servicios.
- **Restricciones éticas y normativas:** el tratamiento de expedientes y datos personales debe ajustarse a las disposiciones institucionales y a la normativa aplicable en materia de protección de datos. Asimismo, los componentes de inteligencia artificial funcionan exclusivamente como herramientas de apoyo y no sustituyen la revisión, interpretación ni las decisiones jurídicas del personal autorizado.

Capítulo 3

Estado del Arte

En el Trabajo Terminal I (TT-I) se realizó un estudio comparativo de diversas plataformas nacionales e internacionales relacionadas con la recepción y gestión de denuncias, quejas y reportes institucionales. El análisis permitió identificar características funcionales y arquitectónicas relevantes, así como limitaciones presentes en soluciones gubernamentales, ciudadanas, corporativas y académicas. Este estudio sirvió como referencia para establecer los aspectos tecnológicos que debían considerarse en el diseño de la plataforma propuesta para la Defensoría de los Derechos Politécnicos (DDP).

Es importante distinguir entre los atributos considerados durante el análisis del estado del arte y los atributos que posteriormente fueron evaluados directamente en la plataforma desarrollada. Los primeros corresponden a características identificadas teóricamente a partir de la revisión de las soluciones existentes, mientras que los segundos forman parte de las evaluaciones y pruebas realizadas durante el desarrollo del presente Trabajo Terminal. Por lo tanto, la presencia de un atributo en el análisis comparativo no implica necesariamente que haya sido implementado o validado experimentalmente en la plataforma propuesta.

3.1. Comparativa de plataformas

A partir de los criterios definidos, se analizaron plataformas gubernamentales, ciudadanas, corporativas y académicas. Entre ellas se consideraron el Sistema Integral de Denuncias Ciudadanas (SIDEC), Denuncia Digital de la Ciudad de México, MP Virtual, Incorruptible, Sistema de Atención Mexiquense (SAM), Whistlelink, EQS Integrity Line, NAVEX/WhistleB, Whistleblower Software, BullyButton, Ventanilla Escolar, Alerta IPN y la plataforma de Denuncia en Línea de la UNAM. La comparación permitió identificar diferencias en aspectos como seguridad, anonimato, seguimiento, soporte multimedia, automatización, escalabilidad y adaptación al entorno universitario.

La Tabla 3.1 resume los resultados obtenidos durante el análisis realizado en TT-I.

Tabla 3.1: Comparativa general de plataformas de denuncia digital

Plataforma	Seguridad	Anonimato	Seguimiento	Multimedia	Automatización	Escalabilidad	Adaptación universitaria
SIDEC	Media	Baja	Media	Sí	Baja	Media	No
Denuncia Digital CDMX	Media	Baja	Media	Sí	Baja	Media	No
MP Virtual	Media	Media	Media	Sí	Baja	Media	No
Incorruptible	Baja	Media	Baja	Sí	Baja	Alta	No
SAM	Media	Baja	Media	Sí	Baja	Media	No
Whistlelink	Alta	Alta	Alta	Sí	Media	Alta	Parcial
EQS Integrity Line	Alta	Alta	Alta	Sí	Alta	Alta	Parcial
NAVEX / WhistleB	Alta	Alta	Alta	Sí	Alta	Alta	Parcial
Whistleblower Software	Muy alta	Muy alta	Alta	Sí	Alta	Alta	Parcial
BullyButton	Media	Media	Baja	Limitado	Baja	Media	Sí
Ventanilla Escolar	Media	Baja	Baja	No	Baja	Media	Sí
Alerta IPN	Media	Baja	Media	Sí	Baja	Media	Sí
UNAM Denuncia en Línea	Media	Media	Alta	Sí	Media	Media	Sí

3.2. Brechas tecnológicas identificadas

La comparación realizada en TT-I mostró que las plataformas analizadas presentan fortalezas en diferentes dimensiones, pero ninguna reúne de manera integral las características consideradas relevantes para el contexto de la DDP. Entre las principales brechas identificadas se encuentran la dependencia de arquitecturas centralizadas, la limitada automatización de procesos administrativos, las diferencias en los mecanismos de protección de identidad, la baja interoperabilidad entre servicios y las limitaciones para gestionar los expedientes de manera integral.

Asimismo, se observó una adaptación limitada de algunas soluciones a las necesidades particulares de instituciones universitarias públicas. Estas diferencias constituyeron un referente para definir las características de la solución propuesta, particularmente en aspectos relacionados con la organización de expedientes, el seguimiento de casos, la seguridad de la información y la incorporación de mecanismos de apoyo mediante inteligencia artificial.

El análisis del estado del arte permitió, por tanto, establecer un punto de referencia para el desarrollo de la plataforma de la DDP. Sin embargo, las características descritas corresponden al análisis comparativo realizado en TT-I y no deben interpretarse como resultados de pruebas efectuadas sobre la plataforma desarrollada en TT-II. La validación de los atributos que fueron implementados y seleccionados para evaluación se presenta posteriormente en los capítulos correspondientes.

Capítulo 4

Marco Teórico

Este capítulo reúne los fundamentos conceptuales sobre los que se sustenta la solución propuesta y se organiza en dos bloques. El primero desarrolla los principios arquitectónicos, las tecnologías de construcción y los mecanismos de seguridad necesarios para el funcionamiento de la plataforma web. El segundo aborda los fundamentos del Procesamiento de Lenguaje Natural, las técnicas de representación y comparación de documentos, la recuperación de antecedentes y la generación automática de resúmenes narrativos. Estos componentes de inteligencia artificial se consideran herramientas de apoyo para la gestión de quejas y se integran dentro de la arquitectura general de la plataforma.

4.1. Fundamentos de arquitectura de software

La arquitectura de software es el conjunto de decisiones estructurales de alto nivel que definen cómo se organiza un sistema: qué componentes lo integran, qué responsabilidad tiene cada uno y cómo se comunican entre sí [7]. Esas decisiones son costosas de revertir una vez que el sistema está en operación, de modo que conviene tomarlas de forma explícita y justificada desde el diseño, y no dejarlas al azar de la implementación.

4.1.1. Atributos de calidad

Una arquitectura no se evalúa únicamente por las funciones que permite construir, sino por los atributos de calidad que habilita o dificulta [8]. Los relevantes para una plataforma institucional de gestión de quejas son los siguientes:

- **Escalabilidad:** capacidad de atender un volumen creciente de usuarios y peticiones agregando recursos, sin rediseñar el sistema [9]. Se distingue entre escalamiento vertical —dar más capacidad a la misma máquina— y horizontal —agregar más instancias que reparten la carga— [10].

- **Mantenibilidad:** facilidad con que el sistema puede modificarse para corregir defectos o incorporar funciones nuevas. Depende directamente de qué tan acopladas estén sus partes.

- **Disponibilidad:** proporción del tiempo en que el sistema responde correctamente. En un sistema distribuido, el fallo de un componente no debe propagarse al resto [11].
- **Seguridad y confidencialidad:** capacidad de proteger la información frente a accesos no autorizados, atributo crítico cuando los datos administrados son denuncias que identifican a personas.
- **Trazabilidad:** posibilidad de reconstruir qué ocurrió con cada expediente y cuándo, requisito tanto operativo como jurídico en el contexto de la Defensoría.

4.1.2. Del monolito a los microservicios

En una arquitectura **monolítica** toda la funcionalidad se empaqueta y despliega como una única unidad ejecutable [12]. Este enfoque es simple de desarrollar y desplegar en etapas tempranas, pero conforme el sistema crece presenta problemas conocidos: cualquier cambio obliga a reconstruir y desplegar la aplicación completa, el escalamiento debe hacerse en bloque aunque solo un componente esté saturado, y el acoplamiento interno dificulta que varias personas trabajen en paralelo sin interferir entre sí.

Una arquitectura de **microservicios** descompone la aplicación en un conjunto de servicios pequeños e independientes, cada uno con una responsabilidad acotada, su propio ciclo de despliegue y una interfaz bien definida para comunicarse con los demás [5]. Cada servicio puede desarrollarse, desplegarse y escalarse por separado, lo que reduce el impacto de un cambio y permite dimensionar los recursos según la carga real de cada componente. La Tabla 4.1 contrasta ambos estilos.

Tabla 4.1: Comparación entre arquitectura monolítica y de microservicios

Criterio	Monolito	Microservicios
Unidad de despliegue	La aplicación completa.	Cada servicio por separado.
Escalamiento	En bloque, aunque solo un módulo lo requiera.	Selectivo, por servicio.
Acoplamiento	Alto: los módulos comparten proceso y memoria.	Bajo: se comunican por interfaces explícitas.
Impacto de un fallo	Puede detener toda la aplicación.	Acotado al servicio afectado si el diseño lo aísla.
Complejidad operativa	Baja: un solo artefacto que administrar.	Alta: más artefactos, redes y puntos de fallo.
Trabajo en equipo	Los cambios compiten sobre el mismo código.	Equipos independientes por servicio.

La elección entre ambos estilos no es absoluta. Estudios comparativos que despliegan una misma aplicación bajo los dos patrones muestran que los microservicios mejoran el aprovechamiento de recursos y la escalabilidad, pero a costa de una complejidad operativa considerablemente mayor [6]. Un sistema distribuido introduce problemas que un monolito no tiene —latencia de red, fallos parciales, consistencia entre nodos— y que deben resolverse de forma explícita [13]. Por esa razón existen posiciones intermedias, como mantener servicios independientes que comparten una única

base de datos: una decisión que sacrifica autonomía de datos a cambio de simplicidad operativa, razonable a escala institucional pequeña y que conviene documentar como tal.

4.1.3. Arquitectura en capas

De forma transversal al estilo anterior, la organización interna de cada servicio suele seguir un esquema en capas, en el que la presentación, la lógica de negocio y el acceso a datos se separan en niveles con responsabilidades distintas [14]. La capa de presentación expone la interfaz —en un servicio web, los puntos de acceso HTTP—; la capa de negocio concentra las reglas del dominio; y la capa de datos se ocupa de la persistencia. La ventaja principal es que un cambio en una capa no obliga a modificar las demás mientras se respete el contrato entre ellas [15].

Esta separación resulta especialmente valiosa cuando las reglas del dominio son normativas, como en el caso de una defensoría: al concentrarlas en una sola capa, un cambio en el reglamento se traduce en modificaciones localizadas y no dispersas por toda la aplicación [16]. Sobre esa base pueden además incorporarse políticas transversales —calidad de servicio, monitoreo, control de acceso— sin reescribir la lógica de negocio [17].

4.1.4. Comunicación entre servicios

Una vez dividido el sistema, sus partes deben comunicarse. Existen dos familias de mecanismos.

La **comunicación síncrona** sigue el modelo petición-respuesta: un servicio llama a otro y espera el resultado antes de continuar. El estilo arquitectónico dominante para ello es REST (*Representational State Transfer*), formulado por Fielding, que organiza la interfaz en torno a recursos identificados por URI y manipulados mediante los verbos del protocolo HTTP, con comunicación sin estado entre peticiones [18]. Su ventaja es la simplicidad conceptual y la interoperabilidad; su desventaja, que acopla temporalmente a los servicios, pues si el servicio invocado no responde, el invocador queda bloqueado o debe manejar el fallo.

La **comunicación asíncrona** desacopla al emisor del receptor mediante colas o flujos de eventos: el servicio origen publica un evento y continúa, sin esperar a que alguien lo consuma [19]. Ofrece mayor tolerancia a fallos y mejor absorción de picos de carga, al precio de una complejidad notablemente mayor y de consistencia eventual en los datos.

Cuando el número de servicios crece, la comunicación directa entre ellos se vuelve difícil de administrar y aparecen componentes de apoyo —registro y descubrimiento de servicios, configuración centralizada, balanceo de carga— que resuelven de forma estándar esa infraestructura transversal [20].

4.1.5. Persistencia de datos

La mayoría de los sistemas de información institucionales descansa sobre bases de datos relacionales, que organizan la información en tablas vinculadas por claves y garantizan las propiedades ACID: atomicidad, consistencia, aislamiento y durabilidad [21]. Esas garantías son especialmente pertinentes cuando cada registro corresponde a un expediente con efectos jurídicos, donde una escritura parcial o una lectura inconsistente no son aceptables.

PostgreSQL es un gestor relacional de código abierto ampliamente utilizado en producción, con soporte para tipos de datos binarios, transacciones concurrentes, índices avanzados y mecanismos de respaldo y restauración [22]. El diseño de la capa de datos debe considerar, además, cómo evolucionará el esquema con el tiempo y cómo se mantiene la integridad cuando varios componentes acceden al mismo almacén, problema central en el diseño de sistemas intensivos en datos [23].

4.2. Tecnologías de construcción y ejecución

Definidos los principios arquitectónicos, esta sección describe las tecnologías concretas que los materializan, agrupadas por capa.

4.2.1. Plataforma del lado del servidor

Java es un lenguaje de programación orientado a objetos, compilado a un código intermedio que se ejecuta sobre una máquina virtual (JVM), lo que le da independencia respecto del sistema operativo subyacente [24]. Su madurez, su tipado estático y su ecosistema de bibliotecas lo han consolidado en el desarrollo de sistemas empresariales de larga vida [25].

Spring Boot es un marco de trabajo construido sobre el ecosistema Spring que reduce significativamente la configuración necesaria para levantar una aplicación: incorpora autoconfiguración, un servidor de aplicaciones embebido y un modelo de dependencias preempaquetadas que permite pasar de cero a un servicio operativo con poco código de infraestructura [26]. Ofrece además componentes para exponer el estado interno de la aplicación —métricas, verificaciones de salud, información de entorno— indispensables para operar un sistema distribuido sin acceso directo a un depurador [27].

Para el desarrollo de los componentes de inteligencia artificial se emplea Python, un lenguaje de programación de propósito general que dispone de bibliotecas especializadas en Procesamiento de Lenguaje Natural, recuperación de información y aprendizaje automático [28].

4.2.2. Interfaz de usuario

Angular es un marco de trabajo para construir aplicaciones web de página única (*single-page applications*), en las que la navegación ocurre en el navegador sin recargar el documento completo [29]. Está organizado en componentes reutilizables que encapsulan plantilla, estilos y lógica, e incorpora de forma nativa enrutamiento, gestión de formularios, cliente HTTP e inyección de dependencias, lo que evita ensamblar esas piezas a partir de bibliotecas sueltas [30]. El resultado de su compilación es un conjunto de archivos estáticos —HTML, CSS y JavaScript— que cualquier servidor web puede entregar, sin necesidad de ejecutar código del lado del servidor para la interfaz.

4.2.3. Contenedores

Un contenedor empaqueta una aplicación junto con todas sus dependencias en una unidad aislada que se ejecuta sobre el núcleo del sistema operativo anfitrión [31]. A diferencia de una máquina virtual, no incluye un sistema operativo completo, por lo que arranca en segundos y consume una

fracción de los recursos. Su aporte principal es la reproducibilidad: la misma imagen se ejecuta de forma idéntica en la máquina de desarrollo y en el servidor de producción, lo que elimina toda una clase de fallos atribuibles a diferencias de entorno.

Los contenedores son, además, la unidad natural de despliegue de una arquitectura de microservicios: cada servicio se distribuye como una imagen propia, versionada e inmutable. Cuando el número de contenedores crece hasta volverse inmanejable manualmente, se recurre a plataformas de orquestación que automatizan su ciclo de vida, la recuperación ante fallos y el escalamiento [32]; a escalas menores, esa administración puede resolverse con guiones de despliegue, opción suficiente cuando el número de servicios es reducido y el equipo pequeño.

4.2.4. Proxy inverso

Un proxy inverso es un servidor que se coloca frente a uno o varios servicios y recibe en su nombre todas las peticiones del exterior, para después reenviarlas al componente que corresponda según la ruta solicitada [33]. Concentra en un solo punto responsabilidades que de otro modo habría que replicar en cada servicio: terminación de conexiones cifradas, balanceo de carga, entrega de contenido estático y control del tráfico entrante [34].

Su papel es doble en una aplicación web moderna. Por un lado entrega los archivos estáticos que componen la interfaz; por otro, enruta las peticiones dirigidas a la API hacia el servicio correspondiente. Desde el punto de vista del navegador todo proviene de un mismo origen, lo que simplifica el modelo de seguridad del cliente, mientras que del lado del servidor la separación en servicios permanece intacta.

4.2.5. Control de versiones

Git es un sistema de control de versiones distribuido que registra el historial completo de cambios de un proyecto y permite que varias personas trabajen en paralelo sobre la misma base de código mediante ramas que después se integran [35]. Su modelo distribuido implica que cada copia del repositorio contiene el historial íntegro, lo que aporta redundancia y permite trabajar sin conexión permanente al servidor central [36].

4.3. Seguridad aplicada al software

Una plataforma que administra denuncias maneja, por definición, información sensible: identifica a quien denuncia, a quien es denunciado y describe hechos que pueden tener consecuencias disciplinarias o jurídicas. Los mecanismos de esta sección son, por ello, requisitos del sistema y no características opcionales.

4.3.1. Autenticación basada en tokens

En una arquitectura distribuida, mantener la sesión del usuario en la memoria del servidor obliga a que todas sus peticiones lleguen siempre a la misma instancia, lo que limita el escalamiento horizontal. La alternativa es la autenticación basada en tokens: el servicio de autenticación verifica

las credenciales una sola vez y emite un token firmado que el cliente adjunta en cada petición posterior.

JSON Web Token (JWT) es el formato más extendido para ello. Se compone de tres partes —encabezado, carga útil y firma— codificadas y separadas por puntos. La carga útil contiene afirmaciones sobre el usuario, como su identidad, su rol y la fecha de expiración del token; la firma, calculada con una clave secreta, permite a cualquier servicio que la conozca verificar que el contenido no fue alterado [37]. Su propiedad más útil en un sistema distribuido es que la validación es local: un servicio puede autorizar una petición sin consultar al servicio emisor ni mantener estado de sesión compartido.

Esa misma propiedad tiene un costo: al ser autocontenido, un token válido no puede revocarse antes de su expiración sin introducir un mecanismo adicional de listas de revocación. De ahí que se recomiende emitirlos con tiempos de vida cortos.

4.3.2. Almacenamiento seguro de contraseñas

Las contraseñas nunca deben almacenarse en texto plano ni cifradas de forma reversible, pues quien obtenga acceso a la base de datos obtendría también las credenciales de todos los usuarios. La práctica correcta es guardar el resultado de una función resumen (*hash*) diseñada específicamente para este fin, que sea deliberadamente costosa de calcular y que incorpore un valor aleatorio distinto por usuario (*salt*), de modo que dos usuarios con la misma contraseña produzcan resúmenes diferentes y no puedan emplearse tablas precalculadas para revertirlos. La verificación en el inicio de sesión no consiste entonces en descifrar el valor almacenado, sino en recalcular el resumen de la contraseña recibida y compararlo con el registrado.

4.3.3. Control de acceso basado en roles

La autenticación resuelve quién es el usuario; la autorización, qué le está permitido hacer. El control de acceso basado en roles asigna a cada usuario uno o varios roles y asocia los permisos a esos roles y no a las personas, lo que simplifica la administración y reduce el riesgo de conceder privilegios por olvido. Debe aplicarse siguiendo el principio de menor privilegio: cada rol recibe únicamente los permisos indispensables para su función, y cada punto de acceso declara de forma explícita qué rol puede invocarlo. En una defensoría, esa distinción es también organizativa: quien recibe una queja no debe poder emitir una resolución, ni al contrario.

4.3.4. Intercambio de recursos entre orígenes

Los navegadores aplican la política de mismo origen, que impide a una página consultar recursos alojados en un dominio, protocolo o puerto distinto del suyo. El mecanismo CORS (*Cross-Origin Resource Sharing*) permite relajar esa restricción de forma controlada mediante encabezados HTTP con que el servidor declara qué orígenes acepta. La recomendación es enumerar explícitamente los orígenes permitidos en vez de autorizar cualquiera, y tener presente que el uso de un proxy inverso que sirva la interfaz y la API bajo un mismo dominio hace que el navegador ni siquiera active esta verificación.

4.3.5. Cifrado en tránsito

Toda la información que viaja entre el navegador y el servidor debe protegerse con TLS (*Transport Layer Security*), protocolo que establece un canal cifrado y autenticado sobre una conexión de red no confiable. Su versión 1.3 simplificó el proceso de negociación, redujo la latencia de establecimiento de la conexión y eliminó los algoritmos criptográficos considerados inseguros en versiones previas [38]. Sin este cifrado, las credenciales, los tokens de sesión y el contenido íntegro de una denuncia viajarían legibles para cualquier intermediario de la red.

4.4. Fundamentos de Procesamiento de Lenguaje Natural

El Procesamiento de Lenguaje Natural (PLN) es una rama de la inteligencia artificial que estudia los métodos mediante los cuales las computadoras pueden analizar, interpretar y generar información expresada en lenguaje humano [39]. Sus aplicaciones incluyen la recuperación de información, el análisis de documentos y la generación automática de resúmenes, tareas que requieren procesar el contenido lingüístico de los textos.

Una de las principales dificultades del PLN es la naturaleza ambigua y contextual del lenguaje. Una misma idea puede expresarse mediante palabras diferentes, mientras que expresiones similares pueden adquirir significados distintos según las circunstancias en las que se utilizan. Por ello, el procesamiento computacional debe considerar tanto las características lingüísticas del texto como las relaciones semánticas que permiten interpretar su contenido.

En el contexto de la Defensoría de los Derechos Politécnicos (DDP), las quejas se presentan mediante narrativas que pueden variar en extensión, estructura y vocabulario. Estas características hacen necesario emplear técnicas que permitan representar su contenido, establecer relaciones entre documentos y procesar la información descrita. Los fundamentos de estas técnicas comprenden el preprocesamiento lingüístico y la representación vectorial del texto, que se desarrollan a continuación.

4.4.1. Preprocesamiento de textos

El preprocesamiento consiste en preparar el contenido textual para su análisis mediante técnicas computacionales. Su propósito es identificar las unidades lingüísticas relevantes y, cuando resulta necesario, reducir variaciones que puedan dificultar la comparación entre documentos. Entre las operaciones más utilizadas se encuentran la tokenización, la lematización y el tratamiento de palabras vacías [39].

Tokenización. La tokenización divide un texto en unidades denominadas *tokens*, que pueden corresponder a palabras, signos de puntuación u otros elementos lingüísticos. Esta operación permite identificar los componentes de una oración para su posterior análisis.

Por ejemplo, la expresión “El profesor negó el acceso” puede dividirse en los siguientes tokens:

[`El`, `profesor`, `negó`, `el`, `acceso`]

Lematización. La lematización consiste en reducir las palabras a su forma canónica o lema, considerando sus características morfológicas. Esta transformación permite relacionar distintas formas de una misma palabra y disminuir las variaciones presentes en los documentos [39].

Por ejemplo:

$$\texttt{negaron} \rightarrow \texttt{negar}$$

$$\texttt{estudiantes} \rightarrow \texttt{estudiante}$$

Tratamiento de palabras vacías. Las palabras vacías, conocidas como *stop words*, son términos frecuentes que, dependiendo de la tarea, pueden aportar poca información para distinguir documentos. Entre ellas se encuentran determinados artículos, preposiciones y conjunciones.

Sin embargo, su eliminación debe realizarse cuidadosamente, ya que expresiones como "no", "sin" y "nunca" pueden modificar el significado de los acontecimientos descritos en una queja. Por esta razón, el preprocesamiento debe considerar las características del contenido y los requisitos del modelo utilizado.

Estas operaciones constituyen herramientas para preparar los textos, aunque no necesariamente deben aplicarse todas ni en el mismo orden. Su selección depende del método de representación y del tipo de análisis que se pretende realizar.

4.4.2. Representación vectorial del texto

La representación vectorial permite transformar documentos escritos en estructuras numéricas que pueden procesarse mediante algoritmos computacionales. Cada texto se representa mediante un vector cuyas dimensiones contienen información sobre sus características lingüísticas o semánticas. Esta transformación constituye el fundamento de los métodos que comparan documentos y recuperan información relacionada [40].

Las técnicas de representación textual pueden distinguirse entre enfoques estadísticos, que consideran principalmente la presencia y frecuencia de términos, y enfoques basados en *embeddings*, que buscan representar relaciones semánticas entre palabras, oraciones o documentos.

Bolsa de palabras y TF-IDF. El modelo de bolsa de palabras, conocido como *Bag of Words* (BoW), representa un documento mediante la frecuencia de aparición de sus términos, sin considerar el orden en el que se presentan. Aunque permite comparar documentos a partir de su vocabulario, no representa directamente las relaciones de significado entre las palabras [40].

Una extensión de este enfoque es TF-IDF (*Term Frequency–Inverse Document Frequency*), que asigna un peso a cada término considerando su frecuencia dentro de un documento y su presencia en el conjunto de documentos.

Su expresión general es:

$$\text{tf-idf}(t,d,D) = \text{tf}(t,d) \times \text{idf}(t,D) \tag{4.1}$$

donde t representa un término, d un documento y D el conjunto de documentos. El componente TF mide la frecuencia del término dentro del documento, mientras que IDF reduce la importancia de los términos que aparecen en numerosos documentos [40].

TF-IDF resulta útil para identificar coincidencias léxicas entre textos. Sin embargo, presenta limitaciones cuando dos documentos describen acontecimientos similares utilizando vocabulario diferente. Esta característica motiva el uso de representaciones capaces de incorporar información semántica.

Embeddings de palabras. Los *word embeddings* representan palabras mediante vectores numéricos densos, obtenidos a partir de patrones de uso observados durante el entrenamiento de modelos lingüísticos. Su fundamento consiste en que las palabras utilizadas en contextos semejantes pueden adquirir representaciones cercanas dentro de un espacio vectorial [41].

A diferencia de los modelos basados únicamente en frecuencias, estas representaciones permiten establecer relaciones entre términos que no necesariamente comparten la misma escritura. Por ejemplo, palabras como "hostigamiento" y "acoso" pueden presentar proximidad en el espacio vectorial debido a sus relaciones semánticas.

Herramientas como spaCy proporcionan modelos lingüísticos que incluyen representaciones vectoriales y funcionalidades para el procesamiento de textos [42]. No obstante, los embeddings estáticos presentan limitaciones para distinguir los diferentes significados que una palabra puede adquirir según el contexto.

Embeddings contextuales. Los *embeddings* contextuales generan representaciones que consideran las relaciones entre las palabras de una secuencia. Estos enfoques permiten incorporar información del contexto y representar oraciones o documentos mediante vectores que reflejan características de su contenido semántico.

Sentence-BERT (SBERT) es una propuesta basada en la arquitectura Transformer que permite obtener representaciones vectoriales de oraciones y compararlas mediante medidas de similitud [43]. Esta capacidad resulta especialmente útil en tareas de recuperación de información, donde es necesario identificar textos relacionados aunque utilicen expresiones diferentes.

En la gestión de quejas, las representaciones semánticas permiten comparar las narrativas de distintos expedientes a partir de su contenido. Sin embargo, una representación cercana no implica necesariamente que los documentos describan el mismo acontecimiento, por lo que sus relaciones deben interpretarse considerando el contexto de cada caso.

4.4.3. Modelos codificadores: Sentence Transformers y MiniLM

Los modelos basados en la arquitectura *Transformer* pueden utilizarse como codificadores (*encoders*) para transformar secuencias de texto en representaciones numéricas. A diferencia de los métodos que representan los documentos únicamente a partir de la frecuencia de sus términos, estos modelos incorporan relaciones contextuales aprendidas durante su entrenamiento [44].

La arquitectura *Sentence-BERT* (SBERT) adapta modelos Transformer para producir *embeddings* de oraciones comparables mediante medidas como la similitud coseno. Su empleo en recuperación semántica permite obtener representaciones de consultas y documentos para identificar cercanía de

significado sin comparar cada par de textos con un modelo de clasificación [43].

MiniLM es una familia de modelos Transformer compactos obtenidos mediante técnicas de destilación de conocimiento, orientadas a conservar parte de la capacidad de representación de modelos más grandes con menor costo de inferencia [45]. Algunas variantes multilingües disponibles mediante *Sentence Transformers* permiten representar textos escritos en distintos idiomas. En una tarea de recuperación documental, estos codificadores proporcionan señales semánticas complementarias a los métodos léxicos.

Es importante distinguir los codificadores de los modelos generativos: los primeros se utilizan aquí para obtener representaciones vectoriales y comparar textos, mientras que los segundos producen nuevas secuencias de lenguaje. La cercanía entre *embeddings* no demuestra por sí sola que dos expedientes describan idénticos hechos.

4.4.4. Similitud coseno

La similitud coseno es una medida matemática utilizada para comparar la orientación de dos vectores en un espacio multidimensional. Se calcula mediante el producto punto de ambos vectores dividido entre el producto de sus normas, lo que permite estimar su proximidad angular independientemente de sus magnitudes [40].

Para dos vectores no nulos $\mathbf{u}$ y $\mathbf{v}$, la similitud coseno se define como:

$$\text{sim}(\mathbf{u},\mathbf{v}) = \frac{\mathbf{u}\cdot\mathbf{v}}{\|\mathbf{u}\|\|\mathbf{v}\|} = \frac{\sum_{i=1}^{d} u_i v_i}{\sqrt{\sum_{i=1}^{d} u_i^2}\sqrt{\sum_{i=1}^{d} v_i^2}} \tag{4.2}$$

donde d representa el número de dimensiones de los vectores. Su resultado se encuentra en el intervalo $[-1,1]$, y los valores cercanos a 1 indican una mayor proximidad en la dirección de las representaciones.

En la comparación de documentos, esta medida permite ordenar los textos de acuerdo con su similitud vectorial. Cuando se aplica sobre embeddings semánticos, puede utilizarse para recuperar narrativas relacionadas, incluso cuando presentan diferencias en su redacción.

No obstante, la similitud coseno mide proximidad entre representaciones y no verifica por sí misma la identidad de los hechos descritos. Por tanto, su utilización en la búsqueda de antecedentes permite identificar coincidencias relevantes, pero no constituye una confirmación automática de duplicidad.

4.5. Búsqueda de antecedentes y detección de posibles duplicidades

La búsqueda de antecedentes consiste en localizar documentos previamente registrados que mantienen alguna relación con una nueva solicitud. En la gestión de quejas, esta actividad permite consultar expedientes que presentan semejanzas en los hechos descritos, las circunstancias o las personas involucradas. Su propósito es facilitar el acceso a información relevante para la revisión

de los casos, sin establecer automáticamente que los documentos recuperados corresponden a una misma situación.

La identificación de posibles duplicidades constituye una tarea relacionada, pero distinta de la recuperación de antecedentes. Mientras que la primera busca reconocer solicitudes que podrían referirse a hechos previamente reportados, la segunda permite localizar documentos relacionados, aunque correspondan a acontecimientos diferentes. Ambas tareas requieren mecanismos de recuperación y comparación de información textual.

4.5.1. Recuperación de información

La recuperación de información es el proceso mediante el cual se identifican documentos relevantes dentro de una colección a partir de una consulta. Su funcionamiento comprende la organización de los documentos disponibles, el procesamiento de la consulta y la aplicación de criterios que permitan determinar cuáles registros presentan mayor relación con la información solicitada [40].

En los sistemas de recuperación textual, los documentos pueden representarse mediante índices que facilitan su búsqueda sin necesidad de examinar manualmente toda la colección. A partir de estos índices, se calculan medidas de relevancia que permiten ordenar los resultados y presentar primero aquellos que mantienen una mayor relación con la consulta.

En el contexto de la DDP, una queja puede utilizarse como consulta para recuperar expedientes previamente registrados. De esta manera, el proceso de recuperación permite identificar antecedentes potencialmente relacionados con los hechos descritos y proporciona referencias documentales para su posterior revisión.

4.5.2. Similitud léxica y semántica

La similitud textual permite establecer el grado de relación entre dos documentos a partir de sus características lingüísticas. Los métodos de comparación pueden distinguirse entre enfoques léxicos, que consideran las coincidencias de términos, y enfoques semánticos, que buscan identificar relaciones de significado entre los textos [40].

La similitud léxica se fundamenta en la presencia de palabras o expresiones compartidas entre documentos. Técnicas como TF-IDF permiten representar estas coincidencias mediante valores numéricos y determinar qué términos resultan relevantes dentro de una colección. Este enfoque es útil cuando los documentos utilizan vocabulario semejante, aunque presenta limitaciones ante diferencias de redacción, sinónimos o expresiones equivalentes.

Por su parte, la similitud semántica busca establecer relaciones entre documentos considerando su contenido y no únicamente las palabras utilizadas. Para ello, pueden emplearse modelos de representación contextual que generan vectores asociados con el significado de las oraciones o documentos [43]. Esto permite recuperar textos relacionados incluso cuando presentan diferencias en su vocabulario.

Por ejemplo, las expresiones “el profesor me impidió presentar el examen” y “el docente no me permitió realizar la evaluación” contienen diferencias léxicas, pero describen situaciones semejantes. Un enfoque basado exclusivamente en coincidencias de palabras podría asignarles una relación menor que un método capaz de considerar su proximidad semántica.

La combinación de ambos enfoques puede resultar útil en sistemas de recuperación, debido a que las coincidencias léxicas permiten reconocer términos específicos, mientras que las representaciones semánticas facilitan la identificación de relaciones expresadas mediante vocabulario diferente. Su utilización depende de las características de los documentos y de los criterios establecidos para la recuperación.

4.5.3. Fragmentación de documentos para recuperación semántica

Los documentos extensos pueden contener hechos diferentes a lo largo de una misma narración. Representarlos mediante un único vector puede dificultar la recuperación de pasajes específicos; además, los modelos codificadores suelen tener límites de longitud para sus entradas. La *fragmentación* (*chunking*) divide el documento en segmentos más pequeños que pueden representarse y compararse de manera individual.

Una estrategia habitual consiste en definir un tamaño máximo de segmento y un solapamiento entre segmentos consecutivos. El solapamiento conserva parte del contexto en los límites de cada fragmento y reduce la posibilidad de separar expresiones que necesitan interpretarse juntas. No obstante, un solapamiento excesivo incrementa el número de representaciones que deben almacenarse y procesarse.

En la recuperación documental, las puntuaciones de los fragmentos pueden agregarse o utilizarse para determinar la relevancia del documento al que pertenecen. Es necesario conservar la asociación entre fragmento y expediente, evitando presentar un mismo documento como varios antecedentes independientes. El tamaño y el solapamiento constituyen parámetros de diseño que deben justificarse en la implementación y contrastarse durante la evaluación.

4.5.4. Recuperación híbrida y fusión de rankings

La *recuperación híbrida* combina mecanismos de búsqueda que utilizan señales distintas, por ejemplo coincidencia léxica de términos y similitud semántica entre representaciones vectoriales. Cada recuperador puede producir una lista de documentos ordenados por su propio criterio de relevancia. Estas puntuaciones no necesariamente comparten escala ni distribución, por lo que sumarlas directamente sin calibración puede producir resultados poco interpretables.

Reciprocal Rank Fusion (RRF) es un método de fusión que utiliza la posición de cada documento dentro de los rankings de entrada en lugar de sumar sus puntuaciones originales [46]. Para dos recuperadores, una extensión ponderada puede expresarse como:

$$\mathrm{RRF}(d) = \frac{w_L}{k_0 + r_L(d)} + \frac{w_S}{k_0 + r_S(d)}, \tag{4.3}$$

donde d es un documento, $r_L(d)$ y $r_S(d)$ son sus posiciones en las listas léxica y semántica, w_L y w_S son sus ponderaciones no negativas y k_0 es una constante de suavizado positiva. Cuando un documento no aparece entre los resultados considerados de un recuperador, su contribución correspondiente se toma como cero.

La ponderación permite privilegiar una señal sin descartar la otra. Sin embargo, no existe una proporción universalmente óptima: los pesos deben seleccionarse con base en consultas representativas, juicios de relevancia y métricas de recuperación. La fusión de rankings sirve para ordenar

antecedentes; su puntuación no debe interpretarse automáticamente como una probabilidad de duplicidad ni como un porcentaje calibrado de similitud.

4.5.5. Indexación y reutilización de representaciones semánticas

Un índice de recuperación semántica almacena representaciones vectoriales de documentos o fragmentos para evitar calcularlas nuevamente durante cada consulta. Cuando la colección se actualiza, una reconstrucción completa puede resultar costosa, especialmente si la codificación se realiza sobre CPU. La indexación incremental busca reutilizar las representaciones de los registros que no cambiaron y procesar únicamente los documentos nuevos o modificados.

Para determinar si un vector es reutilizable, resulta útil asociarlo con una huella del contenido y con la identificación de la configuración del modelo que lo produjo. Si el texto, el modelo o las reglas de fragmentación cambian, la representación anterior podría dejar de ser válida. La persistencia de los vectores permite conservar el trabajo realizado entre reinicios y actualizaciones. El mecanismo específico de almacenamiento y sus parámetros corresponden a las decisiones de implementación del sistema.

4.5.6. Identificación de documentos relacionados

La identificación de documentos relacionados consiste en analizar los resultados de recuperación para reconocer registros que comparten información relevante con una consulta. Esta relación puede establecerse mediante semejanzas en las narrativas, coincidencias de términos específicos o características comunes de los acontecimientos descritos.

En la gestión de quejas, los documentos relacionados pueden corresponder a antecedentes de una situación, solicitudes que involucran a una misma persona o registros que describen acontecimientos semejantes. Sin embargo, estas relaciones no son equivalentes entre sí, ya que dos expedientes pueden compartir elementos sin referirse necesariamente a los mismos hechos.

La detección de posibles duplicidades requiere una consideración adicional: determinar si diferentes solicitudes podrían corresponder a un acontecimiento previamente registrado. Para ello, la similitud textual constituye un criterio de apoyo, pero no una prueba suficiente, debido a que una misma situación puede describirse de distintas maneras y diferentes acontecimientos pueden presentar narrativas similares.

Por tanto, los resultados de recuperación deben interpretarse como coincidencias potencialmente relevantes que requieren revisión. Esta distinción permite utilizar las técnicas de comparación documental sin atribuirles capacidades de verificación que exceden el análisis del contenido textual.

4.5.7. Evaluación de recuperación de antecedentes

La evaluación de un sistema de recuperación de información permite determinar qué tan adecuadamente identifica documentos relevantes a partir de una consulta. Para ello, se requiere un conjunto de referencia en el que se conozca qué documentos deben considerarse relevantes, de manera que los resultados obtenidos puedan compararse con las relaciones esperadas [40].

Entre las métricas utilizadas para evaluar sistemas de recuperación se encuentran la precisión y la exhaustividad en los primeros k resultados, representadas mediante P_k y R_k, respectivamente.

La precisión en los primeros k resultados se define como:

$$P_k = \frac{\text{Documentos relevantes recuperados en los primeros } k}{k} \tag{4.4}$$

Esta métrica indica qué proporción de los documentos presentados en las primeras posiciones resulta relevante para la consulta.

Por su parte, la exhaustividad en los primeros k resultados se expresa como:

$$R_k = \frac{\text{Documentos relevantes recuperados en los primeros } k}{\text{Total de documentos relevantes}} \tag{4.5}$$

Esta medida permite conocer qué proporción de los documentos relevantes disponibles se encuentra entre los primeros resultados recuperados.

Ambas métricas ofrecen perspectivas complementarias sobre el funcionamiento de un sistema de búsqueda. Mientras que precisión (P_k) permite valorar la pertinencia de los resultados presentados, recall (R_k) permite identificar la capacidad del sistema para recuperar los antecedentes relevantes existentes en la colección.

En la búsqueda de antecedentes de la DDP, estas medidas pueden utilizarse para evaluar la recuperación de expedientes relacionados, siempre que se disponga de referencias previamente verificadas. La selección de las métricas y los valores de k debe corresponder a los objetivos y condiciones de evaluación establecidos para el modelo.

4.5.8. Métricas de ordenamiento y evaluación experimental

Además de la precisión y la exhaustividad en las primeras k posiciones, los sistemas de recuperación pueden evaluarse con métricas sensibles al orden de aparición de los resultados. El *Mean Reciprocal Rank* (MRR) resume la posición del primer documento relevante en un conjunto de consultas:

$$\text{MRR} = \frac{1}{|Q|} \sum_{q \in Q} \frac{1}{\text{rank}_q}, \tag{4.6}$$

donde Q es el conjunto de consultas y rank_q es la posición del primer documento relevante para q; las consultas sin documentos relevantes recuperados aportan cero. Por su parte, *Normalized Discounted Cumulative Gain* (nDCG) evalúa la calidad del ordenamiento al descontar la contribución de los resultados que aparecen más abajo en la lista y normalizarla respecto al orden ideal [47]. En su forma habitual:

$$\text{nDCG}\,@k = \frac{\displaystyle\sum_{i=1}^{k} \frac{2^{\text{rel}_i} - 1}{\log_2(i+1)}}{\text{IDCG}\,@k}, \tag{4.7}$$

donde rel_i indica la relevancia asignada al resultado de la posición i, e IDCG $@k$ es el valor que se obtendría con el ordenamiento ideal. Si el denominador es cero, debe establecerse una convención explícita para esa consulta.

La comparación de configuraciones de un recuperador requiere consultas con etiquetas de relevancia, un criterio de evaluación predefinido y una separación entre los datos utilizados para seleccionar parámetros y los reservados para la evaluación final. Cuando distintas consultas derivan de un mismo expediente o escenario, conviene mantenerlas en un mismo grupo para reducir la fuga de información. Los resultados obtenidos con quejas sintéticas constituyen evidencia experimental acotada y no sustituyen la validación con casos representativos de operación institucional. La selección de parámetros y la evaluación final deben distinguirse para evitar que una misma colección se utilice tanto para ajustar el recuperador como para estimar su desempeño sin sesgos.

4.6. Generación automática de resúmenes

La generación automática de resúmenes es una tarea del Procesamiento de Lenguaje Natural que consiste en producir una versión más breve de un documento, conservando la información necesaria para comprender su contenido. Su propósito es reducir la extensión del texto sin perder los elementos esenciales que permiten interpretar el mensaje original [39].

Esta tarea resulta especialmente relevante cuando se trabaja con documentos extensos que contienen información narrativa. En estos casos, un resumen permite identificar los acontecimientos principales, las circunstancias descritas y las relaciones entre los hechos, sin necesidad de revisar inicialmente la totalidad del documento.

En el contexto de la DDP, las quejas pueden contener descripciones extensas de acontecimientos, antecedentes y circunstancias particulares. La generación automática de resúmenes puede facilitar una primera revisión del contenido y apoyar la consulta de los expedientes. Sin embargo, el resumen generado no sustituye el documento original ni la valoración realizada por el personal responsable.

4.6.1. Resumen extractivo y abstractivo

Los métodos de generación automática de resúmenes pueden clasificarse principalmente en extractivos y abstractivos, de acuerdo con la manera en que construyen el texto resultante [39].

El resumen extractivo consiste en seleccionar fragmentos del documento original que contienen información considerada relevante. Estos fragmentos, generalmente oraciones completas, se organizan para construir una versión reducida del texto. Su principal característica es que conserva las expresiones utilizadas en el documento de origen.

Por ejemplo, si una queja contiene varias oraciones que describen un acontecimiento, un método extractivo puede seleccionar aquellas que proporcionan mayor información sobre los hechos, omitiendo detalles repetitivos o secundarios.

Por su parte, el resumen abstractivo genera una nueva redacción a partir de la información identificada en el documento. A diferencia del enfoque extractivo, no se limita a copiar fragmentos, sino que puede reformular oraciones, integrar información relacionada y producir expresiones que no aparecen literalmente en el texto original.

Esta capacidad permite construir resúmenes narrativos más cohesionados. No obstante, también

introduce el riesgo de generar afirmaciones que no se encuentran respaldadas por el documento de origen.

Para la gestión de quejas, esta distinción resulta importante debido a que la claridad del resumen debe mantenerse subordinada a la conservación de los hechos descritos por la persona que presenta la solicitud.

4.6.2. Selección extractiva mediante Maximum Marginal Relevance

La selección extractiva de oraciones puede producir resúmenes redundantes cuando varios fragmentos expresan información semejante. *Maximum Marginal Relevance* (MMR) es un criterio que busca equilibrar la relevancia de una unidad respecto al documento o consulta y su novedad frente a las unidades ya seleccionadas [48].

Una formulación habitual escoge iterativamente la unidad s que maximiza:

$$\mathrm{MMR}(s) = \lambda\ \mathrm{Sim}(s,q) - (1-\lambda) \max_{s' \in S} \mathrm{Sim}(s,s'), \tag{4.8}$$

donde q representa el texto o consulta de referencia, S es el conjunto de unidades seleccionadas y $\lambda \in [0,1]$ regula el equilibrio entre relevancia y redundancia. Para la primera selección, cuando S está vacío, el término de redundancia se considera nulo.

En textos narrativos, MMR proporciona una base para elegir fragmentos informativos sin repetir innecesariamente el mismo contenido. Sin embargo, no garantiza por sí solo la conservación de fechas, negaciones, actores, consecuencias o relaciones cronológicas. Por ese motivo, puede complementarse con reglas de cobertura y coherencia contextual. La selección extractiva y la edición lingüística posterior deben tratarse como etapas separadas, ya que cada una introduce riesgos y criterios de evaluación diferentes.

4.6.3. Modelos de lenguaje basados en Transformers

Los modelos de lenguaje son sistemas computacionales diseñados para procesar y generar secuencias de texto mediante el aprendizaje de patrones lingüísticos. Sus aplicaciones incluyen la comprensión de documentos, la generación de respuestas y la elaboración automática de resúmenes [39].

Los Transformers son una arquitectura de redes neuronales diseñada para procesar secuencias de información, como las palabras que componen un texto. Fueron propuestos por Vaswani y colaboradores en 2017 y se caracterizan por utilizar mecanismos de atención para identificar relaciones entre los elementos de una secuencia [44].

A diferencia de las arquitecturas recurrentes, que procesan la información siguiendo una secuencia de estados, los Transformers permiten analizar las relaciones entre diferentes posiciones del texto mediante mecanismos de atención. Esto facilita la representación del contexto y permite procesar múltiples elementos de una secuencia en paralelo [44].

Uno de sus componentes principales es el mecanismo de autoatención (*self-attention*), mediante el cual el modelo calcula la importancia relativa de las palabras de una secuencia respecto de otras.

De esta manera, puede establecer relaciones entre elementos que se encuentran separados dentro del documento y construir representaciones que consideran su contexto.

Los modelos de lenguaje basados en Transformers pueden utilizarse para desarrollar sistemas de resumen abstractivo. A partir de un documento de entrada, estos modelos generan una secuencia de texto que busca representar su contenido principal mediante una redacción más breve y organizada.

Sin embargo, la capacidad de generar lenguaje coherente no garantiza que todas las afirmaciones producidas correspondan fielmente al documento original. Por ello, la utilización de estos modelos requiere considerar mecanismos de evaluación y revisión de los resultados.

4.6.4. Generación autoregresiva y cuantización de modelos de lenguaje

Los modelos de lenguaje generativos de tipo *decoder* producen texto de manera autoregresiva: predicen el siguiente token condicionado por los anteriores y repiten el procedimiento hasta completar la salida. Aunque el procesamiento de una entrada utiliza operaciones paralelizables, los tokens de salida se generan secuencialmente, de modo que la longitud de la respuesta influye en el tiempo total de inferencia.

Estos modelos pueden recibir instrucciones que establecen el propósito, el estilo y las restricciones del texto generado. En una tarea de redacción institucional, es posible solicitar la transformación de fragmentos a tercera persona y pedir que se conserven negaciones, actores y datos explícitos. No obstante, las instrucciones no constituyen una garantía formal de fidelidad factual, por lo que deben complementarse con evaluación y revisión.

La *cuantización* reduce la precisión numérica utilizada para almacenar parte de los parámetros de una red neuronal, con el objetivo de disminuir su consumo de memoria y, según el hardware y la implementación, facilitar la ejecución de la inferencia. La reducción de precisión también puede modificar la calidad de los resultados, por lo que representa un compromiso entre recursos y comportamiento del modelo. En entornos con CPU y memoria limitadas, la cuantización, el tamaño de contexto, la concurrencia y el número de tokens generados son factores relevantes para el diseño operativo del servicio.

4.6.5. Fidelidad y consistencia factual

La fidelidad factual es una propiedad fundamental de los resúmenes automáticos y se refiere a la correspondencia entre las afirmaciones del resumen y la información contenida en el documento original.

Un resumen puede presentar una redacción clara y gramaticalmente correcta sin representar adecuadamente los acontecimientos descritos. Esto ocurre cuando se incorporan datos inexistentes, se modifican relaciones entre los hechos o se omiten elementos necesarios para comprender una situación.

En los modelos generativos, la producción de información que no está respaldada por el documento de entrada se conoce comúnmente como alucinación. Este fenómeno representa una limitación importante en aplicaciones donde la exactitud del contenido resulta esencial.

En el contexto de las quejas, las alteraciones pueden afectar aspectos como las personas involucradas, las fechas, las acciones atribuidas a cada participante o la secuencia de los acontecimientos.

Por ejemplo, modificar quién realizó una acción puede cambiar sustancialmente el significado de la narrativa.

La fidelidad de un resumen requiere, por tanto, preservar las afirmaciones relevantes y evitar incorporar interpretaciones que excedan la información proporcionada. Asimismo, es necesario distinguir entre reducir la extensión del documento y eliminar información que resulta indispensable para comprender los hechos.

En consecuencia, los resúmenes generados deben considerarse herramientas de apoyo documental, sujetas a revisión humana cuando se utilicen en procesos institucionales.

4.6.6. Evaluación de resúmenes generados

La evaluación de resúmenes automáticos busca determinar en qué medida el texto generado conserva la información relevante del documento original y presenta una redacción comprensible.

Entre los aspectos que pueden considerarse se encuentran la cobertura de los hechos principales, la fidelidad factual, la ausencia de información inventada, la coherencia narrativa y la claridad del texto.

Una estrategia de evaluación consiste en comparar el resumen generado con un resumen de referencia elaborado o validado previamente. Esta comparación permite analizar si el sistema recupera los elementos informativos esperados, aunque la existencia de diferentes formas válidas de resumir un documento puede dificultar la evaluación automática.

Por esta razón, las medidas basadas únicamente en coincidencias textuales no son suficientes para determinar la calidad integral de un resumen. Dos textos pueden utilizar expresiones diferentes y conservar los mismos hechos, mientras que una redacción similar puede contener alteraciones importantes en su significado.

En un sistema que combina selección extractiva y edición generativa conviene evaluar por separado la cobertura de hechos de la captura extractiva y la fidelidad de la reescritura respecto a esa captura, además de contrastar el resultado final con la queja original. Esta comparación por etapas permite identificar si una omisión se originó durante la selección o durante la generación del texto.

La revisión humana permite complementar la evaluación automática mediante la identificación de errores factuales, omisiones relevantes y problemas de interpretación. En documentos que describen posibles vulneraciones de derechos, esta revisión adquiere especial importancia debido a las consecuencias que puede tener una representación incorrecta de los acontecimientos.

Para la DDP, la evaluación de los resúmenes debe considerar tanto su utilidad para facilitar la lectura de las quejas como su capacidad para conservar la información necesaria para comprender cada caso. El resultado debe interpretarse como una síntesis de apoyo y no como una sustitución del expediente original.

Capítulo 5

Análisis y Diseño

Este capítulo documenta el análisis y el diseño de la plataforma tal como quedó definida al cierre de esta etapa del Trabajo Terminal. Su propósito es dejar constancia de *qué* se construyó y, sobre todo, de *por qué* se construyó de esa manera: los requerimientos que se levantaron con la Defensoría, los actores que intervienen, los casos de uso que delimitan el alcance funcional, la arquitectura que soporta la solución y el modelo de datos que la sustenta. La construcción concreta de cada componente —el código, el despliegue y las pruebas— se documenta en el Capítulo 6, y el recorrido funcional de cada módulo entregado en el Capítulo 7.

Los artefactos que aquí se presentan siguen el orden en que fueron producidos: primero el levantamiento de requerimientos con el cliente, del que se derivaron los casos de uso; después el modelo de estados del expediente, que ordena el flujo de trabajo; sobre esa base la arquitectura de componentes y el modelo de datos; y por último las decisiones de diseño con las alternativas que se descartaron en cada punto. Este orden no es una convención editorial: cada artefacto es insumo del siguiente, y esa dependencia es la que sostiene la coherencia técnica del sistema.

5.1. Descripción general de la solución

La solución es una plataforma web para la gestión digital de quejas y denuncias ante la Defensoría de los Derechos Politécnicos. Permite a cualquier integrante de la comunidad politécnica presentar una queja y darle seguimiento —con o sin cuenta de usuario— y provee al personal de la Defensoría las herramientas para recibirla, validarla, canalizarla y administrar la operación técnica del sistema.

La solución se organiza en servicios de negocio implementados principalmente con Spring Boot, componentes de procesamiento de lenguaje natural implementados en Python, y aplicaciones web independientes para los distintos perfiles de uso. La información operativa de las quejas se almacena en PostgreSQL; los modelos de inteligencia artificial se comunican con el servicio de Primer Contacto mediante interfaces HTTP internas. Los componentes se despliegan en contenedores con Podman y se publican mediante un proxy inverso con acceso cifrado. Los servicios de antecedentes y de resúmenes se mantienen separados para gestionar sus recursos y cambios de forma independiente.

5.2. Actores del sistema

El análisis distingue a la persona que presenta la queja y a los perfiles institucionales que participan en su recepción, análisis, gestión y seguimiento. La organización por roles justifica aplicaciones web diferenciadas y políticas de autorización en los servicios: la separación de interfaces mejora la adaptación al trabajo de cada área, aunque no sustituye la validación de permisos en el servidor.

- **Quejoso.** Cualquier integrante de la comunidad politécnica —estudiante, personal académico o administrativo— que presenta una queja o le da seguimiento. Es el único actor externo y el único que puede operar sin credenciales previas.
- **Personal de recepción.** Personal de la Defensoría encargado de recibir, validar y canalizar las quejas que llegan por el portal público o en papel.
- **Analista de primer contacto.** Consulta expedientes, revisa antecedentes relacionados y utiliza borradores de resumen como apoyo al análisis de quejas.
- **Subdefensoría.** Gestiona las actuaciones y el seguimiento que corresponden a su área conforme a los permisos asignados.
- **Defensora.** Titular de la Defensoría. Participa en las etapas de decisión y resolución del expediente, sin que las herramientas de inteligencia artificial sustituyan sus atribuciones; supervisa la operación desde su panel y administra la plataforma: cuentas del personal, catálogos, plantillas, respaldos y bitácora de seguridad.

La Tabla 5.1 presenta los perfiles, las responsabilidades generales y las interfaces consideradas en el alcance. La presencia de un rol no implica, por sí misma, que exista un panel independiente para todas sus operaciones.

Tabla 5.1: Actores, roles e interfaces del sistema

Actor	Rol en el sistema	Responsabilidad	Interfaz
Quejoso	— (usuario externo)	Presentar quejas y darles seguimiento	Portal público del quejoso
Personal de recepción	`RECEPCIONISTA`	Recibir, validar, rechazar y turnar quejas	Panel de revisión
Analista de primer contacto	`ANALISTA_PRIMER_CONTACTO`	Análisis de expedientes y consulta de herramientas de inteligencia artificial	Módulo de Primer Contacto
Subdefensor	`SUBDEFENSOR`	Gestión y seguimiento de actuaciones de su área	Módulo de Subdefensoría
Defensora	`DEFENSOR`	Supervisión, resolución y cierre del expediente; administración de cuentas, catálogos, plantillas, respaldos y bitácora	Panel de la Defensora

Los módulos de Primer Contacto y Subdefensoría forman parte del flujo de trabajo de la plataforma. Sus permisos y servicios deben documentarse de manera coherente con la matriz de autorización y los casos de uso. Las actividades de resolución corresponden al personal institucional autorizado y no se automatizan mediante inteligencia artificial.

5.3. Especificación de requerimientos

El levantamiento de requerimientos combinó la revisión de documentación institucional de la Defensoría con reuniones de trabajo para precisar actividades, responsabilidades y necesidades de los distintos perfiles. El equipo sostuvo una serie de reuniones con el personal de la institución que evolucionaron de forma iterativa: cada sesión aclaró aspectos que la anterior había dejado abiertos, y cada avance técnico intermedio se convirtió en insumo de la siguiente reunión.

La primera sesión tuvo como objetivo comprender el contexto operativo e identificar las áreas que intervienen en la gestión de una queja. Con ese contexto el equipo elaboró un diagrama de proceso en notación BPMN a partir de los documentos oficiales, que se presentó en una segunda sesión como base de discusión. La revisión permitió aclarar el alcance y la secuencia de distintas actividades, incorporar observaciones del personal y ajustar el diagrama para representar el flujo de atención acordado para la plataforma. Validado ese diagrama, se establecieron sesiones por área para traducir las actividades de cada rol en casos de uso y vistas concretas, con sesiones de revisión intermedias para confirmar que los artefactos reflejaran lo acordado.

El resultado acumulado se organizó en tres categorías —requerimientos funcionales, no funcionales y reglas de negocio— y se estructuró por actor, de modo que cada requerimiento tiene un dueño identificable. La nomenclatura empleada codifica el actor en el identificador: `RF-Q` para los requerimientos funcionales del quejoso, `RF-R` para los del personal de recepción, `RF-PC` para los de Primer Contacto, `RF-SD` para los de Subdefensoría y `RF-A` para los de la Defensora, y de forma análoga `RNF-` y `RN-` para los no funcionales y las reglas de negocio. Para los servicios de inteligencia artificial se identifican además criterios de diseño transversales que se presentan en la Sección 5.8, sin alterar la numeración histórica de los requerimientos ya aprobados. Esta convención permite rastrear cada elemento hasta su origen.

5.3.1. Requerimientos funcionales del quejoso

Los requerimientos del quejoso se agrupan en cinco bloques: operación sin cuenta, gestión de la cuenta, gestión de las quejas propias, seguimiento y servicios de apoyo. El primer bloque es el más determinante para el diseño, porque exige que el sistema acepte quejas de personas que no tienen —ni necesariamente quieren tener— una cuenta, lo que obliga a un punto de acceso público sin autenticación y a un mecanismo de identificación posterior basado en el folio.

Tabla 5.2: Requerimientos funcionales del actor Quejoso

ID	Requerimiento	Descripción
RF-Q01	Consultar una queja sin cuenta	Dado un folio y el correo con que se presentó, mostrar el detalle de la queja: motivo, descripción, estatus y fecha.
RF-Q02	Registrar una queja sin cuenta	Capturar la identidad completa del quejoso, unidad académica, fecha de los hechos, datos del denunciado, descripción libre y varios archivos de evidencia en una sola petición; generar un folio de seguimiento.
RF-Q03	Capturar datos del tutor	Si la fecha de nacimiento indica que el quejoso es menor de edad, exigir los datos de un tutor o adulto responsable antes de permitir el envío.
RF-Q04	Activar una cuenta de seguimiento	A partir de un folio y correo ya registrados en una queja existente, definir una contraseña y activar la cuenta.
RF-Q05	Iniciar sesión	Autenticarse con correo institucional y contraseña, obteniendo un token de sesión con vigencia limitada.
RF-Q06	Recuperar la contraseña	Restablecer la contraseña mediante un código de verificación de seis dígitos enviado por correo electrónico.
RF-Q07	Consultar un resumen de actividad	Mostrar al entrar al panel el conteo de quejas propias agrupadas por estatus.
RF-Q08	Listar y consultar las quejas propias	Listar las quejas del usuario con filtros por estatus y texto, y mostrar el detalle completo de cada una con su línea de tiempo de estatus.
RF-Q09	Editar una queja propia	Modificar descripción, unidad académica, fecha de hechos y datos del denunciado, únicamente mientras la queja no haya iniciado su validación.
RF-Q10	Registrar una queja autenticado	Presentar una queja nueva desde el panel sin volver a capturar la identidad, que se toma del token de sesión.
RF-Q11	Consultar las evidencias propias	Previsualizar y descargar los archivos adjuntos a una queja propia.
RF-Q12	Responder acuerdos de conciliación	Consultar los acuerdos propuestos por la Defensoría y aceptarlos o rechazarlos, con comentario opcional.
RF-Q13	Consultar el centro de notificaciones	Consultar un historial persistente de avisos con contador de no leídas y marcado individual como leída.
RF-Q14	Consultar y editar el perfil	Editar correo personal, teléfono, unidad académica y domicilio; consultar en modo de solo lectura el nombre, el correo institucional y la boleta o número de empleado.
RF-Q15	Consultar el catálogo institucional	Seleccionar la dependencia o unidad académica involucrada desde el catálogo del Instituto, en lugar de capturarla como texto libre.
RF-Q16	Consultar preguntas frecuentes	Consultar sin sesión un menú fijo de preguntas y respuestas sobre la Defensoría y el proceso de queja.
RF-Q17	Recibir avisos por correo	Recibir confirmación de creación de cuenta, confirmación de restablecimiento de contraseña y, en el caso de menores de edad, aviso al tutor.

5.3.2. Requerimientos funcionales del personal de recepción

El diseño de este bloque partió de una restricción que el propio personal planteó en las sesiones de levantamiento: no todas las quejas llegan por el portal. Una parte del volumen ingresa en papel, y el sistema debía poder incorporarlas al mismo flujo digital sin obligar al quejoso a capturarlas de nuevo. De ahí el requerimiento de registro manual (RF-R08), que es la razón por la que el modelo de datos distingue el origen de cada queja.

Tabla 5.3: Requerimientos funcionales del actor Personal de recepción

ID	Requerimiento	Descripción
RF-R01	Iniciar sesión	Autenticarse con las credenciales de personal administrativo desde el panel de revisión.
RF-R02	Consultar la bandeja de entrada	Consultar la lista de quejas por trabajar, con contadores de pendientes, en proceso y turnadas en el día.
RF-R03	Consultar el detalle de una queja	Consultar el resumen completo del expediente y los documentos adjuntos, para su validación.
RF-R04	Buscar antecedentes	Consultar quejas anteriores potencialmente relacionadas, por hechos o personas involucradas, como apoyo para identificar antecedentes y posibles duplicidades.
RF-R05	Consultar los documentos adjuntos	Previsualizar y descargar las evidencias asociadas a una queja.
RF-R06	Rechazar una queja	Rechazar una queja por documentación incompleta, indicando motivos y observaciones, con notificación automática al quejoso.
RF-R07	Turnar una queja	Canalizar la queja a un área o dependencia y a un defensor o subdefensor específico, con comentarios, generando el folio oficial de turnado.
RF-R08	Registrar una queja recibida en papel	Dar de alta manualmente una queja física con la identidad del quejoso, dependencia, número de oficio, fecha de recepción, tipo de documento, descripción, ubicación física del expediente y un archivo digitalizado opcional.
RF-R09	Consultar el historial de trámites	Consultar los trámites ya procesados, con filtros por texto, estatus y fecha.
RF-R10	Exportar el historial	Exportar el historial filtrado a un archivo de hoja de cálculo.
RF-R11	Emitir un acuerdo de conciliación	Emitir un acuerdo dirigido al quejoso de una queja, con asunto y términos.
RF-R12	Consultar catálogos de apoyo	Consultar la lista de dependencias y la de personal disponible para turnado.
RF-R13	Cambiar la propia contraseña	Modificar la contraseña de la cuenta propia desde el panel.

5.3.3. Requerimientos funcionales de Primer Contacto

Primer Contacto es la etapa en la que se decide si la Defensoría es competente para conocer la queja. Recepción turna cada queja a un analista, y cada analista trabaja únicamente los expedientes que tiene asignados. La Tabla 5.4 reúne sus requerimientos.

Tabla 5.4: Requerimientos funcionales del actor Analista de Primer Contacto

ID	Requerimiento	Descripción
RF-PC01	Recibir quejas turnadas	Crear el expediente de análisis cuando Recepción turna una queja, con el analista asignado, su prioridad, quejoso, narración y evidencias.
RF-PC02	Consultar la bandeja de análisis	Listar los expedientes asignados al analista con filtros por folio, prioridad y estatus, e indicadores, pendientes y citas del día en un tablero de inicio.
RF-PC03	Abrir un expediente	Iniciar el análisis al abrir el expediente y presentar la narración, los datos de la queja, del quejoso y de la persona señalada, las evidencias y el historial; impedir el acceso a expedientes asignados a otro analista.
RF-PC04	Gestionar la agenda de citas	Programar citas con el quejoso y con la persona señalada (comparecencia, revisión de documentos o seguimiento; presencial o virtual) en horario hábil, sin empalmes ni fines de semana; confirmarlas, reagendarlas o cancelarlas, y avisar a la persona citada con un enlace para responder.
RF-PC05	Elaborar oficios de análisis	Redactar oficios con asunto y contenido, numerados `DDP/PC/OF/año/id`, generarlos en PDF, y editarlos o eliminarlos solo por su autor.
RF-PC06	Registrar la versión de la persona señalada	Capturar la versión que la persona señalada rinde ante el analista, con su identificación, fecha de entrevista y evidencias, dejando constancia de quién la registró.
RF-PC07	Dictaminar la competencia	Declarar la queja procedente con justificación y observaciones, elegir al abogado responsable en Subdefensoría de una lista ordenada por carga de trabajo y turnar el expediente; permitir reenviarlo si Subdefensoría no lo recibió.
RF-PC08	Dictaminar la improcedencia y remitir	Declarar la queja improcedente con justificación y remitirla a la instancia competente (Abogado General, Órgano Interno de Control o instancias del Protocolo de Género): generar el oficio en PDF, enviarlo por correo a la instancia y avisar al quejoso.
RF-PC09	Proponer una conciliación	Registrar una propuesta de conciliación desde el expediente.
RF-PC10	Asignar la prioridad	Asignar al expediente una prioridad (baja, media, alta o urgente) mientras esté abierto o, ya dictaminado procedente, antes de que Subdefensoría lo reciba.

5.3.4. Requerimientos funcionales de Subdefensoría

La Subdefensoría investiga los expedientes procedentes. Cada abogado trabaja los expedientes que le asignó Primer Contacto, mientras que el titular de la Defensoría puede consultarlos todos. Sus requerimientos (Tabla 5.5) están dominados por los plazos que fija el Manual de Procedimientos de la DDP: diez días hábiles para que una unidad responda la primera solicitud de información y cinco para cada recordatorio [4].

Tabla 5.5: Requerimientos funcionales del actor Abogado de Subdefensoría

ID	Requerimiento	Descripción
RF-SD01	Recibir el expediente	Crear el expediente de investigación, asignado al abogado elegido, cuando Primer Contacto dictamina la queja como procedente.
RF-SD02	Consultar el inicio y los pendientes	Mostrar indicadores, pendientes del día ordenados por urgencia, expedientes que vencen pronto y su distribución por etapa.
RF-SD03	Consultar los expedientes propios	Listar los expedientes por etapa (por abrir, por solicitar oficio, esperando respuesta de la unidad, por redactar acuerdo, esperando respuesta del quejoso, concluidos) con búsqueda, filtros por prioridad y plazo, barra de plazo, siguiente paso sugerido y exportación.
RF-SD04	Abrir un expediente	Iniciar la investigación y consultar, en modo de solo lectura, lo actuado en Primer Contacto: oficios, citas y dictamen.
RF-SD05	Solicitar información a la unidad	Seleccionar la unidad académica del catálogo institucional, redactar el oficio de solicitud de información y enviarlo por correo a su titular, con PDF y plazo de diez días hábiles.
RF-SD06	Enviar un recordatorio de urgencia	Enviar un recordatorio a la unidad que no respondió, con plazo de cinco días hábiles.
RF-SD07	Registrar la respuesta de la unidad	Registrar la respuesta de la unidad con su canal de recepción, resumen y archivo.
RF-SD08	Elaborar el acuerdo de conciliación	Elaborar el acuerdo de conciliación y enviarlo al quejoso, quien lo acepta o rechaza mediante un enlace.
RF-SD09	Elaborar el acuerdo de conclusión	Elaborar y enviar el acuerdo de conclusión y cerrar el expediente.
RF-SD10	Controlar los plazos	Mostrar el semáforo de plazos y las alertas de oficios vencidos o por vencer en tres días o menos.
RF-SD11	Asignar la prioridad	Cambiar la prioridad del expediente (baja, media, alta o urgente) y ordenar la bandeja de mayor a menor prioridad.

5.3.5. Requerimientos funcionales de la Defensora

Este bloque concentra las funciones que hacen operable la plataforma a largo plazo sin intervención del equipo de desarrollo. Su requerimiento más sensible es el de respaldo y restauración (RF-A06), porque incluye la única operación destructiva de todo el sistema y por ello recibe un tratamiento de seguridad diferenciado.

Tabla 5.6: Requerimientos funcionales del actor Defensora

ID	Requerimiento	Descripción
RF-A01	Iniciar sesión	Autenticarse como personal administrativo.
RF-A02	Consultar el tablero general	Consultar un resumen del estado del sistema al entrar a la consola.
RF-A03	Gestionar cuentas de personal	Listar, crear con contraseña temporal, editar, restablecer contraseña, dar de baja y reactivar cuentas de cualquiera de los cinco roles.
RF-A04	Administrar el catálogo institucional	Listar, crear y editar dependencias, e importar o actualizar el catálogo de forma masiva desde un archivo de hoja de cálculo.
RF-A05	Administrar plantillas de documentos	Listar plantillas, consultar los marcadores disponibles, previsualizar con datos de ejemplo y editar o publicar su contenido.
RF-A06	Gestionar respaldos de la base de datos	Listar los respaldos existentes, ejecutar un respaldo bajo demanda, descargar un respaldo y restaurar la base de datos a partir de uno de ellos.
RF-A07	Consultar la bitácora de acciones críticas	Consultar el registro de acciones administrativas con usuario, acción, dirección de origen y fecha.
RF-A08	Administrar el contenido de preguntas frecuentes	Listar, crear, editar y eliminar las preguntas del portal público.
RF-A09	Cambiar la propia contraseña	Modificar la contraseña de la cuenta propia desde la consola.

5.3.6. Criterios funcionales de los componentes de inteligencia artificial

Los componentes de inteligencia artificial se concibieron como servicios auxiliares de la revisión de expedientes, principalmente accesibles desde Primer Contacto. La Tabla 5.7 resume los criterios de interacción derivados de su funcionamiento. Estos criterios se expresan como decisiones de diseño complementarias y no pretenden reemplazar los requerimientos funcionales institucionales previamente numerados.

Tabla 5.7: Criterios funcionales de los servicios de inteligencia artificial

Clave	Función	Criterio de diseño
IA-01	Recuperar antecedentes	A partir de la narrativa de una queja, obtener documentos anteriores ordenados por relación textual, sin determinar automáticamente duplicidad.
IA-02	Mostrar evidencia para revisión	Presentar la identificación del expediente y la información contextual disponible, además de las medidas de similitud, para apoyar la revisión humana.

Clave	Función	Criterio de diseño
IA-03	Generar borrador narrativo	Obtener una selección extractiva de la queja y reformularla en estilo institucional mediante un editor generativo.
IA-04	Informar límites	Tratar los resultados como sugerencias o borradores sujetos a revisión; no usarlos como decisiones o resoluciones automáticas.
IA-05	Manejar indisponibilidad	Evitar que una falla de los servicios de IA bloquee la recepción, el seguimiento o las decisiones administrativas del expediente.

5.3.7. Requerimientos no funcionales

Los requerimientos no funcionales expresan atributos de calidad y no funciones. Se agruparon por la categoría del atributo que abordan —disponibilidad, confidencialidad, resiliencia, usabilidad y trazabilidad— porque esa clasificación es la que permite verificarlos: cada categoría se comprueba con un tipo distinto de prueba. La Tabla 5.8 los concentra.

Tabla 5.8: Requerimientos no funcionales de la plataforma

ID	Categoría	Atributo requerido
RNF-Q01	Disponibilidad	Debe poder presentarse una queja sin cuenta ni sesión, en cualquier momento y desde cualquier dispositivo con navegador.
RNF-Q02	Confidencialidad	Todo el tráfico público debe viajar cifrado con TLS; tras el inicio de sesión, la autenticación se transmite como token en el encabezado de autorización y nunca como credenciales en claro.
RNF-Q03	Capacidad	El proxy público debe aceptar peticiones de hasta 100 MB y el backend hasta 60 MB por petición multiparte, para permitir varios archivos de evidencia por queja.
RNF-Q04	Resiliencia	Un fallo en el envío de correo o en el registro de una notificación nunca debe impedir que la operación principal se complete; el fallo se degrada a un registro en la bitácora del servidor.
RNF-Q05	Usabilidad	Los formularios extensos deben presentarse en pasos numerados, con previsualización de los archivos seleccionados y ayuda contextual que no reduzca el espacio útil del formulario.
RNF-Q06	Seguridad	La sesión del quejoso debe expirar en una hora; al expirar o ser rechazada, el cliente debe cerrar sesión de forma automática.
RNF-Q07	Usabilidad	Toda operación debe producir retroalimentación visual inmediata de éxito, error o validación; no se admiten fallos silenciosos.
RNF-R01	Trazabilidad	Cada rechazo y cada turnado debe registrar, sin excepción, el correo de quien lo procesó y la fecha en que ocurrió.
RNF-R02	Seguridad	El personal debe autenticarse en un único punto; ningún panel de personal implementa lógica de contraseñas propia.

ID	Categoría	Atributo requerido
RNF-R03	Interoperabilidad	La exportación del historial debe producir un archivo de hoja de cálculo en formato estándar, abrible sin conversión previa.
RNF-R04	Resiliencia	Si falla el envío del correo de rechazo, el rechazo en sí debe completarse igualmente.
RNF-R05	Consistencia	Los paneles de personal deben compartir componentes visuales, patrones de error y criterios de accesibilidad.
RNF-A01	Seguridad	El primer acceso administrativo debe autoprovisionarse en el arranque inicial con una contraseña temporal registrada una sola vez en la bitácora del servidor; nunca incrustada en el cliente ni expuesta por la interfaz de programación.
RNF-A02	Trazabilidad	Toda acción administrativa relevante, no solo el inicio de sesión, debe quedar registrada con la dirección de origen.
RNF-A03	Seguridad	La restauración de la base de datos debe exigir una confirmación explícita en el cuerpo de la petición; no puede dispararse con una sola acción accidental.
RNF-A04	Tolerancia a fallos	La importación masiva del catálogo debe reportar un resumen de filas procesadas, creadas, actualizadas y con error, en lugar de fallar en bloque ante una fila mal formada.
RNF-A05	Usabilidad	La consola de administración debe aprovechar la densidad de información disponible en pantalla.
RNF-A06	Seguridad	La generación, descarga y restauración de respaldos debe estar disponible únicamente para el rol de la Defensora (`DEFENSOR`).

5.3.8. Reglas de negocio

Las reglas de negocio son las restricciones que el sistema debe hacer cumplir para que el procedimiento sea válido. A diferencia de los requerimientos funcionales, que describen lo que el sistema *permite* hacer, las reglas describen lo que *prohíbe* o *obliga*. Su característica común en esta plataforma es que se validan en el servidor y no solo en la interfaz: ocultar un botón no es hacer cumplir una regla, y así se hace explícito en varias de las que siguen.

Tabla 5.9: Reglas de negocio de la plataforma

ID	Temática	Regla
RN-Q01	Menores de edad	Una queja de una persona menor de 18 años requiere datos de tutor o adulto responsable capturados y confirmados antes de poder enviarse.
RN-Q02	Menores de edad	Una persona menor de 14 años no puede autorregistrarse ni gestionar la queja por sí misma; la interfaz indica de forma explícita que debe ser el tutor quien complete el formulario a su nombre.
RN-Q03	Identificación	El número de boleta o de empleado debe ser exclusivamente numérico y no exceder doce caracteres.

ID	Temática	Regla
RN-Q04	Activación	Una cuenta de quejoso solo puede activarse si existe al menos una queja previa con ese folio *y* ese correo; el par folio-correo es la llave de activación.
RN-Q05	Activación	Una cuenta ya activa no puede volver a activarse.
RN-Q06	Contraseñas	La contraseña debe tener al menos ocho caracteres, una mayúscula y un dígito, tanto en la activación de cuenta como en el restablecimiento.
RN-Q07	Contraseñas	Un código de recuperación expira diez minutos después de solicitado y solo es válido una vez.
RN-Q08	Edición	Una queja solo es editable por su autor mientras su estatus sea `RECIBIDA`; en cualquier otro estatus la edición se rechaza en el servidor, no únicamente se oculta en la interfaz.
RN-Q09	Conciliación	Un acuerdo de conciliación solo puede ser respondido por el quejoso al que va dirigido; el correo del acuerdo debe coincidir con el del token de sesión.
RN-Q10	Origen	El origen de una queja se asigna de forma automática según el punto de acceso empleado —`PUBLICO`, `AUTENTICADO` o `MANUAL`—; no es un dato que el usuario declare.
RN-R01	Ciclo de vida	La queja transita `RECIBIDA` → `EN_VALIDACION` → `RECHAZADA` o `TURNADA`. Una vez rechazada o turnada no regresa a un estado anterior desde el panel de revisión.
RN-R02	Autorización	Únicamente las cuentas con rol de recepción pueden invocar los puntos de acceso del servicio de revisión; la restricción se declara en cada controlador y no solo a nivel de ruta.
RN-R03	Rechazo	Rechazar una queja exige al menos un motivo y genera de forma automática el correo de rechazo al quejoso; no es una acción silenciosa.
RN-R04	Turnado	Turnar una queja exige área y defensor asignado, y genera un folio oficial de turnado distinto del folio original de seguimiento.
RN-R05	Registro manual	Una queja registrada a partir de un documento físico recibe origen `MANUAL` y admite que no se conozca de antemano la boleta o el número de empleado.
RN-R06	Turnado	El catálogo de personal disponible para turnar incluye únicamente cuentas activas con rol de defensor o subdefensor.
RN-R07	Consistencia	El servicio de quejas y el de revisión operan sobre la misma tabla física mediante entidades independientes, de modo que un cambio de estatus hecho por recepción es visible de inmediato para el quejoso sin necesidad de una llamada entre servicios.
RN-A01	Autorización	Todos los puntos de acceso administrativos exigen el rol de administración de sistemas, salvo los de autenticación y los de gestión del perfil propio, que cualquier cuenta autenticada puede usar sobre sí misma.

ID	Temática	Regla
RN-A02	Cuentas	Una cuenta nueva de personal se crea siempre como temporal y con obligación de cambiar la contraseña en el primer inicio de sesión.
RN-A03	Cuentas	Dar de baja una cuenta la desactiva, no la elimina, para conservar la integridad referencial con las acciones que registró en el pasado.
RN-A04	Unicidad	El correo institucional y el número de empleado del personal son únicos en el sistema, garantizado por restricción de base de datos y no solo por validación de interfaz.
RN-A05	Autorización	Las rutas de administración de un catálogo deben evaluarse antes que la regla pública del mismo prefijo; sin ese orden explícito prevalecería la regla menos restrictiva por ser más genérica.
RN-A06	Plantillas	Una plantilla de documento se identifica por una clave estable de negocio y no por su identificador autogenerado, para poder referenciarla sin depender del orden de creación.
RN-A07	Trazabilidad	Cada actualización del contenido de una plantilla registra quién la actualizó y cuándo, además del asiento correspondiente en la bitácora.

5.4. Casos de uso

Los casos de uso describen las interacciones posibles entre cada actor y el sistema con independencia de la tecnología empleada. Se presentan agrupados por actor y con la estructura mínima que permite verificarlos: precondición, flujo principal y postcondición. La especificación extendida de cada caso, con flujos alternos y de excepción, se documenta en el anexo correspondiente.

Tabla 5.10: Casos de uso del actor Quejoso

ID	Nombre	Precondición	Flujo principal	Postcondición
CU-Q01	Presentar una queja sin cuenta	Ninguna	Completa el formulario público con identidad, motivo, evidencias y tutor si aplica, y lo envía	Queja creada con estatus `RECIBIDA` y origen `PUBLICO`; se muestra el folio
CU-Q02	Consultar una queja por folio	Conoce folio y correo	Captura ambos datos en la pantalla de consulta	Se muestra el detalle y el estatus de la queja
CU-Q03	Activar cuenta de seguimiento	Existe una queja con ese folio y correo	Define una contraseña; el sistema valida el par folio-correo contra el servicio de quejas	Cuenta activa; puede iniciar sesión

ID	Nombre	Precondición	Flujo principal	Postcondición
CU-Q04	Iniciar sesión	Cuenta activa	Captura correo y contraseña	Token de sesión emitido; se registra la notificación de acceso
CU-Q05	Recuperar contraseña	Cuenta activa existente	Solicita el código, lo recibe por correo y lo captura con la nueva contraseña	Contraseña actualizada; se envía correo de confirmación
CU-Q06	Presentar una queja autenticado	Sesión iniciada	Desde el panel captura motivo, descripción y evidencias	Queja creada con estatus `RECIBIDA` y origen `AUTENTICADO`
CU-Q07	Editar una queja propia	Sesión iniciada y queja en `RECIBIDA`	Modifica los campos habilitados desde el detalle y guarda	Queja actualizada; en otro estatus el servidor rechaza la edición
CU-Q08	Responder un acuerdo de conciliación	Existe un acuerdo pendiente dirigido a su correo	Revisa el acuerdo y lo acepta o rechaza con comentario opcional	Acuerdo pasa a aceptado o rechazado, con fecha de respuesta
CU-Q09	Revisar notificaciones	Sesión iniciada	Abre el centro de notificaciones y marca como leídas	El contador de no leídas se actualiza
CU-Q10	Actualizar el perfil	Sesión iniciada	Edita los campos habilitados y guarda	Perfil actualizado

Tabla 5.11: Casos de uso del actor Personal de recepción

ID	Nombre	Precondición	Flujo principal	Postcondición
CU-R01	Iniciar sesión en el panel de revisión	Cuenta activa con rol de recepción	Se autentica contra el servicio de administración	Token emitido; acceso al panel
CU-R02	Revisar la bandeja de entrada	Sesión iniciada	Consulta contadores y lista de pendientes	—
CU-R03	Validar y rechazar una queja	Queja en `RECIBIDA` o `EN_VALIDACION`	Revisa documentos y antecedentes, marca motivos y observaciones, confirma	Queja pasa a `RECHAZADA`; se envía correo al quejoso
CU-R04	Validar y turnar una queja	Queja en `RECIBIDA` o `EN_VALIDACION`	Revisa antecedentes, elige área y defensor, agrega comentarios, confirma	Queja pasa a `TURNADA` con folio oficial, área y defensor
CU-R05	Registrar una queja en papel	Documento físico recibido	Captura los datos del documento y adjunta el escaneo si lo hay	Queja creada con origen `MANUAL` y folio propio

ID	Nombre	Precondición	Flujo principal	Postcondición
CU-R06	Consultar y exportar el historial	Existen trámites procesados	Filtra por texto, estatus o fecha y exporta si lo requiere	Archivo de hoja de cálculo descargado con el filtro aplicado
CU-R07	Emitir un acuerdo de conciliación	Existe una queja con folio conocido	Captura asunto y términos dirigidos al folio y correo del quejoso	Acuerdo creado como pendiente, visible para el quejoso

Tabla 5.12: Casos de uso del actor Analista de Primer Contacto

ID	Nombre	Precondición	Flujo principal	Postcondición
CU-PC-01	Recibir expediente desde Recepción	Recepción turna la queja a un analista	El sistema crea el expediente con los datos de la queja, el analista asignado y la prioridad	Expediente en `TURNADA` en la bandeja del analista, con aviso en su panel
CU-PC-02	Consultar la bandeja de análisis	Sesión iniciada como analista	Consulta sus expedientes y filtra por folio, prioridad o estatus	Se listan los expedientes asignados al analista
CU-PC-03	Consultar el expediente de análisis	Expediente asignado al analista	Abre el expediente y consulta sus datos, evidencias e historial	Expediente en `EN_ANALISIS`; un analista distinto recibe acceso denegado
CU-PC-04	Agendar y gestionar citas	Expediente en análisis	Programa, confirma, reagenda o cancela una cita en un horario libre	Cita registrada; la persona citada la confirma o cancela desde el enlace recibido por correo
CU-PC-05	Registrar notas de análisis	Expediente en análisis	Redacta el oficio con asunto y contenido y genera su PDF	Oficio numerado en el expediente; solo su autor puede modificarlo
CU-PC-06	Registrar dictamen de competencia	Expediente en análisis	Captura la justificación, elige al abogado de Subdefensoría y confirma	Expediente en `PROCEDENTE`; se crea el expediente de investigación (CU-SD-01)
CU-PC-07	Registrar dictamen de improcedencia	Expediente en análisis	Captura la justificación y confirma	Expediente en `IMPROCEDENTE`, pendiente de remisión (CU-PC-09)
CU-PC-08	Consultar el dictamen	Expediente dictaminado	Abre el dictamen del expediente	Se muestra el dictamen con su sentido, justificación, autor y fecha

ID	Nombre	Precondición	Flujo principal	Postcondición
CU-PC-09	Crear y enviar remisión externa	Expediente en `IMPROCEDENTE`	Elige la instancia competente, revisa los datos y confirma el envío	Oficio en PDF enviado por correo a la instancia; expediente en `REMITIDA` y aviso al quejoso
CU-PC-10	Proponer y listar acuerdos de conciliación	Expediente en análisis	Captura la propuesta y la envía; consulta las ya propuestas	Acuerdo pendiente, visible para el quejoso

Tabla 5.13: Casos de uso del actor Abogado de Subdefensoría

ID	Nombre	Precondición	Flujo principal	Postcondición
CU-SD-01	Recibir expediente desde Primer Contacto	Dictamen de competencia con abogado elegido	El sistema crea el expediente de investigación	Expediente en `RECIBIDO`, asignado al abogado
CU-SD-02	Consultar la bandeja de expedientes	Sesión iniciada como abogado o como titular	Consulta los expedientes por etapa y filtra por prioridad o plazo	Se listan los expedientes propios; el titular ve todos
CU-SD-03	Consultar el semáforo de plazos	Existen expedientes en trámite	Revisa la barra de plazo de cada expediente	Se muestra el avance contra los plazos del Manual de Procedimientos
CU-SD-04	Consultar alertas de vencimiento	Existen oficios con plazo en curso	Abre la vista de plazos y oficios	Se listan los oficios vencidos o por vencer en tres días o menos
CU-SD-05	Consultar el expediente de investigación	Expediente asignado al abogado	Abre el expediente y consulta lo actuado en Primer Contacto en solo lectura	Expediente en `EN_INVESTIGACION`
CU-SD-06	Emitir oficio	Expediente en investigación	Elige la unidad académica, revisa titular y correo, redacta y envía el oficio	Oficio en PDF enviado por correo; expediente en `EN_ESPERA_OFICIO` con plazo de diez días hábiles
CU-SD-07	Generar recordatorio de urgencia	Oficio sin respuesta	Genera y envía el recordatorio	Recordatorio enviado con plazo de cinco días hábiles
CU-SD-08	Registrar respuesta externa	Oficio enviado a la unidad	Captura el canal de recepción, el resumen y el archivo de la respuesta	Respuesta registrada; el expediente pasa a la elaboración del acuerdo

ID	Nombre	Precondición	Flujo principal	Postcondición
CU-SD-09	Registrar acuerdo de conclusión	Respuesta de la unidad registrada	Envía al quejoso el acuerdo de conciliación y, una vez aceptado mediante el enlace, emite el acuerdo de conclusión	Expediente en `CONCLUIDO`

Tabla 5.14: Casos de uso del actor Defensora

ID	Nombre	Precondición	Flujo principal	Postcondición
CU-A01	Iniciar sesión en el panel de la Defensora	Cuenta activa con rol `DEFENSOR`	Se autentica en el panel	Token emitido; acceso al panel
CU-A02	Dar de alta personal	Sesión iniciada	Captura nombre, número de empleado, correo y rol	Cuenta creada con contraseña temporal; queda en bitácora
CU-A03	Restablecer la contraseña de otra cuenta	La cuenta destino existe	Selecciona la cuenta y solicita el restablecimiento	Nueva contraseña temporal generada; queda en bitácora
CU-A04	Dar de baja o reactivar una cuenta	Sesión iniciada	Selecciona la cuenta y confirma la operación	La cuenta cambia su estado de actividad; queda en bitácora
CU-A05	Importar el catálogo institucional	Archivo de hoja de cálculo con el formato esperado	Carga el archivo en el módulo de catálogo	Dependencias creadas o actualizadas de forma masiva; se muestra el resumen
CU-A06	Editar una plantilla de oficio	Sesión iniciada	Edita el contenido con los marcadores disponibles, previsualiza y publica	Plantilla actualizada; queda en bitácora
CU-A07	Ejecutar un respaldo	Sesión iniciada	Solicita un respaldo bajo demanda	Archivo de respaldo generado y listado; queda en bitácora
CU-A08	Restaurar desde un respaldo	Existe al menos un respaldo	Selecciona el archivo y confirma de forma explícita la operación destructiva	Base de datos restaurada; queda en bitácora
CU-A09	Revisar la bitácora de seguridad	Sesión iniciada	Abre el historial de acciones críticas	Se listan las acciones con usuario, dirección de origen y fecha
CU-A10	Administrar las preguntas frecuentes	Sesión iniciada	Crea, edita o elimina preguntas	Los cambios se reflejan de inmediato en el portal público

5.4.1. Casos de uso de apoyo al análisis de Primer Contacto

El módulo de Primer Contacto dispone de funciones de análisis asistido que no determinan por sí mismas el sentido de una actuación institucional. La Tabla 5.15 representa las interacciones relacionadas con los dos componentes de inteligencia artificial.

Tabla 5.15: Casos de uso de apoyo mediante inteligencia artificial

Clave	Caso de uso	Precondición	Flujo y resultado
CU-IA01	Consultar antecedentes relacionados	Expediente accesible al analista	El servicio consulta el recuperador híbrido y presenta los expedientes sugeridos para revisión.
CU-IA02	Generar borrador de resumen	Narrativa disponible	El servicio obtiene una captura extractiva y solicita su edición institucional; el resultado se muestra con advertencia de revisión humana.

5.5. Ciclo de vida del expediente

El elemento que ordena todo el flujo de trabajo es el estatus de la queja. Se modeló como una máquina de estados con cuatro valores y transiciones dirigidas, decisión que se tomó por dos razones: permite validar en el servidor qué operaciones son admisibles en cada momento —la regla RN-Q08 depende por completo de esto— y da al quejoso una línea de tiempo comprensible del avance de su expediente.

- `RECIBIDA`. Estado inicial de toda queja, sin importar su origen. Es el único estado en el que el quejoso puede editar su propia queja, porque es el único en el que la Defensoría no ha empezado a trabajar sobre ella.
- `EN_VALIDACION`. El personal de recepción tomó la queja y está verificando su documentación y sus antecedentes. La edición por parte del quejoso queda cerrada a partir de aquí, para evitar que el expediente cambie mientras se lo evalúa.
- `RECHAZADA`. Estado terminal. La queja no reunió los requisitos de documentación; el rechazo exige motivos registrados y notificación al quejoso.
- `TURNADA`. Estado terminal desde la perspectiva de recepción. La queja fue canalizada a un área y a un defensor, y recibió un folio oficial de turnado.

Los estados anteriores describen principalmente la fase de recepción y turnado, no el ciclo completo del expediente. Tras el turnado pueden intervenir los módulos de Primer Contacto, Subdefensoría y las instancias responsables de resolución, con estados y actuaciones propios. Por ello, la máquina aquí presentada debe interpretarse como un subproceso; el ciclo de vida completo se documenta conforme a las reglas de los módulos posteriores.

5.6. Diseño de la arquitectura

La arquitectura de la plataforma aplica los principios expuestos en la Sección 4.1. Esta sección describe cómo se concretaron: qué componentes existen, cómo se comunican, cómo se despliegan y qué alternativas se descartaron en cada decisión.

5.6.1. Vista de componentes

El sistema se descompuso en microservicios de dominio y servicios auxiliares de inteligencia artificial. Los servicios de negocio implementan las operaciones institucionales; los de IA atienden recuperación de información y redacción asistida. La Tabla 5.16 presenta los componentes principales. Los puertos de los servicios internos corresponden a la publicación en el servidor cuando aplica; el procesamiento inteligente se comunica por la red de contenedores y no requiere exposición pública.

Tabla 5.16: Microservicios de la plataforma y su responsabilidad

Servicio	Puerto	Responsabilidad	Emite tokens
`auth-service`	8083	Sesión del quejoso, activación de cuenta, recuperación de contraseña y perfil	Sí, para quejosos
`queja-service`	8084	Registro de quejas público y autenticado, consulta y edición de quejas propias, evidencias y respuesta a acuerdos de conciliación	No, solo verifica
`notificaciones-service`	8085	Envío de correo electrónico y centro de notificaciones persistido por usuario	No, solo verifica
`catalogo-service`	8086	Catálogo de dependencias y unidades académicas del Instituto	No, solo verifica
`admin-service`	8087	Sesión del personal, cuentas y roles, plantillas de oficios, respaldos y bitácora de seguridad	Sí, para personal
`revision-service`	8088	Bandeja de recepción, validación, rechazo, turnado, registro manual, historial exportable y emisión de acuerdos	No, solo verifica
`chatbot-service`	8089	Menú de preguntas frecuentes del portal público y su administración	No, solo verifica
`primer-contacto-se`	8082	Gestión de expedientes de Primer Contacto e integración de las herramientas de antecedentes y resúmenes	No, verifica
`subdefensoria-serv`	Interno	Operaciones del módulo de Subdefensoría	No, verifica
`historico-service`	Interno	Consulta y tratamiento de información histórica de quejas	No, verifica
`antecedentes-servi`	Interno	Recuperación híbrida de expedientes con TF-IDF, MiniLM y fusión de rankings	No emite

Servicio	Puerto	Responsabilidad	Emite tokens
`resumen-service`	Interno	Selección extractiva y edición institucional de resúmenes	No emite
`qwen-server`	Interno	Motor de inferencia del modelo generativo para el editor	No emite

Los tokens de sesión se emiten desde los servicios de autenticación de quejosos y de personal. Los servicios de negocio que necesitan autorización los verifican; los componentes de IA permanecen accesibles únicamente a los servicios internos autorizados por la topología de red y las reglas de acceso. Esta separación impide confundir un servicio de inferencia con un punto de autenticación o una decisión administrativa.

5.6.2. Vista de despliegue

El despliegue diferencia el acceso público, los servicios de negocio y los componentes de procesamiento de inteligencia artificial. El entorno de aplicaciones aloja los microservicios y la persistencia operativa; el entorno de acceso sirve las aplicaciones web y el proxy inverso; el procesamiento de modelos dispone de servicios de inferencia separados y redes internas de contenedores. La Figura de despliegue y los detalles de infraestructura del capítulo de implementación especifican la distribución física y la configuración finalmente utilizada.

Esta separación cumple tres propósitos. El primero es de seguridad: el servidor que contiene la base de datos y la lógica de negocio no está expuesto directamente a Internet, y su cortafuegos acepta conexiones a los puertos de los microservicios únicamente desde la dirección del servidor de acceso público. El segundo es de aislamiento de fallos: una saturación en la entrega de archivos estáticos no compite por recursos con el procesamiento de las peticiones de negocio. El tercero es operativo: el certificado de transporte y la configuración del dominio residen en un solo lugar, de modo que renovarlos no implica reiniciar ningún servicio de negocio.

El único puerto realmente público es el de HTTPS; el puerto de HTTP se conserva abierto exclusivamente para redirigir el tráfico a su equivalente cifrado y para atender el reto de validación del certificado. La Tabla 5.17 presenta las reglas de enrutamiento del proxy inverso, que son el contrato entre el exterior y la arquitectura interna.

Tabla 5.17: Reglas de enrutamiento del proxy inverso público

Ruta pública	Destino	Servidor
`/`	Portal del quejoso	Acceso público
`/admin/`	Consola de administración	Acceso público
`/revision/`	Panel de revisión	Acceso público
`/primer-contacto/`	Panel de Primer Contacto	Acceso público
`/subdefensoria/`	Panel de Subdefensoría	Acceso público
`/api/auth/`	`auth-service`	Aplicación
`/api/quejoso/`	`queja-service`	Aplicación
`/api/notificaciones/`	`notificaciones-service`	Aplicación

Ruta pública	Destino	Servidor
/api/catalogos/	catalogo-service	Aplicación
/api/admin/	admin-service	Aplicación
/api/revision/	revision-service	Aplicación
/api/chatbot/	chatbot-service	Aplicación
/api/primer-contacto/	primer-contacto-service	Aplicación
/api/subdefensoria/	subdefensoria-service	Aplicación

Una consecuencia de diseño de este esquema merece destacarse: como el proxy entrega tanto las aplicaciones web como la interfaz de programación bajo un mismo dominio, el navegador considera que todo proviene del mismo origen y no activa la verificación de intercambio de recursos entre orígenes. Eso simplifica el modelo de seguridad del cliente sin sacrificar la separación en servicios del lado del servidor.

5.6.3. Diseño de la comunicación entre servicios

La comunicación entre servicios es síncrona sobre HTTP siguiendo el estilo REST, conforme a lo expuesto en la Sección 4.1. Se descartó la mensajería asíncrona porque el volumen de operaciones y el número de servicios no justifican la complejidad operativa de un intermediario de mensajes, y porque ninguno de los flujos identificados tolera bien la consistencia eventual: un quejoso que envía una queja espera su folio en la misma respuesta, no después.

El diseño utiliza llamadas internas para validación de identidad y envío de notificaciones, además de consultas a los servicios especializados. En Primer Contacto, la recuperación de antecedentes se obtiene mediante una petición HTTP al servicio de búsqueda; la elaboración de resúmenes invoca otro servicio, que a su vez consulta un motor de inferencia generativa. Cada interacción tiene su propio tiempo de espera y una estrategia de manejo de fallos: la indisponibilidad del componente de IA no debe sustituir ni bloquear el criterio institucional. Las dependencias de datos y sus compromisos se analizan en la Sección 5.6.5.

5.6.4. Diseño de la seguridad y el control de acceso

El esquema de seguridad se construyó sobre cuatro mecanismos, cada uno atendiendo una amenaza distinta.

La **autenticación** emplea tokens firmados con algoritmo simétrico. Un token emitido por el servicio de autenticación es válido en los servicios que atienden al quejoso, y uno emitido por el servicio de administración es válido en los que atienden al personal, porque todos comparten la misma clave de firma. Cada servicio verifica el token de forma local, sin consultar al emisor, lo que evita un punto único de falla en cada petición. La vigencia del token es de una hora, y el cliente cierra la sesión de forma automática cuando el servidor la rechaza.

El **almacenamiento de contraseñas** usa una función de resumen con costo configurable en los dos servicios que emiten sesión. La política de complejidad exige un mínimo de ocho caracteres, al menos una mayúscula y al menos un dígito, y está implementada como una expresión compartida para que no divergja entre servicios. Las cuentas de personal se crean con contraseña temporal y

obligación de cambiarla en el primer acceso.

La **autorización** se declara por rol en cada controlador, no solo por ruta. Esta distinción no es cosmética: una restricción declarada únicamente en la configuración de rutas puede eludirse si una ruta nueva se agrega sin actualizar esa configuración, mientras que la declaración en el controlador viaja con el código que protege.

El **cifrado en tránsito** se termina en el proxy inverso con un certificado de una autoridad reconocida y renovación automática. Del proxy hacia los microservicios el tráfico viaja sin cifrar, decisión aceptable porque ese tramo no atraviesa Internet y está restringido por dirección de origen en el cortafuegos, pero que conviene revisar si en el futuro los servidores dejan de estar bajo control directo del proyecto.

Un punto pendiente que debe declararse: el cierre automático de sesión por inactividad solicitado para las cuentas de personal no está implementado al cierre de esta etapa. La expiración del token limita la ventana de exposición a una hora, pero no equivale a un cierre por inactividad.

5.6.5. Decisiones de diseño y alternativas descartadas

Esta sección documenta las decisiones estructurales del proyecto con el formato contexto-alternativas-decisión-consecuencias. Registrarlas de esta forma cumple un propósito concreto: una decisión de arquitectura cuyo razonamiento no se documenta se vuelve indistinguible de un accidente, y quien mantenga el sistema en el futuro no sabrá si puede revertirla.

Decisión 1: base de datos única compartida. *Contexto:* varios servicios de negocio necesitan datos que se relacionan entre sí —una queja, su tutor, sus evidencias, el usuario que la presentó, la notificación que se le envió—. *Alternativas:* una base de datos por servicio, con sincronización explícita entre ellas; o una base única compartida. *Decisión:* base única. *Consecuencias aceptadas:* se sacrifica la autonomía de datos que caracteriza a los microservicios puros, y dos servicios escriben la misma tabla sin coordinación transaccional entre ellos. A cambio se evita la complejidad de mantener consistencia entre bases separadas, que a la escala de este sistema habría requerido un esfuerzo mayor que el beneficio obtenido. Es un híbrido consciente, no una implementación incompleta del patrón.

Decisión 2: entidades independientes sobre una tabla compartida. *Contexto:* el servicio de quejas y el de revisión necesitan la misma tabla de quejas, pero con vistas distintas: el primero requiere los campos del quejoso, el segundo los del flujo de validación. *Alternativas:* un servicio dueño de la tabla que exponga los datos al otro por interfaz de programación; o dos clases de persistencia independientes sobre la misma tabla física. *Decisión:* entidades independientes. *Consecuencias aceptadas:* un cambio de estatus hecho por recepción es visible de inmediato para el quejoso sin llamada entre servicios, lo que simplifica el flujo; pero ambos servicios pueden agregar columnas sin que el otro lo sepa, y una modificación descoordinada del esquema puede romper al servicio vecino. La mitigación adoptada es que cada servicio declare únicamente las columnas que usa.

Decisión 3: catálogo institucional como servicio propio. *Contexto:* el catálogo de dependencias del Instituto es requerido por el formulario público de quejas, por el turnado en el panel de revisión y

por la consola de administración. *Alternativas:* alojarlo dentro del servicio de quejas, que fue quien primero lo necesitó; o extraerlo a un servicio propio. *Decisión:* servicio propio. *Consecuencias aceptadas:* se añadió un servicio más que operar y desplegar, con el sobrecosto correspondiente, en un momento en que un solo consumidor lo necesitaba. La razón para asumirlo fue anticipada: al convertirse en dato de referencia de tres consumidores distintos, alojarlo dentro de un servicio de negocio habría obligado a que los otros dos dependieran de él por razones ajenas a su dominio.

Decisión 4: evidencias almacenadas en la base de datos. *Contexto:* cada queja puede llevar varios archivos de evidencia que constituyen material probatorio. *Alternativas:* guardar los archivos en el sistema de archivos del servidor y almacenar la ruta en la base; o almacenar el contenido binario completo dentro de la base. *Decisión:* contenido binario en la base. *Consecuencias aceptadas:* la base crece más rápido y los respaldos son más grandes. A cambio se obtiene lo que en este dominio pesa más: el archivo y su expediente se respaldan y se restauran como una unidad atómica, de modo que no puede existir un expediente cuya evidencia se haya perdido porque el respaldo del sistema de archivos y el de la base se tomaron en momentos distintos. Para material con posible valor probatorio, esa garantía justifica el costo de almacenamiento.

Decisión 5: aplicaciones web separadas por perfil funcional. *Contexto:* los módulos de quejosos, recepción, administración, Primer Contacto y Subdefensoría tienen responsabilidades y necesidades de interfaz distintas. *Alternativas:* una sola aplicación con rutas condicionadas por rol o aplicaciones separadas. *Decisión:* separar los módulos web por ámbito de uso. *Consecuencias aceptadas:* se deben mantener coherentes componentes, interceptores y estilos entre proyectos; a cambio se delimitan interfaces y despliegues de cada área. La autorización efectiva sigue dependiendo de la validación del servidor.

Decisión 6: datos del quejoso en columnas propias. *Contexto:* el registro público debe capturar la identidad completa del quejoso, que en una versión inicial se concatenaba como texto libre dentro de la descripción de la queja. *Alternativas:* conservar la concatenación, más simple de implementar; o estructurar cada dato en su propia columna. *Decisión:* columnas propias. *Consecuencias aceptadas:* el esquema creció y el formulario requiere más validación. A cambio, los datos se volvieron consultables y verificables —la búsqueda de antecedentes del requerimiento RF-R04 sería impracticable sobre texto concatenado— y la unidad académica pudo pasar de texto libre a una referencia al catálogo institucional.

Decisión 7: una imagen de contenedor por servicio. *Contexto:* los microservicios comparten la misma imagen base y el mismo procedimiento de construcción. *Alternativas:* una imagen común reutilizada por todos, parametrizada al ejecutarse; o una imagen dedicada por servicio. *Decisión:* una por servicio. *Consecuencias aceptadas:* se consume más espacio de almacenamiento en el registro de imágenes. A cambio, cada contenedor es identificable y versionable de forma independiente, y se elimina la ambigüedad de no poder saber qué versión de qué servicio está ejecutando un contenedor determinado.

5.7. Diseño de la base de datos

La persistencia principal de expedientes es relacional y se comparte entre varios servicios de negocio. En algunos casos, distintas entidades de persistencia trabajan sobre la misma tabla física, bajo el patrón descrito en la Decisión 2. La Tabla 5.18 presenta las tablas de los módulos de registro, revisión y administración. Las estructuras adicionales de Primer Contacto, Subdefensoría e histórico deben documentarse en el diccionario de datos correspondiente. Los embeddings del recuperador se conservan en una caché técnica independiente, que no reemplaza el expediente original.

Tabla 5.18: Esquema de la base de datos por tabla y servicio propietario

Tabla	Propietario	Contenido
`usuarios`	`auth-service`	Cuentas de quejoso: identidad institucional, credencial cifrada, datos de contacto, datos de tutor y código de recuperación con su vigencia
`quejas`	`queja-service` y `revision-service`	Cuerpo del expediente: folio, identidad del quejoso, narrativa de los hechos, unidad académica, denunciado, origen, estatus, y los campos del flujo de validación —motivo de rechazo, área, defensor asignado, quién validó y cuándo—
`queja_tutores`	`queja-service`	Datos del tutor o adulto responsable, en relación uno a uno con la queja
`queja_evidencias`	`queja-service`	Archivos de evidencia: nombre, tipo, tamaño y contenido binario completo
`acuerdos_conciliacion`	`revision-service` y `queja-service`	Acuerdos emitidos por la Defensoría: asunto, términos, estado y respuesta del quejoso
`notificaciones`	`notificaciones-service`	Avisos persistidos por destinatario, con tipo, estado de lectura y enlace
`dependencias`	`catalogo-service`	Catálogo institucional jerárquico con clave propia, clave del padre, tipo, categoría y nivel
`personal_administrativo`	`admin-service`	Cuentas de personal: identidad, rol, credencial cifrada, condición de cuenta temporal y último acceso
`plantillas_documentos`	`admin-service`	Plantillas de oficios con clave estable de negocio, contenido y datos de última actualización
`bitacora_acciones`	`admin-service`	Registro de auditoría: usuario, acción, dirección de origen y fecha
`preguntas_chatbot`	`chatbot-service`	Contenido del menú de preguntas frecuentes del portal público

5.7.1. Correspondencia entre reglas de negocio y mecanismos de integridad

Un modelo de datos que solo almacena información deja las reglas del dominio a merced de que cada consumidor las respete. El diseño de esta base busca lo contrario: que las reglas se hagan

cumplir en el nivel más bajo posible, de modo que ningún camino de acceso pueda violarlas. La Tabla 5.19 muestra esa correspondencia para las reglas que admiten verificación estructural.

Tabla 5.19: Reglas de negocio y mecanismo que las hace cumplir

Regla	Enunciado	Mecanismo
RN-Q04	El par folio-correo es la llave de activación	Consulta entre servicios que exige coincidencia de ambos campos antes de crear la cuenta
RN-Q05	Una cuenta activa no se reactiva	Verificación del indicador de actividad antes de procesar la activación
RN-Q07	El código de recuperación expira en diez minutos	Columna de fecha de expiración evaluada en el servidor al validar el código
RN-Q08	Una queja solo es editable en estatus recibida	Validación del estatus en la capa de negocio antes de aplicar la modificación
RN-Q09	Solo el destinatario responde un acuerdo	Comparación del correo del acuerdo contra el del token de sesión
RN-Q10	El origen de la queja se infiere	Asignación en el servidor según el punto de acceso invocado, sin exponerlo como campo de entrada
RN-R01	Transiciones válidas del expediente	Columna de estatus con conjunto acotado de valores y validación de la transición en la capa de negocio
RN-R02	Solo recepción usa el servicio de revisión	Declaración de rol requerido en cada controlador
RN-R06	Solo defensores activos reciben turnado	Consulta filtrada por rol y por indicador de actividad
RN-A03	La baja desactiva, no elimina	Indicador de actividad en lugar de borrado físico, preservando la integridad referencial con la bitácora
RN-A04	Correo y número de empleado únicos	Restricción de unicidad en la definición de la tabla
RN-A06	La plantilla se identifica por clave de negocio	Restricción de unicidad sobre la columna de tipo, independiente del identificador autogenerado

El diccionario de datos completo, con el tipo y la longitud de cada columna, las cardinalidades detalladas, los índices y las sentencias de creación, se documenta en el anexo correspondiente.

5.8. Diseño de los componentes de inteligencia artificial

Los componentes inteligentes se diseñaron como herramientas auxiliares para la revisión de expedientes. Se separaron en dos procesos con objetivos y salidas diferentes: recuperación de antecedentes relacionados y elaboración de borradores narrativos. El primero devuelve referencias

documentales ordenadas por relevancia; el segundo devuelve un texto redactado a partir de información seleccionada de la queja. Ninguno determina automáticamente la competencia institucional, la existencia de una duplicidad ni el sentido de una resolución.

5.8.1. Diseño del componente de búsqueda de antecedentes

La entrada principal es la narración de una queja. El diseño parte de una colección de quejas vigentes e históricas que se representa con dos señales complementarias: coincidencias de términos y similitud semántica. La primera emplea TF-IDF con unigramas y bigramas; la segunda emplea un codificador multilingüe MiniLM para construir embeddings de fragmentos del contenido.

Fragmentación de narrativas. Las narrativas extensas se dividen en segmentos de longitud acotada, con solapamiento entre segmentos consecutivos. El objetivo es preservar contexto local y evitar que un solo vector de documento oculte acontecimientos relevantes mencionados en una parte de la queja. Las decisiones de tamaño, solapamiento y procesamiento por lotes pertenecen a la configuración de implementación y se evalúan según costo y calidad de recuperación.

Recuperación paralela y fusión de rankings. Cada recuperador produce su propia lista ordenada de antecedentes: TF-IDF privilegia coincidencias léxicas específicas, mientras que MiniLM facilita localizar textos de significado relacionado aunque utilicen otras expresiones. Se emplea Reciprocal Rank Fusion (RRF) ponderado, que integra las posiciones en ambos rankings en lugar de sumar directamente sus puntuaciones, porque las escalas de similitud de los recuperadores no son necesariamente equivalentes. El mecanismo se fundamenta en la Sección 4.5.

La configuración seleccionada para la integración del sistema asigna un peso del 75 % al ranking TF-IDF y del 25 % al ranking semántico MiniLM. Estas ponderaciones se aplican a las contribuciones de los rankings mediante RRF; no representan porcentajes de similitud ni probabilidades de duplicidad. Su selección corresponde a los experimentos con datos sintéticos documentados en el capítulo de pruebas, y no implica que constituyan una combinación óptima para todos los escenarios institucionales. Para compararlos es necesario utilizar un mismo conjunto de consultas y juicios de relevancia, probar distintas ponderaciones y medir la pertinencia y posición de los antecedentes mediante métricas como precisión, exhaustividad y ganancia acumulada descontada normalizada.

Indexación y actualización. El diseño evita recalcular los embeddings de toda la colección en cada actualización: mantiene una caché persistente de representaciones, identificadas mediante una huella del contenido y la configuración del codificador. Si un documento no cambió, se puede reutilizar su representación; si cambió o se incorporó, se calcula la nueva. El índice disponible para consulta se sustituye cuando la reconstrucción termina, para no exponer un estado parcialmente construido.

Presentación e interpretación. Los antecedentes se exponen con su identificación y datos contextuales disponibles, para que el personal contraste los hechos. La clasificación de coincidencias por hechos o involucrados sirve como apoyo visual. Una similitud elevada no confirma que dos quejas sean idénticas: la identificación de duplicidades corresponde a la revisión humana.

5.8.2. Diseño del componente de generación de resúmenes

La generación de resúmenes sigue un esquema de dos etapas para separar la selección de información de la redacción. La entrada es la narrativa original de la queja y la salida es un borrador institucional, nunca una sustitución del documento fuente.

Selección extractiva. En la primera etapa, el procedimiento de selección extractiva utiliza criterios de relevancia, redundancia, importancia y conservación del contexto. Incorpora un criterio de selección basado en Maximum Marginal Relevance (MMR), de modo que el resultado no concentre exclusivamente oraciones muy similares. Su salida es una captura extractiva, que conserva fragmentos del relato en su formulación original y sirve de entrada al editor.

Edición mediante un modelo de lenguaje. La segunda etapa utiliza Qwen3, un modelo generativo, para convertir la captura extractiva en narración institucional en tercera persona. La instrucción de edición busca conservar actores, negaciones, fechas, cantidades, evidencias, consecuencias y secuencia de acontecimientos, así como presentar las afirmaciones como declaraciones del quejoso y no como hechos jurídicamente comprobados. Su función prevista es reformular los fragmentos recibidos, no realizar una nueva selección deliberada de hechos. Sin embargo, debido al carácter generativo del modelo, pueden ocurrir omisiones o alteraciones de información incluso bajo estas instrucciones.

Procesamiento por bloques y límites operativos. La captura puede dividirse en bloques de oraciones con una extensión máxima, para acotar el trabajo por solicitud al motor generativo y adecuar el procesamiento a la infraestructura de CPU disponible. Se establece un presupuesto de tiempo para la edición y se prevé conservar el fragmento extractivo si una llamada falla o queda incompleta. Esa contingencia evita descartar contenido por errores de generación, pero puede producir un borrador parcialmente editado, por lo que debe informarse en las pruebas y en la interpretación de resultados.

Fidelidad y validación humana. El diseño distingue dos fuentes posibles de omisión: la selección extractiva y la edición generativa. Es necesario evaluar ambas por separado, comparando la narrativa original con la captura seleccionada y esta con el resumen final. Se consideran críticos los cambios de actores, negaciones, fechas y cantidades. Aunque las instrucciones de generación buscan evitar alteraciones, no ofrecen una garantía de conservación factual; toda síntesis debe quedar sujeta a revisión humana. Por restricciones de tiempo, la evaluación realizada con narrativas sintéticas no se complementó con una validación de calidad y utilidad mediante expedientes reales y la participación del personal de la Defensoría. Por tanto, las pruebas técnicas no deben interpretarse como validación institucional del componente. La revisión de calidad con datos autorizados y personal responsable queda como actividad futura.

5.8.3. Integración de los servicios con Primer Contacto

El módulo de Primer Contacto actúa como consumidor de ambos componentes. El servicio de antecedentes atiende peticiones de consulta y devuelve expedientes sugeridos; el servicio de resúmenes

ejecuta la selección extractiva y solicita la redacción al motor generativo. La separación de los servicios permite actualizar los algoritmos de recuperación y generación sin acoplarlos entre sí.

Por tratarse de llamadas síncronas, el diseño contempla tiempos máximos de espera, observabilidad del estado de los servicios y manejo de fallos. Si un componente no responde, la actividad administrativa debe poder continuar sin interpretar el resultado faltante como una decisión automatizada. La descripción de contratos HTTP, parámetros y despliegue corresponde al capítulo de implementación.

5.8.4. Decisiones de diseño y alternativas consideradas

La Tabla 5.20 resume los principales compromisos del diseño.

Tabla 5.20: Decisiones técnicas de los componentes de inteligencia artificial

Decisión	Alternativas	Justificación y compromiso
Recuperación híbrida	TF-IDF aislado, MiniLM aislado o combinación	Combina coincidencias específicas y relaciones semánticas; exige evaluar sus pesos.
Fragmentación	Vector único por documento o vectores por fragmento	Conserva señales locales de textos extensos; aumenta almacenamiento y cómputo.
Fusión por rankings	Suma directa de puntuaciones o RRF ponderado	Evita comparar directamente escalas de similitud no equivalentes; se seleccionó la ponderación 75 % TF-IDF y 25 % MiniLM con evidencia sintética, sin asumir generalización a expedientes reales.
Caché de embeddings	Reconstrucción total o reutilización por contenido	Reduce trabajo repetido; obliga a invalidar representaciones al cambiar contenido o modelo.
Resumen en dos etapas	Generación directa o selección más edición	Separa relevancia y redacción; conserva riesgos de omisión en ambas etapas.
Inferencia en CPU	Modelo de mayor tamaño o modelo compacto cuantizado	Permite operación en los recursos disponibles; limita concurrencia y velocidad.

5.9. Diseño de la interfaz de usuario

El diseño de las interfaces partió de prototipos de alta fidelidad que se usaron como herramienta de validación temprana con el cliente. La razón de invertir en ellos antes de escribir código fue económica: corregir el orden de los campos de un formulario en un prototipo cuesta minutos, y hacerlo sobre una interfaz ya implementada y desplegada cuesta un ciclo completo de compilación y despliegue.

Esa inversión se justificó en la práctica. La retroalimentación de las sesiones de revisión derivó en

dos tipos de cambio que se incorporaron antes de implementar: ajustes en el orden y agrupación de los campos del formulario de queja, y la incorporación de mensajes de validación explícitos donde el prototipo original solo mostraba el campo en rojo.

Los criterios de diseño aplicados a las aplicaciones web fueron los siguientes:

- **Identidad institucional.** La paleta y la estructura del encabezado y del pie siguen la identidad visual del Instituto, de modo que el usuario reconozca que se encuentra en un servicio oficial y no en un sitio de terceros.
- **Formularios por pasos.** Los formularios extensos se dividen en secciones numeradas en lugar de presentarse como una lista continua de campos, para reducir la carga cognitiva y hacer visible el progreso.
- **Ayuda contextual no intrusiva.** Los avisos normativos que el usuario debe conocer —como el plazo para presentar una queja— se presentan en un elemento flotante consultable en cualquier momento, en lugar de un bloque fijo que reduce el espacio útil del formulario.
- **Retroalimentación explícita.** Toda operación produce un mensaje visible de éxito, error o validación pendiente. Este criterio se elevó a requerimiento no funcional (RNF-Q07) porque su ausencia fue la causa de que, en una versión temprana, los mensajes de error existieran en el código pero no fueran visibles para el usuario.
- **Consistencia entre paneles de personal.** Las interfaces de administración, revisión, Primer Contacto y Subdefensoría comparten criterios visuales, patrones de error y estilos institucionales, para reducir diferencias innecesarias entre áreas.
- **Resultados de inteligencia artificial revisables.** La interfaz separa los antecedentes relacionados del borrador de resumen, identifica sus resultados como apoyos para el análisis y permite consultar la narrativa original al revisar el contenido.

Los prototipos completos y las capturas de las interfaces implementadas se presentan en el Capítulo 7 y en el anexo correspondiente.

Capítulo 6

Implementación y evaluación del prototipo

Este capítulo documenta cómo se construyó, se desplegó y se verificó la plataforma diseñada en el Capítulo 5.1. Se organiza siguiendo las capas del sistema: primero el entorno y las herramientas, después la implementación del lado del servidor, en seguida las aplicaciones web, luego el empaquetado en contenedores y la publicación en los servidores, y finalmente la implementación y evaluación de los componentes de inteligencia artificial y las pruebas realizadas. Cierra con un balance explícito de lo que quedó implementado y lo que no, porque un documento técnico que solo enumera logros no permite a nadie retomar el trabajo.

6.1. Entorno de desarrollo y herramientas

La plataforma se construyó con el conjunto de tecnologías cuyos fundamentos se expusieron en la Sección 4.2. La Tabla 6.1 resume la asignación concreta de cada herramienta a su función dentro del proyecto.

Tabla 6.1: Herramientas empleadas y su función en el proyecto

Capa	Herramienta	Función
Lenguaje del servidor	Java 21	Lenguaje de los microservicios de gestión institucional
Marco del servidor	Spring Boot	Autoconfiguración, servidor embebido, seguridad y persistencia
Construcción	Maven	Gestión de dependencias y empaquetado en archivo ejecutable
Persistencia	Spring Data JPA	Mapeo objeto-relacional y derivación de consultas
Base de datos	PostgreSQL 16	Almacén relacional único compartido
Autenticación	JSON Web Token	Tokens firmados con algoritmo simétrico
Documentación de la API	OpenAPI 3	Especificación e interfaz de exploración por servicio

Capa	Herramienta	Función
Hojas de cálculo	Apache POI	Generación del historial exportable y lectura de la importación masiva del catálogo
Cliente web	Angular 21	Aplicaciones web diferenciadas por rol
Contenedores	Podman	Empaquetado y ejecución de los servicios y aplicaciones en contenedores
Servidor web	Nginx	Proxy inverso público y entrega de archivos estáticos
Certificados	Certbot	Emisión y renovación automática del certificado de transporte
Control de versiones	Git	Historial del proyecto
Recuperación de antecedentes	Python, scikit-learn y MiniLM	Índices TF-IDF, embeddings semánticos y fusión de rankings
Resúmenes narrativos	Python, FastAPI y Qwen3	Selección extractiva y edición institucional
Inferencia y persistencia	llama.cpp y SQLite	Inferencia cuantizada en CPU y caché persistente de embeddings

Una característica del proyecto que conviene señalar desde el principio: cada microservicio es un proyecto de construcción independiente, sin un descriptor padre que los agrupe. La decisión simplifica la evolución de cada servicio por separado, pero tiene una consecuencia operativa concreta: no existe un comando único que compile todo el sistema, y cada servicio debe compilarse desde su propio directorio.

6.2. Implementación del lado del servidor

Los microservicios Java de gestión institucional siguen una estructura interna común. Esta uniformidad fue una decisión de implementación, no una consecuencia: cuando se construyó cada servicio nuevo se replicó la organización de carpetas, los filtros y el manejo de errores del anterior, en lugar de introducir un estilo distinto. El beneficio es que quien conoce un servicio reconoce la estructura de los restantes, y un defecto corregido en uno se localiza sin dificultad en los demás.

6.2.1. Estructura común de un microservicio

Cada servicio organiza su código en cinco paquetes que corresponden a las capas descritas en la Sección 4.1:

- `controller`. Puntos de acceso HTTP. Reciben y devuelven objetos de transferencia, nunca entidades de persistencia, y declaran el rol requerido para invocarlos.
- `service`. Lógica de negocio y validación de las reglas. Es la única capa que conoce las reglas del dominio; los controladores no validan reglas y los repositorios no las conocen.

- `repository`. Acceso a datos mediante interfaces de persistencia que derivan las consultas a partir del nombre de sus métodos, sin escribir sentencias SQL.
- `entity`. Entidades de persistencia con su correspondencia a tablas y columnas.
- `model`. Objetos de transferencia de datos para las peticiones y las respuestas.

La separación entre `entity` y `model` merece una justificación explícita, porque implica escribir clases que a primera vista parecen redundantes. Exponer directamente la entidad de persistencia en una respuesta HTTP acopla el contrato público del servicio a la estructura de la base de datos: cualquier columna nueva aparece automáticamente en la respuesta, incluidas las que no deberían ser públicas —la credencial cifrada de un usuario, por ejemplo—. Mantener objetos de transferencia separados obliga a decidir de forma consciente qué se expone.

6.2.2. Verificación de tokens y control de acceso

El mecanismo de autenticación se implementó como un filtro que se ejecuta antes de que la petición llegue al controlador. Su lógica es compartida por los servicios Java que requieren autenticación: extrae el token del encabezado de autorización, verifica su firma con la clave compartida, extrae de él la identidad y el rol, y establece el contexto de seguridad de la petición. Si el token falta, está vencido o su firma no coincide, el filtro rechaza la petición sin llegar a la lógica de negocio.

Sobre ese contexto se aplica la autorización, declarada en cada controlador mediante anotaciones que exigen un rol determinado. Un detalle de configuración que resultó relevante durante la implementación: cuando un mismo prefijo de ruta tiene una parte pública y una parte administrativa, el orden de declaración de las reglas importa, porque el marco de seguridad aplica la primera coincidencia. Declarar la regla pública antes de la administrativa hace que la menos restrictiva prevalezca por ser más genérica, y el resultado es un punto de acceso administrativo efectivamente abierto. Esta situación se atendió declarando siempre la regla más específica primero, y quedó registrada como regla de negocio RN-A05 justamente para que no se reintroduzca al agregar servicios nuevos.

6.2.3. Manejo centralizado de errores

Cada servicio implementa un manejador global de excepciones que traduce cualquier error de la capa de negocio a una respuesta con estructura uniforme: mensaje, marca de tiempo y código. La alternativa —capturar excepciones en cada controlador— se descartó porque produce respuestas de error con formatos distintos según el punto de acceso, y obliga al cliente a implementar tantas variantes de manejo de error como puntos de acceso consuma. Con el manejador centralizado, las aplicaciones web leen el mensaje de error siempre del mismo lugar.

6.2.4. Documentación de la interfaz de programación

Los servicios Java exponen su especificación en formato OpenAPI y una interfaz de exploración interactiva. Esta decisión resolvió un problema concreto de coordinación: durante el desarrollo del cliente, la única forma de conocer la forma exacta de una petición era leer el código del controlador correspondiente. Con la especificación publicada, el contrato de cada servicio es consultable sin abrir el código.

6.2.5. Puntos de acceso implementados

La Tabla 6.2 presenta los puntos de acceso principales agrupados por servicio, con su condición de acceso. La especificación completa de cada uno, con sus parámetros y respuestas, se consulta en la interfaz de exploración de cada servicio y se reproduce en el anexo correspondiente.

Tabla 6.2: Puntos de acceso principales por microservicio

Servicio	Punto de acceso	Acceso
auth-service	POST /api/auth/login	Público
	POST /api/auth/activar-cuenta	Público
	POST /api/auth/solicitar-codigo	Público
	POST /api/auth/reset-password	Público
	GET y PUT /api/auth/me, /api/auth/perfil	Sesión de quejoso
queja-service	POST /api/quejoso/quejas/registro-publico	Público
	GET /api/quejoso/quejas/folio/{folio}	Público
	POST /api/quejoso/quejas/registrar	Sesión de quejoso
	GET /api/quejoso/quejas/mias	Sesión de quejoso
	GET y PUT /api/quejoso/quejas/mias/{folio}	Sesión de quejoso
	GET y PUT /api/quejoso/conciliaciones/**	Sesión de quejoso
notificaciones-service	GET /api/notificaciones/mias y /mias/no-leidas	Sesión de quejoso
	PUT /api/notificaciones/{id}/leida	Sesión de quejoso
	POST /api/notificaciones/enviar y /registrar	Uso interno entre servicios
catalogo-service	GET /api/catalogos/dependencias y /dependencias/{clave}	Público
	GET, POST, PUT /api/catalogos/dependencias/admin/**	Administración
	POST /api/catalogos/dependencias/admin/importar-excel	Administración
admin-service	POST /api/admin/auth/login	Público
	GET, POST, PUT, DELETE /api/admin/personal/**	Administración
	GET y PUT /api/admin/plantillas/**	Administración
	GET y POST /api/admin/seguridad/respaldos/**	Administración
	POST /api/admin/seguridad/restaurar	Administración
	GET /api/admin/seguridad/bitacora	Administración
	GET /api/admin/dashboard/resumen	Administración
	PUT /api/admin/perfil/password	Cualquier cuenta de personal
revision-service	GET /api/revision/bandeja	Recepción
	GET /api/revision/quejas/{folio} y /antecedentes	Recepción
	GET /api/revision/quejas/evidencias/{id}	Recepción
	POST /api/revision/quejas/{folio}/rechazar y /turnar	Recepción
	POST /api/revision/registro-manual	Recepción

Servicio	Punto de acceso	Acceso
	`GET /api/revision/historial` y `/historial/exportar`	Recepción
	`GET /api/revision/catalogos/areas` y `/defensores`	Recepción
	`POST` y `GET /api/revision/conciliaciones`	Recepción
`chatbot-service`	`GET /api/chatbot/menu`	Público
	`GET, POST, PUT, DELETE /api/chatbot/admin/preguntas/**`	Administración
`antecedentes-se`	`POST /api/antecedentes/buscar`	Uso interno
`resumen-service`	`POST /resumir`	Uso interno

6.3. Implementación de las aplicaciones web

Las aplicaciones web se desarrollaron como aplicaciones de página única con componentes autónomos, sin el sistema de módulos de versiones anteriores del marco de trabajo. Cada aplicación es un proyecto independiente con su propio árbol de rutas, su guarda de autenticación y sus interceptores.

6.3.1. Estructura común

Estas aplicaciones comparten una organización general: una capa `core` con los servicios de comunicación con el servidor, los modelos de datos y la configuración de seguridad del cliente; una capa `shared` con los componentes reutilizables —encabezado, pie, avisos, ayuda flotante—; y una capa `pages` con un componente por pantalla, cargado de forma diferida para que el navegador no descargue el código de pantallas que el usuario no ha visitado.

6.3.2. Interceptores y guardas

Dos piezas transversales resuelven problemas que de otro modo habría que repetir en cada pantalla.

El **interceptor de autorización** agrega el token de sesión al encabezado de cada petición saliente, de modo que ningún servicio de la aplicación tiene que recordar hacerlo. El mismo interceptor detecta las respuestas de sesión inválida o insuficiente y, en ese caso, cierra la sesión local y redirige al inicio de sesión. Esto implementa el requerimiento RNF-Q06 en un solo punto del código.

La **guarda de rutas** impide el acceso a las secciones autenticadas cuando no existe una sesión válida en el cliente. Es importante entender su alcance: la guarda es una medida de usabilidad, no de seguridad, porque se ejecuta en el navegador y puede eludirse. La seguridad real la aplica el servidor, que rechaza cualquier petición sin token válido con independencia de lo que haga el cliente. Confundir ambas cosas es un error frecuente y por eso se hace explícito.

6.3.3. Detección de cambios sin zonas

La versión del marco de trabajo empleada permite ejecutar la aplicación sin la biblioteca que tradicionalmente intercepta las operaciones asíncronas para disparar la actualización de la vista. Ese

modo reduce el trabajo del navegador, pero tiene una consecuencia que apareció durante la implementación: la vista no se actualizaba de forma automática al recibir la respuesta de una petición, de modo que los datos llegaban pero la pantalla seguía mostrando el estado anterior.

La solución adoptada fue un interceptor adicional que solicita de forma explícita una actualización de la vista tras cada respuesta del servidor. Se documenta aquí porque es una particularidad no evidente del entorno y porque cualquier pantalla nueva que se agregue al proyecto depende de que ese interceptor siga registrado.

6.4. Empaquetado en contenedores y despliegue

El sistema se ejecuta mediante contenedores distribuidos según sus responsabilidades, sobre la infraestructura descrita en la Sección 5.6. La Tabla 6.3 presenta los principales componentes de despliegue, sin incluir los contenedores auxiliares de prueba.

Tabla 6.3: Matriz de despliegue en contenedores

Contenedor	Servidor	Contenido
Base de datos	Aplicación	PostgreSQL 16 con almacenamiento persistente
`auth-service`	Aplicación	Imagen dedicada del servicio de autenticación
`quejas-service`	Aplicación	Imagen dedicada del servicio de quejas
`notificaciones-service`	Aplicación	Imagen dedicada del servicio de notificaciones
`catalogo-service`	Aplicación	Imagen dedicada del servicio de catálogo
`admin-service`	Aplicación	Imagen propia que incluye el cliente de la base de datos, necesario para generar y restaurar respaldos
`revision-service`	Aplicación	Imagen dedicada del servicio de revisión
`chatbot-service`	Aplicación	Imagen dedicada del servicio de preguntas frecuentes
Portal del quejoso	Acceso público	Servidor de estáticos con la aplicación compilada
Consola de administración	Acceso público	Servidor de estáticos con la aplicación compilada
Panel de revisión	Acceso público	Servidor de estáticos con la aplicación compilada
Proxy inverso	Acceso público	Nginx con la configuración de enrutamiento y el certificado de transporte
Servicio de antecedentes	Aplicación / IA	Recuperación léxica y semántica y caché de embeddings
Servicio de resúmenes	Aplicación / IA	Selección extractiva y edición institucional
Servidor Qwen3	Aplicación / IA	Inferencia cuantizada en CPU con llama.cpp
Panel de Primer Contacto	Acceso público	Interfaz de análisis asistido por IA

Contenedor	Servidor	Contenido
Panel de Subdefensoría	Acceso público	Interfaz institucional de gestión de expedientes

6.4.1. Configuración externalizada

Cada microservicio monta su configuración de producción como un volumen del contenedor, en lugar de incluirla en la imagen. La consecuencia práctica es una distinción importante en el procedimiento de operación: un cambio de configuración —una dirección, un tiempo de expiración— se aplica editando el archivo montado y reiniciando el contenedor, mientras que un cambio de lógica exige recompilar el servicio, generar un artefacto nuevo y reconstruir la imagen. Esta separación es la que permite que la misma imagen sirva en cualquier ambiente sin reconstruirse, tal como se expuso en la Sección 4.2.

Durante la operación apareció una consecuencia no evidente de este esquema: editar el archivo de configuración en el servidor anfitrión no basta para que el contenedor lo tome, porque el punto de montaje conserva la referencia al archivo original. Es necesario reiniciar el contenedor, no solo recargar el servicio. Se documenta porque es una fuente de diagnósticos erróneos: el archivo se ve correcto en el servidor y el servicio sigue comportándose como antes.

6.4.2. Publicación segura y cifrado del canal

La publicación al exterior se resolvió en tres pasos. Primero se restringió el cortafuegos del servidor de aplicación para que los puertos de los microservicios y de la base de datos aceptaran conexiones únicamente desde la dirección del servidor de acceso público, dejando fuera cualquier otro origen de Internet. Después se configuró el proxy inverso del servidor de acceso público con las reglas de enrutamiento de la Tabla 5.17. Por último se emitió el certificado de transporte mediante el método de validación por directorio web, se reconfiguró el proxy para atender el puerto cifrado y se dejó el puerto sin cifrar únicamente para redirigir el tráfico y atender la renovación automática del certificado.

Durante este proceso se documentaron dos incidentes que conviene registrar por su valor diagnóstico. El primero fue una aparente imposibilidad de alcanzar los puertos web del servidor de acceso público desde el exterior, mientras que el puerto de administración remota respondía con normalidad. Tras descartar de forma sistemática la configuración del servicio, la publicación del contenedor y el cortafuegos local, se identificó que la causa era una regla de cortafuegos del proveedor que estaba guardada pero no sincronizada con la máquina virtual: existía en el panel de control pero no se había aplicado. El segundo fue un aviso recurrente del motor de contenedores sobre una red virtual mal configurada, que provenía de un intento previo de crear una red propia que finalmente no se utilizó; su eliminación resolvió el aviso. Ambos casos ilustran un principio de diagnóstico útil: cuando un componente responde de forma local y no desde el exterior, el problema no está en el componente sino en el camino.

6.5. Implementación de la búsqueda de antecedentes

El servicio de búsqueda de antecedentes se implementó en Python y se expone mediante una interfaz HTTP. Para cada consulta recibe la descripción de una queja, recupera registros existentes y devuelve documentos ordenados para su revisión por el personal autorizado. La recuperación combina dos representaciones complementarias. La primera utiliza TF-IDF con unigramas y bigramas para identificar coincidencias léxicas; la segunda obtiene representaciones semánticas con un modelo multilingüe de la familia MiniLM, a través de Sentence Transformers. Las puntuaciones de ambas técnicas no se suman directamente: cada recuperador genera su propia clasificación de candidatos y estos ordenamientos se integran mediante Reciprocal Rank Fusion (RRF) ponderado, descrito en el Marco Teórico. En la configuración final adoptada para el sistema se asignó un peso del 75 % al ordenamiento de TF-IDF y del 25 % al de MiniLM. Estos pesos corresponden a la fusión de rankings, no a una suma directa de las similitudes. Su elección representa una decisión de implementación y no demuestra una configuración universalmente óptima para cualquier conjunto de quejas.

6.5.1. Preparación del índice y fragmentación

Los documentos se leen desde las tablas de quejas e histórico mediante consultas de solo lectura. Para la comparación semántica, el contenido extenso se divide en fragmentos de hasta 128 tokens, con un solapamiento de 24 tokens. Esta fragmentación permite representar secciones diferentes de un mismo expediente, en lugar de depender únicamente de una representación global de toda la narración.

El procesamiento inicial obtiene las representaciones vectoriales y las almacena en una caché persistente basada en SQLite. La clave de cada entrada depende de una huella del contenido y de la configuración de representación. Cuando se actualiza el índice, las entradas de documentos sin cambios se reutilizan; las nuevas o modificadas se procesan de nuevo. La construcción ocurre sin bloquear el inicio de la API y el índice vigente se sustituye cuando la actualización termina.

6.5.2. Recuperación y ordenamiento

La consulta se transforma tanto en un vector TF-IDF como en representaciones semánticas. Para interpretar y reproducir el resultado de documentos extensos, es necesario registrar cómo se agregan las puntuaciones de sus fragmentos y cómo se excluyen, cuando corresponde, las autocoincidencias de las consultas de evaluación. La información experimental presentada no permite verificar por sí sola estos dos aspectos. Se generan listas de candidatos de cada recuperador y se combinan sus posiciones mediante RRF ponderado. La implementación emplea una constante de suavizado de 60 y ponderaciones finales 0.75 para TF-IDF y 0.25 para MiniLM. Las demás combinaciones se examinaron experimentalmente; no se presupone que la configuración desplegada sea óptima para cualquier tipo de consulta.

El servicio conserva las medidas léxica y semántica por separado, además de la puntuación de fusión. La puntuación RRF es una señal de ordenamiento, no una probabilidad de que dos quejas se refieran al mismo hecho. Por ello, cualquier porcentaje mostrado en la interfaz debe identificarse por su origen (por ejemplo, similitud léxica o semántica), sin presentarlo como una probabilidad

calibrada de duplicidad. Los resultados pueden agruparse por semejanzas narrativas o coincidencias de personas y otros datos, pero la confirmación de duplicidad permanece bajo revisión humana.

6.6. Implementación de la generación de resúmenes

El servicio de resúmenes utiliza una secuencia extractiva-generativa. Primero, un procedimiento de selección documental basado en relevancia, redundancia y reglas de conservación de contexto obtiene una captura extractiva a partir de la narración de la queja. La selección incorpora el principio de Maximum Marginal Relevance (MMR) y criterios adicionales para priorizar hechos y reducir repeticiones. Posteriormente, un modelo generativo basado en Qwen3 recibe la captura seleccionada y produce un borrador de estilo institucional y en tercera persona, utilizando instrucciones para conservar actores, negaciones, fechas, cantidades, evidencias y solicitudes. La denominación de editor lingüístico describe su función prevista, pero no garantiza que el modelo conserve todos los hechos de la captura.

6.6.1. Ejecución del editor lingüístico

El editor utiliza un modelo Qwen3 de cuatro mil millones de parámetros, cuantizado en formato Q4_K_M y servido por llama.cpp. La inferencia se ejecuta en CPU mediante un proceso independiente del servicio HTTP que expone el resumen. Esta separación permite modificar el procesamiento extractivo sin reconstruir el servidor del modelo y viceversa.

La captura se divide en bloques de hasta seis oraciones y con una referencia de 120 palabras como límite por bloque. Cada bloque se edita secuencialmente, con un límite de generación de hasta 450 tokens. Se implementó un presupuesto aproximado de 95 segundos para la etapa de edición, con el objetivo de reducir el riesgo de agotar el tiempo de espera del consumidor Java. Cuando un bloque no puede editarse satisfactoriamente, se conserva su contenido extractivo original. Este mecanismo evita perder el bloque por un fallo de generación, pero no garantiza la fidelidad completa de un resumen.

6.6.2. Respuesta y revisión humana

El servicio expone una operación HTTP para generar el borrador y devuelve tanto el texto editado como la captura extractiva de la que partió. La respuesta indica que requiere revisión humana. El resultado no constituye una resolución jurídica ni reemplaza la queja original; su propósito es apoyar la lectura inicial del expediente.

6.7. Evaluación experimental de los componentes de inteligencia artificial

La evaluación de antecedentes se organizó en consultas sintéticas con referencias de relevancia y casos contrastivos. Se consideraron métricas de recuperación y ordenamiento, entre ellas Precision@k, Recall@k, MRR y nDCG@k. Se preparó una exploración de ponderaciones de RRF del 0

al 100 por ciento para cada recuperador, manteniendo la suma de pesos constante. La configuración final elegida para la plataforma fue 75 % TF-IDF y 25 % MiniLM. Esta elección debe interpretarse como una decisión de compromiso: en las 200 quejas extensas alcanzó un P@5 de 52.0 %, próximo al 52.3 % de 90/10; en las 15 consultas contrastivas alcanzó un R@10 de 13.3 %, por lo que no puede afirmarse que funcione igual de bien ante paráfrasis complejas. La selección se realizó a partir de las pruebas sintéticas disponibles y de las necesidades de integración del prototipo, sin considerar estos resultados una validación definitiva de su desempeño institucional. No fue posible completar una validación con expedientes reales ni una revisión formal de los resultados por personal de la Defensoría dentro del tiempo disponible para el Trabajo Terminal. Asimismo, el protocolo de separación entre datos de ajuste y de evaluación final requiere documentarse con mayor detalle para establecer la reproducibilidad de las comparaciones. Los resultados experimentales se presentan en el capítulo de pruebas y sus anexos.

En la verificación de infraestructura se observó un índice de 1 210 registros. En una actualización sin modificaciones de documentos se reutilizaron 1 210 representaciones almacenadas y no fue necesario recalcularlas. Para el servicio de resúmenes se ejecutó una solicitud sintética que obtuvo respuesta HTTP 200 en 26.3 segundos. Esta medición es un caso de prueba y no constituye una garantía de latencia para cualquier entrada.

La revisión de dicha salida identificó omisiones de hechos presentes en el texto de entrada, incluidas fechas y un cambio de calificación. Con la evidencia recopilada no fue posible establecer si esas omisiones se produjeron durante la selección extractiva basada en MMR, durante la reformulación con Qwen3 o por la interacción entre ambas etapas. Una evaluación técnica por etapas puede realizarse con narrativas sintéticas controladas comparando la entrada original, la captura extractiva y el borrador generado. Sin embargo, la evaluación sistemática de fidelidad y utilidad de los resúmenes para el procedimiento institucional requeriría incorporar expedientes reales debidamente autorizados y criterios de revisión acordados con personal de la Defensoría. Esta validación institucional no se completó por las restricciones de tiempo del Trabajo Terminal. Por tanto, las pruebas realizadas verifican el funcionamiento del componente e identifican limitaciones observadas, pero no acreditan su calidad general en casos reales.

6.8. Pruebas y verificación

La verificación de la plataforma combinó pruebas automatizadas de lógica de negocio, comprobaciones de integración, revisiones de configuración y recorridos funcionales manuales. Estas actividades ofrecen evidencias de distinto alcance y no deben interpretarse como equivalentes. Los casos, sus resultados y las verificaciones pendientes se detallan en el Capítulo 8.

- **Compilación y empaquetado.** Los microservicios Java se construyeron con Maven y las aplicaciones web se compilaron en modo de producción. Esta verificación identifica errores de construcción, pero no acredita por sí sola el cumplimiento de las reglas de negocio.
- **Pruebas unitarias automatizadas.** Se utilizaron JUnit 5 y Mockito para verificar lógica y validaciones de los microservicios sin depender de la base de datos ni de servicios externos. En la ejecución documentada se reportaron 364 casos aprobados, sin fallas ni errores. Posteriormente se incorporaron ocho casos de resiliencia, cuyo resultado debe distinguirse del conteo inicial.

- **Integración y puntos de acceso.** Se realizaron comprobaciones de contratos HTTP, autorización, interacción entre servicios y conectividad a través del proxy inverso. Algunas fueron ejecutadas dinámicamente, otras se comprobaron mediante inspección de código o configuración y otras permanecen pendientes; el Capítulo 8 especifica su estado por caso.
- **Recorridos de sistema.** Se revisaron manualmente flujos de registro, recepción, turnado y seguimiento. La automatización integral de los recorridos de extremo a extremo mediante Playwright aún no estaba concluida.

En consecuencia, no es correcto afirmar que toda la verificación fue manual ni que existe una cobertura automatizada integral. Las pruebas unitarias proporcionan una base de regresión para reglas específicas; la cobertura de líneas, los casos pendientes de seguridad, capacidad, aceptación y los flujos completos todavía requieren evidencias adicionales. Tampoco se documenta aquí la existencia de una integración continua que ejecute automáticamente todas las suites.

6.9. Estado de avance por componente

La Tabla 6.4 presenta el balance de lo implementado al cierre de esta etapa. Se incluye de forma deliberada la columna de lo no implementado, porque el valor de este balance para quien retome el proyecto está en lo que falta, no en lo que ya está.

Tabla 6.4: Estado de avance por componente al cierre de la etapa

Componente	Estado	Observaciones
Portal del quejoso	Operativo	Los diecisiete requerimientos funcionales del actor están implementados y desplegados
Panel de revisión	Operativo	Los trece requerimientos del actor de recepción están implementados
Consola de administración	Operativo	Los nueve requerimientos de administración están implementados
Paneles de Primer Contacto y Subdefensoría	Operativos	Disponen de interfaces institucionales; su cobertura debe contrastarse con los casos de uso definitivos
Búsqueda de antecedentes	Integrada	Recuperación híbrida disponible para Primer Contacto, con revisión humana de los resultados
Generación de resúmenes	Integrada, sin validación institucional	Captura extractiva y edición con Qwen3; probado con narrativas sintéticas. No se completó su evaluación con expedientes reales y personal de la Defensoría por limitaciones de tiempo; los borradores requieren revisión humana
Cierre de sesión por inactividad	Pendiente	La expiración del token limita la ventana de exposición, pero no equivale a un cierre por inactividad
Automatización integral de pruebas	Parcial	Se reportaron 364 pruebas unitarias aprobadas y se prepararon ocho casos adicionales de resiliencia; continúan pendientes la automatización integral de recorridos y verificaciones de sistema

Componente	Estado	Observaciones
Corrección de hallazgos de análisis estático	Pendiente	Las vulnerabilidades de neutralización de entradas y de generación pseudoaleatoria identificadas requieren remediación prioritaria
Separación de los cortafuegos por servidor	Pendiente	Ambos servidores comparten el mismo grupo de reglas; no hay exposición real hoy, pero conviene separarlos

Capítulo 7

Módulos de la Plataforma

Este capítulo presenta, de forma breve, qué encuentra cada actor al entrar a su aplicación y cómo avanza una queja de un módulo al siguiente. Las funciones, reglas y estados que aquí se mencionan están especificados en el Capítulo 5; entre paréntesis se indica el caso de uso que implementa cada pantalla.

7.1. Portal del quejoso

Es la única aplicación dirigida al público y se publica en la raíz del dominio. Su área pública permite presentar una queja con un formulario en pasos numerados, que previsualiza los archivos y señala en cada campo la regla que incumple (CU-QJ-07); consultar una queja con el folio y el correo (CU-QJ-11); activar la cuenta de seguimiento, iniciar sesión y recuperar la contraseña (CU-QJ-01 a CU-QJ-04); responder sin sesión las citas y los acuerdos recibidos por correo (CU-PC-04, CU-QJ-14), y consultar el asistente de preguntas frecuentes (CU-QJ-06). El panel autenticado reúne el resumen de las quejas propias, su detalle con la línea de tiempo y las acciones que permite cada estatus —editar o cancelar en `RECIBIDA`, corregir en `RECHAZADA`— (CU-QJ-08 a CU-QJ-10, CU-QJ-12, CU-QJ-15), los acuerdos de conciliación (CU-QJ-13, CU-QJ-14), las notificaciones (CU-NOT-01) y el perfil (CU-QJ-05).

7.2. Respuesta de la persona señalada

La página `/denunciado/respuesta` forma parte del portal, pero está dirigida a la persona a quien se atribuyen los hechos. Muestra el folio de la queja recibido en el enlace, solicita su identidad, su versión de los hechos, su credencial y sus evidencias, exige su aviso de privacidad y entrega un folio de respuesta (RF-D01, RF-D02).

7.3. Panel de Recepción

Su pantalla de inicio de sesión es la entrada única del personal, que es dirigido al panel de su rol (CU-ADM-07). La bandeja muestra los indicadores del día, la cola paginada y la actividad

de cada recepcionista (CU-REC-01). Al abrir una queja, esta queda asignada a quien la abrió y se presenta la pantalla de validación: los datos y documentos a la izquierda (CU-REC-03) y, a la derecha, la lista de verificación de los cinco requisitos de admisión con su fundamento, el catálogo de documentos aceptados y el cómputo automático del plazo de 90 días (CU-REC-02). Con los cinco requisitos satisfechos se habilita el turnado, que muestra los antecedentes de la queja y sugiere al abogado de menor carga (CU-REC-05); con alguno incumplido, solo puede regresarse al quejoso con observaciones (CU-REC-04). El panel incluye además el registro en ventanilla, que reutiliza el formulario del portal (CU-REC-08), y el historial con exportación a Excel (CU-REC-07).

7.4. Panel de Primer Contacto

La bandeja lista los expedientes turnados con su prioridad y estatus (CU-PC-02). Al abrir un expediente, este pasa a `EN_ANALISIS` (CU-PC-03) y se presenta en cuatro pestañas:

- **Análisis IA.** Borrador de resumen con botones para copiarlo y ver la narración completa; fragmentos clave etiquetados por tema —inicio del contexto, hechos principales, consecuencia, trato recibido—; los cuatro antecedentes más parecidos con su porcentaje de similitud y una gráfica de barras; y el acceso al análisis detallado de antecedentes, donde pueden guardarse o buscarse manualmente. Si el componente no responde, la pestaña lo indica.
- **Expediente.** Narración, datos de las partes, evidencias e historial del expediente como línea de tiempo.
- **Gestión.** Oficios con su PDF (CU-PC-05), solicitud y versión de la persona señalada (RF-D03), citas (CU-PC-04) y propuesta de conciliación (CU-PC-10).
- **Resolución.** Dictamen de competencia, con el responsable en Subdefensoría elegido por carga, o de improcedencia con su remisión (CU-PC-06 a CU-PC-09).

La agenda presenta las citas en calendario y en lista, y su ventana de programación muestra cada horario como disponible, ocupado o no disponible (CU-PC-04).

7.5. Panel de Subdefensoría

El panel se organiza alrededor del siguiente paso de cada expediente. El inicio muestra los pendientes del día ordenados por urgencia y los expedientes que vencen pronto; “Mis expedientes” los agrupa por etapa con una barra de plazo (CU-SD-02, CU-SD-03); el expediente reúne lo actuado en Primer Contacto, en modo de solo lectura, y las acciones de investigación —oficios, recordatorios, respuesta de la unidad y acuerdos— (CU-SD-05 a CU-SD-09); y “Plazos y oficios” concentra las alertas de vencimiento (CU-SD-04).

7.6. Panel de la Defensora

Es exclusivo del rol `DEFENSOR`. En la sección de supervisión, el panel general muestra los indicadores del periodo, la distribución de las quejas por etapa, su evolución mensual, las unidades con más

quejas, la carga del personal y los casos que requieren atención según las reglas de la Tabla 7.1; cada número abre la lista filtrada que lo explica. Desde el explorador de quejas, la Defensora filtra por prioridad y revisa directamente el detalle de las quejas prioritarias (CU-ADM-03). En la sección de administración gestiona el personal (CU-ADM-01, CU-ADM-02), el catálogo de dependencias (CU-ADM-06), las plantillas oficiales (CU-ADM-04), las preguntas frecuentes (CU-BOT-01) y los respaldos con la bitácora (CU-ADM-05).

Tabla 7.1: Reglas de “Casos que requieren atención”

Regla	Condición
Sin tomar	Más de 3 días en Recepción sin abrirse
Corregida sin revisar	Más de 3 días desde la corrección
Validación detenida	Abierta por una recepcionista hace más de 1 día
Observaciones pendientes	El quejoso no ha corregido en más de 5 días
Sin abogado	En Primer Contacto sin abogado asignado
Vencida (Primer Contacto)	Más de 10 días en Primer Contacto
Sin turnar a Subdefensoría	Procedente hace más de 15 días
Vencida (seguimiento)	Más de 60 días en Subdefensoría

Los días se muestran en rojo cuando alcanzan el doble del plazo de la regla.

Capítulo 8

Pruebas

Este capítulo documenta la verificación de la plataforma: la estrategia con que se diseñaron las pruebas y los casos y resultados de cada característica de calidad. Las pruebas se organizan siguiendo el modelo ISO/IEC 25010 [49] con que se clasificaron los requerimientos no funcionales (Tabla 5.8), en siete secciones: funcionalidad, mantenibilidad, usabilidad, fiabilidad, seguridad, capacidad y confidencialidad. Cada caso de prueba indica el requerimiento que verifica, lo que permite rastrear cada requerimiento hasta la evidencia que lo respalda.

Una advertencia de método acompaña a todo el capítulo: probar no demuestra la ausencia de defectos, solo reduce el riesgo de que existan [50]. Por eso las pruebas se priorizaron según el daño que causaría cada falla, y los resultados se reportan tal como se obtuvieron, incluidas las pruebas que fallaron y las que siguen pendientes de ejecutarse.

8.1. Estrategia de pruebas

8.1.1. Niveles y técnicas

La estrategia sigue el modelo en V, en el que cada nivel de prueba verifica el artefacto del nivel de diseño correspondiente [51]:

- **Pruebas de componente (unitarias).** Verifican una clase de reglas o de servicio de forma aislada, sustituyendo sus dependencias por objetos simulados. Se aplican solo a la lógica que toma decisiones; no se prueban métodos de acceso, DTO ni repositorios generados.

- **Pruebas de integración.** Verifican la colaboración de un servicio con su base de datos, su configuración de seguridad y los servicios que invoca. Se siguió una estrategia ascendente: primero cada servicio con su base, después los pares de servicios.

- **Pruebas de sistema.** Recorren los casos de uso de extremo a extremo sobre el sistema desplegado en un entorno de pruebas.

- **Pruebas de aceptación.** Ejecutadas por personal de la Defensoría, o por personas que actúan cada rol, bajo supervisión del equipo (pruebas alfa).

Según la información disponible para diseñarlas, las pruebas son de **caja blanca** —se diseñan a partir del código, como las unitarias y la verificación estática de permisos— o de **caja negra** —se diseñan a partir de la especificación y se ejecutan contra la interfaz pública, como las de seguridad dinámica y de confidencialidad—. Según su forma de ejecución, son **estáticas**, si analizan el código o la configuración sin ejecutarlos, o **dinámicas**, si ejecutan el sistema. Para diseñar los datos de entrada se emplearon las técnicas de particiones de equivalencia, análisis de valores límite, tablas de decisión y transición de estados [50]; por ejemplo, el plazo de 90 días se prueba con 89, 90 y 91 días, y la máquina de estados de la queja con cada transición permitida y con las prohibidas.

8.1.2. Prioridad basada en riesgo

No es viable probar todas las combinaciones de entrada, de modo que el esfuerzo se asignó según el daño que causaría cada falla. Son de prioridad P1 los riesgos de acceso indebido a datos personales, de ruptura del ciclo de estatus, de atención simultánea de una queja por dos recepcionistas, de falla en el paso de expedientes entre áreas y de exposición del tráfico o de los secretos; de prioridad P2, los errores en plazos y datos obligatorios, la pérdida de respaldos y la caída de servicios auxiliares; y de prioridad P3, la lentitud y las pantallas confusas.

8.1.3. Entorno y criterios

Las pruebas dinámicas se ejecutan en un entorno de pruebas y no en producción: una base PostgreSQL 16 dedicada, sembrada con los datos de referencia y con la carga masiva de quejas sintéticas, los mismos artefactos que se despliegan y una cuenta de prueba por rol. Las pruebas estáticas y unitarias no necesitan el sistema levantado. Se definieron los siguientes criterios:

- **Entrada:** el código compila sin errores y el entorno de pruebas está disponible.
- **Salida:** todos los casos P1 ejecutados y aprobados, al menos el 90 % de los P2 ejecutados, ningún defecto crítico o alto abierto, cobertura de al menos 70 % en las clases de reglas, percentil 95 menor a 1 s en la prueba de carga y puntaje SUS de al menos 68.
- **Suspensión:** si un defecto crítico bloquea más del 30 % de los casos, se detiene la ejecución hasta corregirlo.

8.2. Pruebas de funcionalidad

Las pruebas de funcionalidad verifican la adecuación funcional: que las reglas de negocio y los casos de uso se comporten como se especificaron.

8.2.1. Pruebas unitarias

Se escribieron pruebas unitarias con JUnit 5 y Mockito para los diez microservicios Java desarrollados para la plataforma [52], [53]. Las pruebas no levantan el contexto de Spring ni requieren base de datos o red: las dependencias se sustituyen por objetos simulados, lo que permite ejecutarlas en

segundos en cada compilación. Siguen el patrón preparar–actuar–verificar, incluyen un mensaje en cada aserción y se diseñaron con particiones de equivalencia y valores límite. La Tabla 8.1 resume su alcance.

Tabla 8.1: Pruebas unitarias por microservicio

Servicio	Casos	Qué verifican
`quejas-service`	112	Validadores del registro público: correo en dos niveles, fechas, nombres, boleta, tutor y archivos por firma binaria; edición, corrección y cancelación; conciliación (RN-Q01 a RN-Q12)
`primer-contacto-se`	55	Citas sin empalmes, plazo y rango máximo de consulta, token de respuesta; dictamen con Subdefensoría caída; sincronización de estatus; motor de antecedentes (RN-PC01 a RN-PC04)
`admin-service`	36	Cuentas del personal y protección de la última cuenta de administración; bitácora con IP real; plantillas; respaldos en carpeta temporal; tablero (RN-A01 a RN-A04, RNF-A07)
`auth-service`	36	Inicio de sesión, recuperación con código (cinco intentos, diez minutos), política de contraseñas, activación y emisión del token (RN-Q06 a RN-Q08)
`revision-service`	36	Toma atómica entre recepcionistas, regreso, turnado idempotente, ventanilla e historial (RN-R01 a RN-R07, RNF-R06)
`denunciado-service`	29	Todas las reglas del registro de la versión de la persona señalada (RF-D01)
`subdefensoria-serv`	24	Días hábiles (10 y 5), semáforo y alertas de vencimiento, archivo de respuesta (RN-SD01, RN-SD02)
`notificaciones-ser`	20	Centro de notificaciones e inyección de encabezados en el correo (CWE-93)
`catalogo-service`	8	Alta, edición e importación de Excel tolerante a errores (RNF-A04)
`chatbot-service`	8	Menú agrupado y administración de preguntas
Total	**364**	

Resultado. Los 364 casos se ejecutaron con Maven y resultaron aprobados (0 fallas, 0 errores). La única prueba que requería base de datos —la carga del contexto de Primer Contacto— se etiquetó como de integración y se excluye de la ejecución unitaria, para que la suite no dependa del entorno. Posteriormente se incorporaron ocho casos de resiliencia, descritos en la Sección 8.5; al cierre documentado se señala que FIA-05 y FIA-06 están implementadas, pero pendientes de su primera ejecución. Por esa razón, esos ocho casos no se suman a las 364 pruebas aprobadas.

8.2.2. Pruebas de integración y de sistema

La Tabla 8.2 lista los casos de integración y de sistema de prioridad P1 y P2 con su resultado. Los que tienen evidencia se ejecutaron durante el desarrollo de cada módulo con guiones y con el navegador; los marcados como pendientes forman parte de la suite de sistema que se ejecutará en el entorno de pruebas antes de la entrega a la Defensoría.

Tabla 8.2: Pruebas de integración y de sistema

ID	Qué se verifica	Requerimient	Tipo	Resultado
IT-06	Dos recepcionistas abren la misma queja al mismo tiempo; solo una la obtiene	RNF-R06, RN-R03	Dinámica, CN	Aprobada (10 de 10 intentos concurrentes)
IT-20	Activar una cuenta solo con un par folio–correo válido	RN-Q06	Dinámica, CB	Aprobada en prueba unitaria; dinámica pendiente
IT-22	La queja turnada aparece en la bandeja de Primer Contacto	CU-REC-05, CU-PC-01	Dinámica, CN	Aprobada en el sistema desplegado
IT-23	El dictamen competente crea el expediente en Subdefensoría	CU-PC-06, CU-SD-01	Dinámica, CN	Aprobada en entorno local con la base de pruebas
IT-24	El cambio de estatus en Primer Contacto se refleja en la tabla de quejas	RN-R01	Dinámica, CB	Aprobada en prueba unitaria de sincronización
IT-09	Los indicadores del panel de la Defensora coinciden con datos sembrados en PostgreSQL 16	CU-ADM-03	Dinámica, CB	Aprobada
IT-11	Inicio de sesión unificado: siete escenarios (sin sesión, enlace antiguo, Defensora en Recepción, cierre de sesión, recepcionista hacia el panel de la Defensora, entre otros)	CU-ADM-07, RNF-R02	Dinámica, CN	Aprobada (7 de 7)
IT-12	Registro de la persona señalada con datos válidos, nombres con dígitos, ejecutable renombrado, credencial PDF o de 4 MB, tres credenciales y sin aviso	RF-D01, RNF-G08	Dinámica, CB	Aprobada (19 de 19)
REN-02	Carga masiva de quejas sintéticas por el registro público, con credencial y evidencias	CU-QJ-07	Dinámica, CN	Aprobada (170 quejas)
ST-01 a ST-14	Recorridos de extremo a extremo por actor, automatizados con Playwright	Casos de uso	Dinámica, CN	Pendiente: suite por automatizar; recorridos verificados manualmente

Compilación de producción. Las cinco aplicaciones web se compilan con la configuración de producción, que falla si un componente excede su presupuesto de tamaño o si una plantilla hace referencia a un elemento inexistente. Las cinco compilan sin errores.

8.3. Pruebas de mantenibilidad

La mantenibilidad se verificó con pruebas estáticas de caja blanca sobre el código Java de ocho de los diez servicios (225 archivos), y con la cobertura de las pruebas unitarias. Primer Contacto y Subdefensoría se analizaron con las mismas reglas de forma informativa.

8.3.1. Guía de estilo

El proyecto adoptó como guía de estilo el Google Java Style Guide [54], con cuatro desviaciones que reflejan lo que el código ya seguía de forma consistente, para no reformatear todo el proyecto sin aportar calidad —sangría de 4 espacios en lugar de 2, líneas de 120 columnas en lugar de 100, guion bajo permitido en los nombres de paquete y el registrador `log` en minúsculas—. La guía se codificó como configuración de Checkstyle: las reglas **obligatorias** deben cumplirse sin excepción y las **recomendadas** se reportan como deuda técnica.

La Tabla 8.3 resume los casos y sus resultados.

Tabla 8.3: Pruebas de mantenibilidad

ID	Qué se verifica	Criterio	Resultado
MAN-01	Reglas obligatorias de la guía: nombre de archivo, sin tabuladores, sin importaciones con comodín, llaves siempre, un enunciado por línea, una variable por declaración, nombres, sin `System.out` ni excepciones ignoradas, `equals` con `hashCode`	0 violaciones	Fallida: 4 violaciones en 225 archivos (tres en `RevisionQuejaService`: dos enunciados en una línea, dos variables en una declaración y un `if` sin llaves; una importación estática con comodín en `RespuestaDenunciadoService`)
MAN-02	Métricas: complejidad ciclomática ≤ 15, NPath ≤ 400, método ≤ 80 líneas, ≤ 8 parámetros, acoplamiento de salida ≤ 30, archivo ≤ 800 líneas	Se reporta como deuda	Informativa: 5 métodos con complejidad mayor a 15, 117 tipos públicos sin Javadoc, 90 líneas de más de 120 columnas
MAN-03	Cobertura de líneas en los paquetes de servicios, validaciones y utilerías, medida con JaCoCo	$\geq 70\,\%$ por servicio	Pendiente de su primera ejecución (el reporte se genera en cada ejecución de las pruebas)
MAN-04	Cada servicio publica su contrato OpenAPI	10 de 10	Aprobada (Primer Contacto y Subdefensoría lo incorporaron al cierre)

El cumplimiento global de las reglas obligatorias es de cuatro violaciones en 225 archivos: corregirlas permite aprobar MAN-01. La deuda reportada por MAN-02 no es bloqueante, pero indica dónde conviene concentrar la refactorización; los métodos más complejos están en los servicios de revisión y de seguimiento, que concentran la lógica de los tableros.

8.4. Pruebas de usabilidad

La usabilidad no puede verificarse por completo con herramientas automáticas, porque depende de la experiencia de personas concretas. Se combinaron por ello mediciones automáticas de accesibilidad con pruebas con usuarios. La Tabla 8.4 resume los casos.

Tabla 8.4: Pruebas de usabilidad

ID	Qué se verifica	Requerimiento	Criterio	Resultado
USA-01	Cuestionario SUS a cinco usuarios después de las pruebas alfa [55]	RNF-G09	Puntaje ≥ 68	Pendiente: sesión alfa con la Defensoría
USA-02	Tareas cronometradas: presentar una queja, turnar, agendar una cita y dictaminar	RNF-Q05, RNF-A05	Tiempo y errores por tarea	Pendiente: sesión alfa
USA-03	Accesibilidad básica de los portales: contraste, etiquetas y uso con teclado, medida con Lighthouse	RNF-G09	Puntuación $\geq 0{,}85$	Configurada; informativa hasta definir el umbral por portal
USA-04	El portal del quejoso permite presentar la queja completa desde un teléfono	RNF-Q01	Flujo completo	Pendiente de verificación formal; diseño adaptable implementado
USA-05	El formulario de queja se presenta en pasos numerados con previsualización de archivos	RNF-Q05	Cumple	Aprobada por inspección
USA-06	Toda operación muestra éxito o error; sin fallos silenciosos	RNF-Q07	Cumple	Aprobada por inspección; se propone automatizarla con Playwright
USA-07	Cada indicador del panel de la Defensora abre la lista filtrada	RNF-A05	Cumple	Aprobada en revisión con capturas de las cinco pantallas

La validación cualitativa más importante ocurrió durante el desarrollo: las sesiones de revisión con el personal produjeron cambios concretos —la redacción jurídica de los requisitos de admisión, el paso de dos a cinco preguntas en la validación, la matrícula en dos pasos y el rediseño completo de Primer Contacto y del panel de la Defensora—, lo que equivale a varias iteraciones de prueba de usabilidad informal. La medición cuantitativa con SUS queda como criterio de salida de la etapa de aceptación.

8.5. Pruebas de fiabilidad

Las pruebas de fiabilidad verifican la tolerancia a fallos —que el fallo de un componente no detenga a los demás— y la recuperabilidad —que los datos puedan restaurarse—. Las primeras se implementaron como pruebas unitarias que simulan un servicio caído; las segundas, como guiones que operan sobre bases desechables.

Tabla 8.5: Pruebas de fiabilidad

ID	Qué se verifica	Requerimiento	Criterio	Resultado
FIA-05	Con el servicio de notificaciones sin conexión o respondiendo 500, los avisos de queja creada, al tutor, de cambio de estatus y al personal no propagan la excepción (4 casos)	RNF-Q04	Ninguna excepción se propaga	Implementada; pendiente de su primera ejecución
FIA-06	Con el servicio de notificaciones caído, el correo de observaciones y los avisos de Recepción no impiden el regreso de la queja (4 casos)	RNF-R04	Ninguna excepción se propaga	Implementada; pendiente de su primera ejecución
FIA-07	La importación del catálogo con filas mal formadas reporta un resumen y no falla en bloque	RNF-A04	Resumen de creadas, actualizadas y con error	Aprobada
FIA-04	Con Subdefensoría caída al dictaminar, el dictamen se conserva y puede reenviarse	RN-PC03	El dictamen no se pierde	Aprobada (prueba unitaria)
FIA-03	Respaldo manual, descarga y restauración en una base desechable	RNF-G04, CU-ADM-05	Sin errores de `psql`; tablas principales con filas	Pendiente de ejecución en el entorno de pruebas
FIA-01	Detener un contenedor auxiliar mientras se usa el sistema	RNF-Q04	El resto opera	Aprobada en operación (incidentes de la Sección **??**)
FIA-02	Reiniciar el servidor de aplicación	RNF-G04	Los contenedores se levantan solos	Aprobada en operación

Las pruebas FIA-05 y FIA-06 son el ejemplo más claro de cómo un incidente se convirtió en prueba. El defecto descrito en la Sección **??** —peticiones colgadas por una llamada sin tiempo de espera— se habría detectado con una prueba que simulara el servicio caído. Las pruebas usan un cliente HTTP simulado que lanza un error de conexión o un error 500 y verifican que ningún método del cliente de notificaciones propague la excepción hacia el servicio que lo invoca. La restauración (FIA-03) es la prueba de mayor impacto de esta sección: un respaldo que no puede restaurarse no es un respaldo, y la única forma de saberlo es restaurarlo. El guion genera un respaldo desde el panel, lo descarga, lo restaura en una base nueva y verifica que las tablas de quejas, personal y dependencias tengan filas.

8.6. Pruebas de seguridad

La seguridad se verificó en dos planos complementarios. En el plano estático, se extrajo del código la matriz completa de roles por punto de acceso y se comparó con las reglas que exigen los requerimientos. En el plano dinámico, la misma matriz se recorre contra el sistema en ejecución con un token por rol.

8.6.1. Matriz de permisos extraída del código

Un guion recorre los controladores de ocho de los diez servicios —Primer Contacto y Subdefensoría declaran sus permisos solo en la cadena de filtros y se verifican en la prueba dinámica—, lee las rutas, los métodos HTTP, las anotaciones `@PreAuthorize` y las reglas públicas de la cadena de filtros, y genera una matriz de 92 puntos de acceso con los roles que cada uno admite. Un segundo guion compara esa matriz con un archivo de reglas que traduce los requerimientos a expresiones sobre las rutas —por ejemplo, "`/api/admin/seguridad/(respaldos|restaurar)` solo admite a la Defensora"— y reporta cada diferencia. Al ser estática, la prueba puede ejecutarse con cada cambio del código y detecta, antes del despliegue, un punto de acceso nuevo que se haya publicado con permisos de más.

La primera ejecución encontró seis diferencias. Cuatro correspondían a los respaldos y la restauración, que el código abre al rol `DEFENSOR` mientras que la redacción original del requerimiento RNF-A06 los reservaba a un rol técnico de administración. Las otras dos correspondían a la consulta y emisión de acuerdos de conciliación, que el código abre también a Subdefensoría y a la Defensora, mientras que la redacción original de RN-R02 reservaba todo el servicio de revisión a Recepción. En ambos casos el análisis concluyó que el código reflejaba la decisión de diseño vigente —por convención con la Defensoría, la administración corresponde a la Defensora, y la conciliación es una actuación de varias áreas—, de modo que se corrigió la redacción de los requerimientos (Tablas 5.8 y 5.9) y el archivo de reglas, y no el código. El resultado ilustra un beneficio de esta prueba que va más allá de la seguridad: obliga a que el documento de requerimientos y el código digan lo mismo.

8.6.2. Casos de prueba de seguridad

La Tabla 8.6 reúne los casos de seguridad con su resultado.

Tabla 8.6: Pruebas de seguridad

ID	Qué se verifica	Requerimient	Criterio	Resultado
SEG-07	Matriz de permisos extraída del código contra las reglas de los requerimientos (34 puntos de acceso regulados de 92)	RNF-A06, RN-R02, RNF-R02, RNF-Q01, RNF-Q02, RN-Q12	0 diferencias	Fallida en la línea base (6 diferencias); resuelta al alinear los requerimientos

ID	Qué se verifica	Requerimiento	Criterio	Resultado
SEG-01	La matriz en vivo: sin token, 401 o 403; con un rol no permitido, 403; con el permitido, la petición pasa el filtro	RN-R02, RNF-A06	0 accesos indebidos	Pendiente de ejecución en el entorno de pruebas
SEG-10	Las rutas de Primer Contacto y Subdefensoría exigen token (antes eran públicas)	RN-R02	403 sin token	Aprobada en el servidor: consulta, PDF de oficios y evidencias responden 403 sin token
IT-04	Un quejoso no puede consultar ni editar la queja de otra persona cambiando el folio	RN-Q11	404	Aprobada por revisión de código (búsqueda por folio y correo del token)
SEG-08	El token vence a la hora (`exp` − `iat` = 3 600) y un token alterado se rechaza	RNF-Q06	3 600 s; 401 o 403	Aprobada por configuración y prueba unitaria de emisión; dinámica pendiente
SEG-09	Restaurar sin `çonfirmar": true` se rechaza	RNF-A03	Respuesta 4xx	Probable falla por revisión de código: se rechaza con una excepción genérica que se traduce en 500, no en 400
SEG-03	Recorrido de rutas (`../`) en la descarga y restauración de respaldos	RNF-A06	Distinto de 200	Fallida por revisión de código: el nombre de archivo no se valida contra la carpeta de respaldos (riesgo bajo: solo cuentas de administración)
SEG-05	Secretos —contraseña de la base, clave de firma de tokens, credenciales de correo— en el repositorio	RNF-G07	0 hallazgos	Fallida: residen en texto plano en los archivos de configuración
SEG-04	Dependencias Maven y npm con vulnerabilidades altas o críticas con parche	RNF-G07	0	Pendiente de su primera ejecución
SEG-02	Escaneo pasivo de vulnerabilidades web de los cinco portales	RNF-G06	Sin alertas altas	Pendiente (informativa)

ID	Qué se verifica	Requerimient	Criterio	Resultado
SEG-11	Los puertos de los servicios y de la base no son alcanzables desde Internet	RNF-G06	Conexión rechazada	Aprobada en operación (reglas en la tabla `raw`)

Tres resultados requieren acción. El más importante es SEG-05: las contraseñas y la clave de firma de los tokens están en los archivos de configuración versionados, y la rama de producción del repositorio pudo clonarse sin credenciales. La corrección consiste en rotar esos secretos, pasarlos a variables de entorno del servidor y retirarlos del historial del repositorio. SEG-03 se corrige verificando que la ruta normalizada del archivo permanezca dentro de la carpeta de respaldos, y SEG-09 con un manejador que traduzca la falta de confirmación a una respuesta 400.

8.7. Pruebas de capacidad

La capacidad se verifica en dos dimensiones: el tamaño máximo de una petición, que determina cuántas evidencias puede adjuntar un quejoso, y el número de usuarios concurrentes. Las pruebas de tamaño envían formularios multiparte vacíos a propósito, con un relleno del tamaño deseado, de modo que no crean quejas en el entorno.

Tabla 8.7: Pruebas de capacidad

ID	Qué se verifica	Requerimient	Criterio	Resultado
CAP-01	Una petición de 95 MB atraviesa el proxy	RNF-Q03	Distinto de 413	Pendiente de ejecución
CAP-02	Una petición de 105 MB es rechazada por el proxy	RNF-Q03	413	Pendiente de ejecución
CAP-03, CAP-04	Lo mismo directamente contra el servicio de quejas	RNF-Q03	Distinto de 413 / 413	Pendiente de ejecución
CAP-06	Coherencia entre el requerimiento y la configuración de cada servicio	RNF-Q03	Iguales	Observada y resuelta: el requerimiento indicaba 60 MB y los servicios aceptan 100 MB; se actualizó el requerimiento
CAP-07	Una queja con seis archivos, uno de 12.5 MB, se registra sin terminar el contenedor	RNF-Q03	Respuesta 200	Aprobada tras el redimensiona-miento de memoria

ID	Qué se verifica	Requerimient	Criterio	Resultado
CAP-05	50 usuarios virtuales concurrentes sobre las consultas públicas (catálogo, menú del chatbot, consulta por folio)	RNF-G05	p95 $<$ 1 s; errores $<$ 1 %	Pendiente de ejecución con k6

La prueba CAP-07 merece un comentario. El límite de tamaño de una petición no es solo una cifra de configuración: como las evidencias se guardan como contenido binario en la base, cada megabyte recibido se copia varias veces en memoria. Un límite de 100 MB por petición exige que el servicio tenga memoria para varias copias de esa petición, y la prueba con archivos reales fue la que reveló que el contenedor original no la tenía. Por eso RNF-Q03 se verifica con dos tipos de prueba: la de límites, que comprueba el rechazo, y la de archivos reales, que comprueba que lo aceptado se procesa.

8.8. Pruebas de confidencialidad

La confidencialidad se verifica con pruebas de caja negra que observan, desde fuera del servidor, cómo viaja la información. Son pasivas —no modifican datos— y por ello pueden ejecutarse también contra producción. El guion usa `openssl` para negociar conexiones con cada versión de TLS y `curl` para revisar redirecciones y encabezados.

Tabla 8.8: Pruebas de confidencialidad

ID	Qué se verifica	Requerimient	Criterio	Resultado
CON-01	Una petición HTTP se redirige a HTTPS	RNF-Q02	301 a `https`	Aprobada por configuración; dinámica pendiente
CON-02	Se aceptan TLS 1.2 y 1.3	RNF-Q02	Negociación exitosa	Aprobada por configuración (`ssl_protocols`)
CON-03	Se rechazan TLS 1.0 y 1.1	RNF-Q02	Negociación fallida	Aprobada por configuración
CON-04	Certificado válido con al menos 14 días de vigencia	RNF-Q02	Cumple	Aprobada por configuración (renovación automática con Certbot)
CON-05	El servidor envía el encabezado `Strict-Transport-Security`	RNF-Q02	Presente	Fallida: el proxy no lo envía
CON-06	Las respuestas JSON de la API no se comprimen (mitigación de BREACH)	RNF-Q02	Sin `Content-Encodi`	Aprobada por configuración

ID	Qué se verifica	Requerimient	Criterio	Resultado
CON-07	Las rutas internas de notificaciones e ingesta responden 403 desde Internet	RNF-G06	403	Aprobada por configuración; dinámica pendiente
CON-08	El inicio de sesión no usa *cookies* ni acepta credenciales en la URL; la sesión viaja en el encabezado `Authorization`	RNF-Q02	Sin `Set-Cookie`	Aprobada por diseño
CON-09	Las evidencias de una queja solo se entregan al quejoso dueño o al personal autorizado	RN-Q11	403 o 404 para terceros	Aprobada (cubierta por IT-04 y SEG-10)

La única falla, CON-05, se corrige con una línea en la configuración del servidor seguro del proxy. Varias pruebas figuran como aprobadas por configuración porque la configuración del proxy se revisó línea por línea; su ejecución dinámica, que confirma que esa configuración es la que realmente está cargada, queda pendiente para el entorno de pruebas.

8.9. Pruebas de los componentes de inteligencia artificial

La verificación de los componentes de inteligencia artificial comprendió dos tipos de actividades: la evaluación experimental de la recuperación de antecedentes con datos sintéticos y las pruebas funcionales y de integración realizadas sobre los servicios desplegados. En el caso de los resúmenes se verificaron tanto la respuesta técnica del servicio como la presencia de información relevante en una salida generada. Se distinguen expresamente las mediciones experimentales de las comprobaciones puntuales de funcionamiento, pues una respuesta HTTP correcta no demuestra por sí sola la calidad del contenido producido.

8.9.1. Evaluación de recuperación de antecedentes

Se utilizaron dos conjuntos sintéticos. El primero estuvo compuesto por 200 quejas extensas, organizadas en 25 escenarios con ocho variantes de redacción por escenario; cada queja se empleó como consulta y la relevancia se determinó mediante su pertenencia al mismo escenario. Para interpretar correctamente esta evaluación, debe comprobarse y dejarse explícito si cada consulta fue excluida de la colección de candidatos. Si no se excluyó, una coincidencia consigo misma podría sobrestimar la recuperación. La información presentada no basta para establecer cuál fue el tratamiento aplicado. El segundo incluyó 15 consultas contrastivas frente a 45 documentos candidatos, con un antecedente positivo sintético por consulta y documentos distractores. Estas etiquetas representan relaciones diseñadas para el experimento y no equivalen a una valoración jurídica de los expedientes.

Para estudiar la combinación de los recuperadores léxico (TF-IDF) y semántico (MiniLM) se reutilizaron los rankings calculados previamente por ambos modelos. La fusión se realizó con *Reciprocal Rank Fusion* (RRF), considerando los diez primeros candidatos de cada recuperador y una constante de suavizado de 60. Se examinaron 101 distribuciones de peso, desde 100 % léxico hasta

100 % semántico, con incrementos de un punto porcentual. Esta operación recalculó la fusión sobre rankings guardados; no supuso ejecutar nuevamente MiniLM para cada combinación ni consultar los expedientes del servidor de producción.

Se calcularon precisión en los primeros cinco resultados (P@5), exhaustividad en los primeros diez (R@10), rango recíproco medio (MRR) y ganancia acumulada descontada normalizada (nDCG@5), entre otras métricas. La Tabla 8.9 muestra una selección de ponderaciones para las 200 quejas extensas.

Tabla 8.9: Resultados de recuperación en 200 quejas sintéticas extensas

TF-IDF / MiniLM	**P@5**	**R@10**	**nDCG@5**
100 % / 0 %	45.2 %	91.5 %	0.435
90 % / 10 %	52.3 %	91.5 %	0.496
75 % / 25 %	52.0 %	91.5 %	0.490
50 % / 50 %	49.7 %	67.5 %	0.471
25 % / 75 %	48.5 %	46.5 %	0.457
0 % / 100 %	33.5 %	46.5 %	0.325

La búsqueda con predominio léxico obtuvo el mejor P@5 entre las configuraciones mostradas, pero la diferencia entre 90 / 10 y 75 / 25 fue de solo 0.3 puntos porcentuales. En la búsqueda más fina de 101 combinaciones, la ponderación 91 / 9 también alcanzó un P@5 de 52.3 %. Por tanto, los datos no permiten afirmar una superioridad concluyente de una ponderación concreta. Además, el resultado depende de la métrica seleccionada: el orden más favorable para P@5 no tiene por qué serlo para la primera posición.

La configuración final adoptada para el servicio fue 75 % TF-IDF y 25 % MiniLM en la fusión RRF ponderada. En este primer conjunto alcanzó P@5 de 52.0 %, R@10 de 91.5 % y nDCG@5 de 0.490. La elección no equivale a afirmar que sea la mejor ponderación para todos los escenarios: se conserva como configuración de implementación y se reportan sus limitaciones.

La Tabla 8.10 resume la prueba contrastiva. En este conjunto, donde se introdujeron diferencias de redacción y distractores, la mayor influencia del recuperador semántico produjo una exhaustividad sustancialmente superior. Dado que solo existe un antecedente relevante por consulta, el valor máximo teórico de P@5 es 20 % cuando se devuelven cinco resultados: por ello, sus porcentajes no son directamente comparables con los del conjunto de 200 quejas, que tiene varios documentos relevantes por escenario. Para este segundo conjunto resultan particularmente interpretables las métricas Hit@k y MRR; deben añadirse sus resultados solo cuando se cuente con las salidas verificadas del experimento.

Tabla 8.10: Resultados en 15 consultas sintéticas contrastivas

TF-IDF / MiniLM	**P@5**	**R@10**	**nDCG@5**
90 % / 10 %	2.7 %	13.3 %	0.084
75 % / 25 %	2.7 %	13.3 %	0.084
50 % / 50 %	9.3 %	86.7 %	0.216

TF-IDF / MiniLM	P@5	R@10	nDCG@5
25 % / 75 %	9.3 %	93.3 %	0.219
0 % / 100 %	17.3 %	93.3 %	0.669

En particular, la ponderación final 75/25 alcanzó P@5 de 2.7 %, R@10 de 13.3 % y nDCG@5 de 0.084 en las consultas contrastivas. Este resultado advierte que la configuración seleccionada puede omitir antecedentes relevantes cuando existe poca coincidencia léxica, por lo que debe mantenerse la revisión humana y ampliarse la evaluación de casos parafraseados.

Los resultados evidencian un compromiso entre coincidencia léxica y recuperación semántica, no una ponderación universalmente óptima. La diferencia entre conjuntos podría relacionarse con el grado de coincidencia de vocabulario, las paráfrasis y la construcción de distractores, pero estas hipótesis requieren un análisis individual de consultas fallidas para comprobarse. La selección de pesos se examinó también mediante particiones por escenario, con el propósito de no ajustar y medir una configuración sobre los mismos grupos sintéticos. No obstante, el documento no especifica el número de particiones, sus tamaños ni los resultados diferenciados de selección y evaluación, por lo que aún no puede considerarse reproducible dicho procedimiento. Aun así, los conjuntos no han sido etiquetados por especialistas de la Defensoría; por tanto, estas medidas describen el comportamiento experimental del recuperador y no su precisión sobre expedientes institucionales reales.

8.9.2. Funcionamiento del índice y respuesta de antecedentes

En el servidor se verificó la construcción del índice sobre 1 210 registros y la persistencia de sus representaciones semánticas. Una actualización posterior, sin cambios en los documentos, informó 1 210 representaciones reutilizadas y ninguna recalculada. El servicio informó estado listo mediante su punto de comprobación de disponibilidad.

También se ejecutaron consultas HTTP de búsqueda de antecedentes con respuesta satisfactoria (código 200). En una consulta sintética de revisión de calificación, la API de análisis respondió en aproximadamente 0.135 segundos; en otra consulta realizada mediante el contrato de integración se registró un tiempo cercano a 0.111 segundos. Estas cifras son observaciones puntuales con el índice disponible, no percentiles de latencia ni pruebas de concurrencia.

8.9.3. Generación de resúmenes e integración con los servicios

Se envió una queja sintética al servicio de resúmenes, que realiza una selección extractiva de información y posteriormente utiliza un modelo generativo para redactar un borrador en estilo institucional. La solicitud devolvió HTTP 200 y un tiempo total de 26.304 segundos. Se confirmó la presencia de un texto generado y del indicador de revisión humana requerida.

La inspección del resultado permitió identificar tanto elementos conservados como omisiones. Es una observación cualitativa de un caso, no una tasa de fidelidad o de cobertura para el componente de generación. Se mantuvieron las referencias a los correos electrónicos y capturas del sistema, así como la negación de agresión física; en cambio, no se conservaron las dos fechas explícitas ni el cambio de calificación de ocho a seis. Por tanto, esta prueba fue satisfactoria en respuesta técnica, pero detectó una limitación de cobertura factual. No se completó en esa prueba la atribución de

las omisiones a la fase extractiva o a la edición generativa. Para efectuar esa atribución podría compararse, incluso con entradas sintéticas, el texto original, la selección extractiva y el borrador generado, verificando acontecimientos, negaciones, fechas, cantidades y evidencias. Hasta disponer de esa comparación, no corresponde atribuir la pérdida de información exclusivamente a MMR o a Qwen3.

La evaluación efectuada no incluyó un conjunto amplio de resúmenes evaluados mediante criterios institucionales, ni una validación formal con expedientes reales y personal de la Defensoría de los Derechos Politécnicos. Estas actividades no pudieron completarse debido al tiempo disponible para el desarrollo y la presentación del Trabajo Terminal. En consecuencia, las pruebas con narrativas sintéticas permiten comprobar la integración y detectar errores puntuales, pero no establecer un nivel de fidelidad, cobertura o utilidad generalizable a la operación de la Defensoría. Como trabajo futuro, se propone una evaluación con expedientes reales debidamente autorizados y revisión de personal institucional, con criterios explícitos para la conservación de hechos, actores, fechas, negaciones, cantidades, evidencias y solicitudes. Este trabajo debe distinguir las posibles omisiones de la etapa extractiva de las modificaciones introducidas por la etapa generativa.

Después del despliegue se comprobó, mediante solicitudes al punto de salud, que el servicio Java de Primer Contacto podía comunicarse con el servicio de resúmenes (HTTP 200) y que este último podía comunicarse con el servidor del modelo generativo (HTTP 200). Estas comprobaciones acreditan conectividad entre componentes, pero no constituyen una medición de calidad del resumen ni una prueba de carga.

8.9.4. Alcance de los resultados de inteligencia artificial

Las pruebas ejecutadas permiten documentar el comportamiento de la fusión de rankings sobre conjuntos sintéticos, la reutilización del índice y el funcionamiento de las interfaces HTTP. Sin embargo, no demuestran que la ponderación 75/25 sea óptima sobre quejas reales ni la conservación factual sistemática de los resúmenes. La verificación de una salida generada no sustituye un estudio con múltiples documentos y criterios de revisión previamente definidos. Por cuestiones de tiempo no fue posible llevar a cabo la validación con expedientes reales ni la revisión formal por parte del personal de la Defensoría. Este alcance debe distinguirse de las pruebas técnicas que sí fueron ejecutadas con datos sintéticos. La evaluación institucional queda identificada como trabajo futuro y requiere acceso autorizado a los expedientes, definición de criterios con los especialistas y análisis independiente de las etapas extractiva y generativa. Tampoco se documentan una prueba de concurrencia para la inferencia ni una distribución representativa de los tiempos de respuesta.

8.10. Resumen de resultados

La Tabla 8.11 reúne los defectos abiertos que dejaron las pruebas, con la acción que resuelve cada uno.

Tabla 8.11: Defectos abiertos y acción correctiva

Prueba	Defecto	Severidad	Acción
SEG-05	Secretos en texto plano en el repositorio	Alta	Rotarlos, pasarlos a variables de entorno y depurar el historial
CON-05	Falta el encabezado HSTS	Media	Agregar `Strict-Transport-Security` en el servidor seguro del proxy
SEG-03	La descarga y restauración de respaldos no valida la ruta	Baja	Normalizar la ruta y exigir que quede dentro de la carpeta de respaldos
SEG-09	Restaurar sin confirmación responde 500	Baja	Responder 400 desde el manejador global
MAN-01	Cuatro violaciones obligatorias de estilo	Baja	Corregir las cuatro líneas

Los resultados registrados respaldan el correcto funcionamiento de las reglas cubiertas por la ejecución inicial de 364 pruebas unitarias y determinadas integraciones verificadas en el entorno descrito. Sin embargo, las pruebas unitarias no equivalen a una validación completa de los flujos de extremo a extremo. La automatización con Playwright, la medición de cobertura, varias verificaciones dinámicas de seguridad y confidencialidad, las pruebas de carga y la aceptación formal permanecen pendientes o solo parcialmente verificadas. Los ocho casos adicionales de resiliencia mencionados en la sección de pruebas unitarias tampoco deben sumarse a las 364 pruebas iniciales sin incorporar su resultado de ejecución correspondiente.

La protección de la información requiere atención prioritaria. El hallazgo SEG-05 identifica secretos expuestos en archivos versionados; mientras no se roten y retiren, no debe declararse completamente satisfecho el criterio de seguridad. Asimismo, los resultados de inteligencia artificial documentan el funcionamiento de los servicios y el comportamiento de los experimentos sintéticos, pero no acreditan todavía calidad generalizada sobre expedientes institucionales. La validación con expedientes reales y personal de la Defensoría no se completó debido a las restricciones de tiempo del proyecto; queda registrada como trabajo futuro, no como una prueba aprobada ni como una condición que invalide las verificaciones técnicas ya realizadas. El estado final de las pruebas debe describirse, por tanto, como una validación parcial con resultados aprobados, hallazgos abiertos y actividades pendientes, sin extrapolar esos resultados a condiciones que no fueron ensayadas.

Referencias

[1] Instituto Politécnico Nacional. «Ley Orgánica del Instituto Politécnico Nacional,» visitado 10 de abr. de 2026. dirección: https://www.ipn.mx/assets/files/defensoria/docs/manuales/ley-org%C3%A1nica-ipn.pdf

[2] Instituto Politécnico Nacional, «Acuerdo de creación de la Defensoría de los Derechos Politécnicos,» *Gaceta Politécnica*, n.º 622 (Extraordinaria), págs. 3-7, ene. de 2006. visitado 10 de abr. de 2026. dirección: https://www.ipn.mx/assets/files/imageninstitucional/docs/gaceta-extraordinaria/2006/01/622-31-enero-gaceta-extra-.pdf

[3] Instituto Politécnico Nacional, «Manual de Organización de la Defensoría de los Derechos Politécnicos,» Dirección de Planeación y Organización, Ciudad de México, México, oct. de 2022. visitado 10 de abr. de 2026. dirección: https://www.ipn.mx/assets/files/defensoria/docs/manuales/moddp2022.pdf

[4] Instituto Politécnico Nacional, «Manual de Procedimientos de la Defensoría de los Derechos Politécnicos,» Dirección de Planeación y Organización, Ciudad de México, México, oct. de 2024. visitado 10 de abr. de 2026. dirección: https://www.ipn.mx/assets/files/defensoria/docs/manuales/mp-ddp.pdf

[5] Amazon Web Services. «¿Qué son los microservicios?» Visitado 10 de abr. de 2026. dirección: https://aws.amazon.com/es/microservices/

[6] M. Villamizar et al., «Evaluating the Monolithic and the Microservice Architecture Pattern to Deploy Web Applications in the Cloud,» Universidad de los Andes, Colombia.

[7] BBVA. «Arquitectura de software o sistemas: ¿qué es y ejemplos?» Visitado 10 de abr. de 2026. dirección: https://www.bbva.com/es/innovacion/arquitectura-de-software-o-sistemas-que-es-y-ejemplos/

[8] UTEL. «Atributos de calidad del software,» SCALA, visitado 10 de abr. de 2026. dirección: https://gc.scalahed.com/recursos/files/r161r/w26023w/L1IDS118_l2_s3.pdf

[9] Microsoft. «¿Qué es la escalabilidad?» Microsoft Learn, visitado 10 de abr. de 2026. dirección: https://learn.microsoft.com/es-es/biztalk/core/what-is-scalability

[10] Amazon Web Services. «Construcción de una arquitectura distribuida y escalable,» visitado 10 de abr. de 2026. dirección: https://aws.amazon.com/startups/learn/building-scalable-distributed-architecture?lang=es

[11] M. T. Nygard, *Release It!: Design and Deploy Production-Ready Software*. Pragmatic Bookshelf.

[12] IBM. «¿Qué es una arquitectura monolítica?» Visitado 10 de abr. de 2026. dirección: https://www.ibm.com/think/topics/monolithic-architecture

[13] A. S. Tanenbaum et al., *Arquitectura de Sistemas Distribuidos*.

[14] IBM. «¿Qué es la arquitectura de tres capas?» Visitado 10 de abr. de 2026. dirección: https://www.ibm.com/mx-es/think/topics/three-tier-architecture

[15] Microsoft Ibérica, *Guía de Arquitectura N-Capas orientada al Dominio con .NET 4.0*.

[16] B. M. Coti Colop, «Reglas del Negocio en Arquitectura Tres Capas,» Tesis de mtría., Universidad de San Carlos de Guatemala.

[17] J. L. Poza Luján, «Propuesta de arquitectura distribuida de control inteligente basada en políticas de calidad de servicio,» Tesis doct., Universitat Politècnica de València.

[18] R. T. Fielding, «Architectural Styles and the Design of Network-based Software Architectures,» Tesis doct., University of California, Irvine.

[19] B. Stopford, *Designing Event-Driven Systems: Concepts and Patterns for Streaming Services with Apache Kafka*. O'Reilly Media.

[20] Spring Cloud. «Spring Cloud Config & Netflix Eureka,» VMware, Inc., visitado 10 de abr. de 2026. dirección: https://spring.io/projects/spring-cloud

[21] IBM. «¿Qué es PostgreSQL?» Visitado 10 de abr. de 2026. dirección: https://www.ibm.com/mx-es/think/topics/postgresql

[22] H. J. Schönig, *Mastering PostgreSQL 15: Advanced techniques to build and manage scalable, reliable, and fault-tolerant database applications*. Packt Publishing.

[23] M. Kleppmann, *Designing Data-Intensive Applications: The Big Ideas Behind Reliable, Scalable, and Maintainable Systems*. O'Reilly Media.

[24] Oracle. «¿Qué es la tecnología Java y para qué la necesito?» Visitado 10 de abr. de 2026. dirección: https://www.java.com/es/download/help/whatis_java.html

[25] IBM. «¿Qué es Java?» Visitado 10 de abr. de 2026. dirección: https://www.ibm.com/mx-es/think/topics/java

[26] IBM. «¿Qué es Spring Boot?» Visitado 10 de abr. de 2026. dirección: https://www.ibm.com/mx-es/think/topics/java-spring-boot

[27] C. Álvarez Caules. «Spring Boot Actuator,» Arquitectura Java, visitado 10 de abr. de 2026. dirección: https://www.arquitecturajava.com/spring-boot-actuator/

[28] Amazon Web Services. «¿Qué es Python?» Visitado 10 de abr. de 2026. dirección: https://aws.amazon.com/es/what-is/python/

[29] Angular. «What is Angular?» Visitado 10 de abr. de 2026. dirección: https://angular.dev/overview

[30] Imagina Formación. «Conoce las ventajas de utilizar Angular,» visitado 10 de abr. de 2026. dirección: https://imaginaformacion.com/tutoriales/conoce-las-ventajas-de-utilizar-angular

[31] Red Hat. «¿Qué es Docker?» Visitado 10 de abr. de 2026. dirección: https://www.redhat.com/es/topics/containers/what-is-docker

[32] B. Burns, J. Beda y K. Hightower, *Kubernetes: Up and Running: Dive into the Future of Infrastructure*. O'Reilly Media.

[33] NGINX. «nginx,» visitado 10 de abr. de 2026. dirección: https://nginx.org/en/

[34] B. Khanal. «Nginx: The Lightweight Powerhouse for Modern Web Serving,» Medium, visitado 10 de abr. de 2026. dirección: https://medium.com/@bishal.khanal.2057/nginx-the-lightweight-powerhouse-for-modern-web-serving-717f7cc628da

[35] GitHub. «Acerca de GitHub y Git,» visitado 10 de abr. de 2026. dirección: https://docs.github.com/es/get-started/start-your-journey/about-github-and-git

[36] E. Linis. «Conceptos Básicos de Git,» GitHub Gist, visitado 10 de abr. de 2026. dirección: https://gist.github.com/erlinis/57a55dfb0337f5cd15cd

[37] Spring Security. «OAuth 2.0 Resource Server JWT,» VMware, Inc., visitado 10 de abr. de 2026. dirección: https://docs.spring.io/spring-security/reference/servlet/oauth2/resource-server/jwt.html

[38] E. Rescorla, «The Transport Layer Security (TLS) Protocol Version 1.3,» Internet Engineering Task Force (IETF), RFC 8446.

[39] D. Jurafsky y J. H. Martin, *Speech and Language Processing*, 3.ª ed. Stanford University, 2023, Borrador. dirección: https://web.stanford.edu/~jurafsky/slp3/

[40] C. D. Manning, P. Raghavan y H. Schütze, *Introduction to Information Retrieval*. Cambridge, Reino Unido: Cambridge University Press, 2008. dirección: https://nlp.stanford.edu/IR-book/

[41] T. Mikolov, I. Sutskever, K. Chen, G. S. Corrado y J. Dean, «Distributed Representations of Words and Phrases and their Compositionality,» en *Advances in Neural Information Processing Systems 26 (NIPS 2013)*, 2013, págs. 3111-3119. dirección: https://arxiv.org/abs/1310.4546

[42] M. Honnibal, I. Montani, S. V. Landeghem y A. Boyd, *spaCy: Industrial-strength Natural Language Processing in Python*, 2020. DOI: 10.5281/zenodo.1212303

[43] N. Reimers e I. Gurevych, «Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks,» en *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)*, Hong Kong, China, nov. de 2019, págs. 3982-3992. dirección: https://arxiv.org/abs/1908.10084

[44] A. Vaswani et al., «Attention is All You Need,» en *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 2017, págs. 5998-6008. dirección: https://arxiv.org/abs/1706.03762

[45] W. Wang, F. Wei, L. Dong, H. Bao, N. Yang y M. Zhou, «MiniLM: Deep Self-Attention Distillation for Task-Agnostic Compression of Pre-Trained Transformers,» en *Advances in Neural Information Processing Systems*, vol. 33, 2020, págs. 5776-5788.

[46] G. V. Cormack, C. L. A. Clarke y S. Buettcher, «Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods,» en *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2009, págs. 758-759. DOI: 10.1145/1571941.1572114

[47] K. Järvelin y J. Kekäläinen, «Cumulated Gain-Based Evaluation of IR Techniques,» *ACM Transactions on Information Systems*, vol. 20, n.º 4, págs. 422-446, 2002. DOI: 10.1145/582415.582418

[48] J. Carbonell y J. Goldstein, «The Use of MMR, Diversity-Based Reranking for Reordering Documents and Producing Summaries,» en *Proceedings of the 21st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, 1998, págs. 335-336. DOI: 10.1145/290941.291025

[49] International Organization for Standardization, *ISO/IEC 25010:2023 Systems and software engineering – Systems and software Quality Requirements and Evaluation (SQuaRE) – Product quality model*, Ginebra, Suiza: ISO/IEC, 2023. visitado 30 de oct. de 2026. dirección: https://www.iso.org/standard/78176.html

[50] G. J. Myers, C. Sandler y T. Badgett, *The Art of Software Testing*, 3.ª ed. Hoboken, NJ: John Wiley & Sons, 2011.

[51] D. Graham, R. Black y E. van Veenendaal, *Foundations of Software Testing: ISTQB Certification*, 4.ª ed. Andover, Reino Unido: Cengage Learning, 2019.

[52] The JUnit Team. «JUnit 5 User Guide,» visitado 30 de oct. de 2026. dirección: https://junit.org/junit5/docs/current/user-guide/

[53] Mockito. «Mockito Framework,» visitado 30 de oct. de 2026. dirección: https://site.mockito.org/

[54] Google. «Google Java Style Guide,» visitado 30 de oct. de 2026. dirección: https://google.github.io/styleguide/javaguide.html

[55] J. Brooke, «SUS: A "Quick and Dirty" Usability Scale,» en *Usability Evaluation in Industry*, P. W. Jordan, B. Thomas, I. L. McClelland y B. Weerdmeester, eds., Londres: Taylor & Francis, 1996, págs. 189-194.